



UNIVERSIDADE ESTADUAL DE CAMPINAS
Faculdade de Ciências Aplicadas

WILMER DARIO URANGO NARVAEZ

OTIMIZAÇÃO DA RECEITA NO TRANSPORTE FERROVIÁRIO DE
PASSAGEIROS: UM ESTUDO BASEADO EM MODELOS DE DEMANDA
INDEPENDENTE E COMPORTAMENTAL

Limeira
2025

WILMER DARIO URANGO NARVAEZ

OTIMIZAÇÃO DA RECEITA NO TRANSPORTE FERROVIÁRIO DE
PASSAGEIROS: UM ESTUDO BASEADO EM MODELOS DE DEMANDA
INDEPENDENTE E COMPORTAMENTAL

Dissertação apresentada à Faculdade de Ciências Aplicadas da Universidade Estadual de Campinas como parte dos requisitos exigidos para a obtenção do título de Mestre em Engenharia de Produção e de Manufatura, na Área de Pesquisa Operacional e Gestão de Processos.

Orientador: Prof. Dr. Diego Jacinto Fiorotto

ESTE TRABALHO CORRESPONDE À
VERSÃO FINAL DA DISSERTAÇÃO DE-
FENDIDA PELO ALUNO WILMER DA-
RIO URANGO NARVAEZ, E ORIEN-
TADA PELO PROF. DR. DIEGO JA-
CINTO FIOROTTO.

Limeira
2025

Ficha catalográfica
Universidade Estadual de Campinas (UNICAMP)
Biblioteca da Faculdade de Ciências Aplicadas
Renata Eleuterio da Silva - CRB 8/9281

N169o Narvaez, Wilmer Darío Urango, 1995-
Otimização da receita no transporte ferroviário de passageiros : um estudo baseado em modelos de demanda independente e comportamental / Wilmer Darío Urango Narvaez. – Limeira, SP : [s.n.], 2025.

Orientador: Diego Jacinto Fiorotto.
Coorientador: Karim Perez Martínez.
Dissertação (mestrado) – Universidade Estadual de Campinas (UNICAMP), Faculdade de Ciências Aplicadas.

1. Pesquisa operacional. 2. Transporte ferroviário. 3. Programação linear inteira mista. I. Fiorotto, Diego Jacinto, 1987-. II. Martínez, Karim Perez. III. Universidade Estadual de Campinas (UNICAMP). Faculdade de Ciências Aplicadas. IV. Título.

Informações complementares

Título em outro idioma: Optimization of revenue in passenger rail transportation : a study based on independent and behavioral demand models

Palavras-chave em inglês:

Operations research

Railroads

Mixed-integer linear programming

Área de concentração: Pesquisa Operacional e Gestão de Processos

Titulação: Mestre em Engenharia de Produção e de Manufatura

Banca examinadora:

Diego Jacinto Fiorotto [Orientador]

Priscila Cristina Berbert Rampazzo

Luciano Carlos Azevedo da Costa

Data de defesa: 06-06-2025

Programa de Pós-Graduação: Engenharia de Produção e de Manufatura

Objetivos de Desenvolvimento Sustentável (ODS)

Não se aplica

Identificação e informações acadêmicas do(a) aluno(a)

- ORCID do autor: <https://orcid.org/0000-0002-2522-257X>

- Currículo Lattes do autor: <http://lattes.cnpq.br/5817368702629798>

Prof. Dr. Diego Jacinto Fiorotto

Prof. Dra. Priscila Cristina Berbert Rampazzo

Prof. Dr. Luciano Carlos Azevedo da Costa

A Ata da defesa com as respectivas assinaturas dos membros encontra-se no SIGA/Sistema de Fluxo de Dissertação/Tese e na Secretaria do Programa da Unidade.

Agradecimientos

A Dios, por bendecirme cada día, por poner en mi vida a las personas adecuadas y darme la sabiduría de tomar buenas decisiones.

A mi madre, Saudith Narváez, por cada consejo, por confiar en mí en cada decisión que he tomado hasta este punto y por su ayuda incondicional; a mi padre, Walter Urango, por su fuerza y ejemplo, que me enseñaron a ser un hombre de bien y de buenos principios; a mis hermanos, Yeiner y Steven Urango, por su apoyo y motivación que me dieron en cada instante.

A mi esposa, Edith Gonzalez, por estar junto a mí en cada paso, por ayudarme en cada momento y por ser uno de mis motores para seguir adelante en esos tiempos difíciles. A mi hijo, Johan Urango, que, aunque recién nacido, ya es la mayor motivación para continuar luchando en esta vida.

A mi orientador, el Dr. Diego Jacinto Fiorotto, por todo su tiempo, ayuda y dedicación para llevar a cabo este objetivo, no solo en la parte académica, sino también en la parte personal.

A la Dra. Karim Perez Martínez, quien confió en mí y me hizo parte de este mundo del revenue management.

Y, en general, a todos mis amigos que en cierto punto fueron una ayuda en cada uno de los pasos de este proceso.

O presente trabalho foi realizado com apoio da Coordenação de Aperfeiçoamento de Pessoal de Nível Superior - Brasil (CAPES) - Código de Financiamento 001.

Esta dissertação aborda o problema da gestão de receitas no transporte ferroviário de passageiros, no qual a capacidade de assentos é perecível e a demanda apresenta substituição entre tarifas e variação temporal. Esse cenário configura um desafio típico dessa área: aceitar uma reserva a um preço mais baixo no presente pode impedir a venda futura de uma tarifa mais elevada, mas rejeitá-la pode resultar em assentos ociosos em outros trechos da rede.

O problema central consiste em decidir, para cada origem-destino, o tipo de assento e o período de reserva, estabelecendo quantos assentos de cada classe devem ser protegidos (reservas) e quantos devem ser disponibilizados para venda (autorizações) em um trem de passageiros.

Esse processo deve levar em conta que os clientes podem escolher dentro de um conjunto de tarifas, que os assentos não vendidos representam perda definitiva de capacidade e que a empresa pode impor restrições operacionais, como *fulfillment over periods* ou *skip-lagging*.

O gap identificado na literatura é a ausência de modelos que apliquem simultaneamente a modelagem baseada em transporte de veículos e fluxo em redes ao problema em questão. Para preencher essa lacuna, foram formulados dezesseis modelos de programação linear inteira mista, que, além da abordagem matemática mencionada, combinam dois enfoques de demanda (independente e comportamental) com políticas de autorizações de vendas de assentos estáticas e dinâmicas, incorporando também as restrições operacionais de *fulfillment over periods* e *skip-lagging*. Os modelos foram implementados no Python usando o solver Gurobi e foram avaliados com dez instâncias reais de uma empresa canadense, analisando tempos de computação, receitas totais, cobertura da demanda e a estrutura unimodular das matrizes.

Os resultados mostram que as autorizações dinâmicas recuperam grande parte da receita perdida devido à imposição de restrições operacionais, enquanto a demanda comportamental reflete melhor o comportamento real de compra sem penalizar o desempenho computacional. Conclui-se que a integração da escolha do passageiro, o controle dinâmico de inventário e as regras empresariais oferece uma ferramenta rigorosa e aplicável para a tomada de decisões táticas e estratégicas na gestão de receitas ferroviárias.

Palavras-chaves: Gestão da Receita, Demanda Comportamental, Transporte Ferroviário de Passageiros, Programação Inteira Mista.

Abstract

This dissertation addresses the problem of revenue management in passenger rail transport, in which seat capacity is perishable and demand exhibits substitution among fares and temporal variation. This scenario represents a typical challenge in this field: accepting a reservation at a lower price in the present may prevent the future sale of a higher fare, but rejecting it may result in idle seats on other segments of the network.

The central problem consists in deciding, for each origin-destination pair, the type of seat and the reservation period, establishing how many seats of each class should be protected (reservations) and how many should be made available for sale (authorizations) on a passenger train.

This process must take into account that customers may choose within a set of fares, that unsold seats represent a definitive loss of capacity, and that the company may impose operational restrictions, such as fulfillment over periods or skip-lagging.

The gap identified in the literature is the absence of models that simultaneously apply vehicle-transport and network-flow-based modeling to the problem at hand. To fill this gap, sixteen mixed-integer linear programming models were formulated, which, in addition to the aforementioned mathematical approach, combine two demand perspectives (independent and behavioral) with static and dynamic seat sale authorization policies, also incorporating the operational constraints of fulfillment over periods and skip-lagging. The models were implemented in Python using the Gurobi solver and evaluated with ten real instances from a Canadian company, analyzing computation times, total revenues, demand coverage, and the unimodular structure of the matrices.

The results show that dynamic authorizations recover a large share of the revenue lost due to the imposition of operational constraints, while behavioral demand better reflects actual purchasing behavior without penalizing computational performance. It is concluded that the integration of passenger choice, dynamic inventory control, and business rules provides a rigorous and applicable tool for tactical and strategic decision-making in railway revenue management.

Keywords: Revenue Management, Behavioral Demand, Passenger Rail Transportation, Mixed Integer Programming.

Lista de Figuras

3.1	Representação de viagem	37
3.2	Representação de trechos	38
3.3	Representação de itinerários	38
3.4	Representação do horizonte de reserva	39
3.5	Classes de autorização	39
3.6	Representação de demanda comportamental	40
3.7	Representação de demanda independente	40
3.8	Versão gráfica simples do Problema de Transporte Ferroviário de Passageiros	44
3.9	Solução factível para o problema simplificado	45
3.10	Exemplo de <i>nesting</i> para o trecho $E_1 - E_2$ e tipo de assento P	50
3.11	Exemplo cálculo da variável β para o trecho $E_1 - E_2$, um período e um tipo de assento	51
3.12	Exemplo: Tipos de Demanda	53
3.13	Exemplo: demanda comportamental para a classe c_1	54
3.14	Exemplo: demanda comportamental para a classe c_2	54
3.15	Exemplo: demanda comportamental para a classe c_3	54
3.16	Exemplo: demanda comportamental total potencial	55
4.1	Porcentagem de demanda atendida (%)	75
4.2	Tempos de construção, em segundos, de cada modelo para cada instância	76
4.3	Tempos de resolução, em segundos, de cada modelo para cada instância	77

Lista de Tabelas

2.1	Resumo dos trabalhos revisados	35
3.1	Descrição dos modelos matemáticos propostos	46
4.1	Resumo das instâncias utilizadas no experimento	66
4.2	Valores ótimos e variações em função do modelo <code>Basic_Independ_Est</code> para a abordagem de demanda independente com autorizações estáticas.	67
4.3	Valores ótimos e variações em função do modelo <code>Basic_Comporta_Est</code> para a abordagem de demanda comportamental com autorizações estáticas.	67
4.4	Valores ótimos e variações em função do modelo <code>Basic_Independ_Din</code> para a abordagem de demanda independente com autorizações dinâmicas.	67
4.5	Valores ótimos e variações em função do modelo <code>Basic_Comporta_Din</code> para a abordagem de demanda comportamental com autorizações estáticas.	68
4.6	Resultados ótimos de cada modelo para cada instância	69
4.7	Comparação das variações das diferenças dos modelos completos para a instância <code>Inst1</code>	70
4.8	Exemplo de combinações	71
4.9	Quantidade de combinações, por instância, que possuem mais de 1 classe de controle	72
4.10	Quantidade de soluções ótimas para cada modelo e instância	73
4.11	Nós explorados pelo solver para encontrar a solução ótima	78
4.12	Modelos não unimodulares para cada instância	80

1	Introdução	12
1.1	Apresentação do tema	12
1.2	Justificativa	13
2	Revisão da literatura	15
2.1	Fundamentos da gestão de receitas (RM)	15
2.1.1	Definição e importância	15
2.1.2	Histórico e evolução	16
2.2	Transporte Ferroviário de Passageiros	19
2.2.1	Áreas de pesquisa	20
2.2.2	Controle de inventário	21
2.2.3	Modelagem da demanda	23
2.3	Aplicação de RM ao transporte ferroviário de passageiros	25
2.4	Outras aplicações industriais de RM	28
2.4.1	Aviação	28
2.4.2	Hotelaria	32
2.5	Contextualização desta pesquisa	35
3	Modelagem matemática	37
3.1	Conceitos importantes	37
3.2	Descrição do problema	41
3.3	Formulação matemática	43
3.4	Abordagem dos modelos propostos	45
3.4.1	Primeira abordagem: modelos com autorizações estáticas e demanda independente	47
3.4.2	Segunda abordagem: modelos com autorizações estáticas e demanda comportamental	52
3.4.3	Terceira abordagem: modelos com autorizações dinâmicas e demanda independente	60

3.4.4	Quarta abordagem: modelos com autorizações dinâmicas e demanda comportamental	62
4	Análise e resultados computacionais	65
4.1	Instâncias	65
4.2	Ferramentas e ambiente computacional	66
4.3	Análise por abordagem	66
4.4	Comparação entre modelos	69
4.5	Quantidade de soluções	72
4.6	Métricas de Avaliação	74
4.6.1	Demanda atendida	74
4.6.2	Tempos de construção e de resolução	76
4.6.3	Nós explorados	77
4.6.4	Matrizes totalmente unimodulares	78
5	Conclusões e trabalhos futuro	82
6	Referências	85

CAPÍTULO 1

Introdução

1.1 Apresentação do tema

Os problemas relacionados à gestão de receitas (*Revenue Management* - RM) podem ser definidos como estratégias que visam maximizar as receitas ajustando-se preços e a disponibilidade de capacidade com base na demanda ([Gallego and van Ryzin, 1994](#)). A área de RM foi inicialmente desenvolvida pela indústria aérea nas décadas de 70 e 80, quando as companhias aéreas começaram a adotar técnicas de otimização para definir os preços dos bilhetes com base na disponibilidade de assentos e na antecedência das reservas ([Glover et al., 1982](#)). O objetivo principal do RM consiste em otimizar a disponibilidade e o preço dos produtos para gerar a maior quantidade de receita possível. Entre suas principais características estão a segmentação de clientes, o controle de capacidade, o ajuste dinâmico de preços e o uso de previsões para estimar a demanda. O sucesso alcançado no setor aeronáutico foi tão expressivo que o RM foi expandido para outros setores com características semelhantes, como hotelaria, restaurantes, varejo, comércio eletrônico e transporte ([Heo and Lee, 2009](#)).

A otimização de receitas no transporte ferroviário de passageiros tornou-se uma área de pesquisa essencial para aumentar a sustentabilidade e a competitividade do setor. Esse tipo de

transporte enfrenta desafios específicos na gestão de sua capacidade devido à variabilidade da demanda, à rigidez tarifária e à necessidade crescente de adaptar suas estratégias às dinâmicas de mercado (Guerriero et al., 2021). Nesse contexto, o RM oferece uma estrutura robusta para abordar a alocação ideal de recursos, utilizando técnicas avançadas de modelagem matemática e análise de dados (Ammirato et al., 2020).

Esta dissertação aborda esse problema de forma unificada, formulando como decidir quantos assentos proteger (reservas) e quantos colocar à venda (autorização) ao longo de todo o horizonte de reservas – ou em cada período –, considerando duas visões da demanda (independente e comportamental) e duas políticas de disponibilidade (estática e dinâmica), além de incorporar práticas operacionais reais, como as restrições *fulfillment-over-periods* e *skip-lagging*. O objetivo geral é maximizar a receita esperada, determinando para cada itinerário, tipo de assento, classe tarifária e período, a combinação ótima de reservas e autorizações, fornecendo à empresa ferroviária critérios quantitativos que equilibram a geração de receita com a qualidade do serviço.

1.2 Justificativa

Esta pesquisa justifica-se pelo fato de que, diferentemente dos setores de aviação e hotelaria, o *revenue management* ferroviário ainda carece de modelos que integrem de maneira simultânea a lógica dos modelos de transporte de veículos e a modelagem de fluxo em redes, incorporando, de forma conjunta, aspectos como substituição tarifária, regras operacionais e decisões dinâmicas. Apesar de já existirem modelos semelhantes nas áreas mencionadas, o contexto ferroviário apresenta características particulares que o distinguem de forma relevante. Em primeiro lugar, o problema do transporte ferroviário envolve um número significativamente maior de transbordos em comparação ao problema aéreo. Em segundo lugar, a rede ferroviária tende a apresentar uma estrutura mais linear em seus transbordos do que a rede aérea. Além disso, enquanto aeronaves são geralmente alocadas a rotas específicas, os trens seguem itinerários fixos com múltiplas paradas intermediárias. Por fim, nos problemas aéreos a decisão central consiste em determinar a quantidade de assentos a serem disponibilizados em cada classe global, ao passo que, no contexto ferroviário, a complexidade reside em decidir quantos assentos autorizar e/ou proteger

em cada trecho da rede, o que demanda uma abordagem distinta e mais detalhada. A literatura revisada não apresenta um modelo que combine todas essas perspectivas de forma integrada, o que configura a lacuna de conhecimento que esta pesquisa busca preencher.

Com base nessa motivação, a pesquisa se propôs a desenvolver e comparar uma família de modelos de programação linear inteira mista que combinam duas visões da demanda — independente e comportamental — com duas políticas de disponibilidade de vendas — estáticas e dinâmicas. Cada combinação gera um modelo básico ao qual, de forma incremental, são adicionadas as restrições *fulfillment* e *skip-lagging*, até formar um modelo completo, resultando em um total de dezesseis formulações.

O enfoque é quantitativo-aplicado: os modelos foram implementados em Python, utilizando o pacote Gurobipy para a modelagem matemática e o solver Gurobi para a resolução dos modelos. Foram testadas dez instâncias reais fornecidas por um operador canadense, que representam situações práticas com diferentes tamanhos e complexidade de rede. Além disso, foram registrados os tempos de construção e solução dos modelos, número de nós explorados, percentual de demanda atendida e valores da função objetivo; adicionalmente, analisou-se a estrutura unimodular das matrizes de restrições para explicar o desempenho computacional.

Os resultados mostram que os modelos básicos oferecem as maiores receitas brutas, mas à custa de desconsiderar práticas corporativas; a incorporação das restrições *fulfillment* e *skip-lagging* reduz entre 20% e 85% da receita, respectivamente, enquanto a transição de autorizações estáticas para dinâmicas recupera mais de 10% dessa margem e melhora o aproveitamento da demanda. A maioria dos modelos apresenta como matriz de coeficientes uma matriz unimodular, o que permite obter soluções inteiras em menos de 0,15 segundos, mesmo em instâncias grandes; quando a matriz não é unimodular, seu caráter Δ -modular mantém baixos os tempos computacionais e a quantidade de nós explorados.

Em consequência, conclui-se que a combinação de demanda comportamental com autorizações dinâmicas oferece o melhor equilíbrio entre realismo operacional e rentabilidade, que as restrições *fulfillment* e *skip-lagging* são essenciais para evitar políticas tarifárias incoerentes e que a eficiência computacional das formulações as torna aplicáveis à tomada de decisões táticas em ambientes reais.

CAPÍTULO 2

Revisão da literatura

2.1 Fundamentos da gestão de receitas (RM)

Nesta seção, será apresentada a definição da gestão de receitas, suas principais características, um breve histórico da sua evolução e suas aplicações em diferentes setores da indústria.

2.1.1 Definição e importância

A gestão de receitas, conhecido como RM, do inglês *Revenue Management*, é uma abordagem estratégica voltada para otimizar a disponibilidade e os preços dos produtos, com o objetivo de maximizar o crescimento da receita procurando os produtos apropriados para os clientes certos, no momento adequado e por um preço conveniente (Cross, 1997). Essa prática envolve a previsão do comportamento do consumidor em nível de micromercado e a gestão científica da demanda por produtos e serviços (Talluri et al., 2008).

O RM evoluiu desde suas origens na indústria aérea até se tornar uma prática amplamente adotada em diversos setores, incluindo hotelaria, energia, manufatura e transporte (Cross, 1995; Cheraghi et al., 2010). A implementação do RM geralmente exige a análise de dados históricos e da atividade atual de pedidos, a fim de prever a demanda com precisão. Isso permite que as

empresas definam e atualizem estratégias de preço e disponibilidade de produtos nos diferentes canais de venda (Cheraghi et al., 2010).

O RM possibilita que cada unidade de capacidade disponível seja aproveitada ao máximo, segmentando clientes, controlando a disponibilidade de produtos e ajustando preços de forma dinâmica (Heo and Lee, 2009). Além de elevar a rentabilidade, essa estratégia melhora a previsibilidade da demanda, permitindo que as empresas reajam rapidamente às oscilações do mercado. Em um ambiente altamente competitivo, o gerenciamento de receitas torna-se um diferencial crucial para manter uma posição sólida e, ao mesmo tempo, oferecer soluções mais eficientes e personalizadas para os consumidores (Gallego and van Ryzin, 1994).

Quando aplicada com êxito, essa abordagem pode gerar impactos econômicos expressivos, com aumentos de receita superiores a 5%, conforme relatado em diversas indústrias (Cross, 1995). À medida que a área continua a se desenvolver, vem incorporando modelos avançados de previsão e otimização da demanda, baseados em estudos das áreas de ciência da gestão e economia (Cheraghi et al., 2010).

2.1.2 Histórico e evolução

Até o ano de 1978, a Junta de Aeronáutica Civil (CAB do inglês *Civil Aeronautics Board*) limitava a concorrência entre as companhias aéreas, onde basicamente as companhias só podiam competir oferecendo serviços como refeições luxuosas e alta frequência nos horários de saída dos voos. Nesse ponto, a CAB não permitia que fosse oferecida uma tarifa menor para um voo, se esta fosse antieconômica para a indústria como um todo. Assim, mesmo que para uma companhia aérea fosse rentável colocar um valor baixo para uma passagem em comparação com outra, a CAB não permitiria, a menos que houvesse uma justificativa extremamente sólida. Quando esse tipo de situação ocorria, o restante das companhias aéreas justificava que o público seria prejudicado, pois elas teriam que aumentar o valor das passagens em outras rotas para compensar o baixo custo da nova proposta do concorrente (Glover et al., 1982).

Com a chegada da desregulamentação, as companhias aéreas se depararam com um mundo cheio de novas formas de concorrência, onde o preço das passagens se tornou prioritário. E foi nesse momento que iniciou a verdadeira concorrência entre as companhias aéreas. Aqui surgiu

um novo problema em função da diversidade de preços com diferentes restrições que limitam a disponibilidade de assentos a tarifas mais baixas, a presença de múltiplos voos operados por diversas companhias aéreas em diferentes rotas, e a variabilidade na demanda por assentos em função de fatores como a temporada, o dia da semana, a hora do dia e a qualidade do serviço oferecido, o que influencia a escolha dos passageiros entre diferentes opções de voo (Glover et al., 1982).

Nesse momento, esse problema foi denominado como problema de preços e combinação de passageiros e foi modelado da seguinte forma: cada passageiro em um voo representa um custo de oportunidade, já que sua ocupação de um assento impede que outro passageiro com um itinerário mais rentável ou uma classe de tarifa mais alta o utilize. Isso se traduz na possibilidade de assentos vazios em diferentes segmentos de voo, o que afeta a eficiência da rede da companhia aérea ao considerar múltiplos passageiros com diversas origens, destinos e classes de tarifas (Glover et al., 1982).

Houve dois possíveis resultados: 1) a otimização da combinação de passageiros permite que as companhias aéreas estruturem de maneira mais eficaz seu sistema de reservas, estabelecendo limites e prioridades adequadas para o número de passageiros com diferentes classes de tarifas em distintos voos. 2) Além disso, possibilita a avaliação de diversos cenários de preço e rota, considerando o benefício gerado a partir da melhor combinação de passageiros em relação a um cenário específico.

Ao ajustar a estrutura das classes de tarifas, as companhias aéreas buscam gerenciar o deslocamento de passageiros por meio de estratégias de preços e a aplicação de restrições como horários, duração da estadia e tempo de antecedência à saída do voo. Além disso, buscam reduzir o deslocamento controlando a capacidade, determinando a quantidade de assentos atribuídos a cada classe de tarifa em cada segmento de voo.

Por outro lado, a otimização da combinação de passageiros é formulada como: "Dada a previsão diária da demanda de passageiros nas diferentes classes de tarifas, qual combinação de passageiros e classes de tarifas em cada segmento de voo maximizará as receitas do dia?". Essa resposta ajuda a companhia aérea a determinar a alocação ideal de reservas entre as diversas classes de tarifas em cada segmento de voo (Glover et al., 1982).

Essas últimas duas definições foram conhecidas como *Yield Management* e, posteriormente, com a chegada de novos sistemas de informação, regras de controle e outras condições, foram generalizadas e aplicadas em outras indústrias de características semelhantes, que no futuro seriam chamadas de RM ([Littlewood, 2005](#)).

Subsequentemente, entre os anos de 2013 e 2017, o campo do RM passou por uma evolução significativa, impulsionada pelos avanços nas tecnologias analíticas, pelo acesso a dados em tempo real e pela crescente complexidade dos mercados. Esse processo de transformação foi marcado por uma mudança de perspectiva: as decisões antes centradas exclusivamente na empresa passaram a considerar com mais profundidade o comportamento do consumidor em ambientes competitivos. De acordo com [Mulyani \(2021\)](#), o interesse por RM cresceu de forma exponencial, refletindo sua relevância tanto na pesquisa acadêmica quanto na prática empresarial.

Nos primeiros anos do período, a atenção da literatura acadêmica ainda se concentrava nos dois pilares clássicos do RM: as decisões de precificação (*pricing*) e as de quantidade ou capacidade (*quantity-based decisions*), conforme discutido por [Talluri and Van Ryzin \(2004\)](#). No entanto, uma análise de palavras-chave conduzida por [Mulyani \(2021\)](#) mostra que, enquanto o termo *resource allocation* perdia importância ao longo do tempo, o conceito de *pricing* ganhava destaque, consolidando-se como o principal foco até o final do período analisado.

A partir de 2014, começaram a ganhar espaço linhas de pesquisa voltadas à análise do comportamento do consumidor. Temas como escolha do consumidor, percepção de preço, sensação de justiça (*fairness*) e dispersão de preços passaram a ser frequentemente abordados nos estudos, em resposta à necessidade de compreender melhor o processo de decisão de compra em mercados altamente competitivos. Essa mudança de foco para uma abordagem mais orientada ao cliente está em sintonia com as observações de [Noone et al. \(2011\)](#), que identificaram uma transição do RM de um enfoque centrado na empresa para uma perspectiva mais sensível ao ambiente competitivo e às preferências dos usuários.

Do ponto de vista metodológico, o período foi marcado pela crescente adoção de técnicas quantitativas mais sofisticadas. Métodos tradicionais, como programação dinâmica e estocástica, modelos de otimização e heurísticas, continuaram sendo amplamente utilizados. Entre-

tanto, a partir de 2015 — com maior intensidade entre 2016 e 2017 — abordagens como teoria dos jogos, modelos logit e análise conjunta (*conjoint analysis*) ganharam destaque. Essas técnicas refletem a necessidade de capturar as respostas estratégicas de consumidores e concorrentes dentro dos modelos de decisão (Mulyani, 2021; Shen and Su, 2007; Strauss et al., 2018).

Por fim, uma das transformações mais relevantes desse período foi a incorporação de tecnologias emergentes, como *big data* e *machine learning*, que começaram a ser aplicadas com mais frequência nos estudos sobre RM nos últimos anos da década. Esse movimento foi favorecido pelo avanço dos sistemas de captura e processamento de dados em tempo real, o que permitiu maior sofisticação na abordagem de problemas dinâmicos e complexos. Essa tendência, destacada por Gönsch et al. (2013), evidencia a necessidade de métodos empíricos mais robustos e adaptáveis, que complementem os modelos teóricos tradicionais.

2.2 Transporte Ferroviário de Passageiros

O problema do transporte ferroviário de passageiros tem sido amplamente explorado na literatura científica, dada sua complexidade operacional e seu papel estratégico na promoção da mobilidade sustentável. De modo geral, esse problema busca maximizar os benefícios econômicos e sociais decorrentes do uso eficiente da infraestrutura ferroviária, levando em consideração, ao mesmo tempo, as restrições de capacidade, a qualidade do serviço prestado e as expectativas dos usuários (Huisman et al., 2005; Shan et al., 2024). O sistema ferroviário possui características específicas que o diferenciam de outros modos de transporte: a oferta é altamente perecível — um assento não vendido em determinado trem representa uma perda definitiva —, a capacidade é limitada pelo número de composições, pela disposição dos assentos e pela configuração da rede, e a demanda apresenta flutuações e segmentações marcantes, variando conforme o horário, o dia da semana, a distância percorrida e o perfil dos usuários (Guan et al., 2023; Besinovi et al., 2022).

Além disso, as decisões operacionais no setor são altamente interdependentes: o planejamento de linhas, a alocação de assentos, a definição de políticas tarifárias e a programação dos trens se influenciam mutuamente, exigindo, portanto, uma abordagem integrada para que os resultados sejam consistentes e sustentáveis (Huisman et al., 2005; Shan et al., 2024). Outro

aspecto relevante é a conectividade entre os serviços, que requer estratégias eficientes de gestão de transferências e de atrasos, com o objetivo de minimizar os impactos ao passageiro diante de eventuais interrupções ou imprevistos operacionais (König, 2020).

2.2.1 Áreas de pesquisa

A literatura especializada apresenta diversos enfoques para tratar esse problema sob diferentes perspectivas. Um dos mais relevantes é o RM, que adapta técnicas originalmente desenvolvidas para a aviação comercial, com o intuito de maximizar a receita por meio da gestão dinâmica de preços e da alocação de assentos, considerando a segmentação do mercado e a sensibilidade dos passageiros em relação ao preço (Ammirato et al., 2020; Guan et al., 2023). Essa abordagem evoluiu significativamente, partindo de modelos estáticos para formulações dinâmicas mais sofisticadas, integrando previsão de demanda, otimização tarifária e controle de inventário, mesmo em contextos com alta incerteza (Hetrakul and Cirillo, 2014; Shan et al., 2024).

Outro campo amplamente discutido é o da gestão de atrasos (*delay management*), que tem como foco a tomada de decisões operacionais orientadas a reduzir os impactos de perturbações na rede, sobretudo na coordenação entre trens com conexões interdependentes (König, 2020). A planificação de linhas e a alocação de recursos operacionais também é tema recorrente, envolvendo decisões relacionadas às rotas, paradas, frequências, capacidades e uso do material rodante, geralmente com base em modelos de programação matemática (Huisman et al., 2005; Shan et al., 2024).

Por outro lado, pode-se encontrar o planejamento das paradas dos trens e a estratégia de preços as quais estão interligados e impactam tanto as receitas quanto a experiência dos passageiros. Zhou and Others (2022) propuseram um modelo de otimização não linear inteiro misto que aborda conjuntamente a estratégia de preços dos bilhetes e o planejamento das paradas. Esse modelo busca maximizar as receitas do transporte ferroviário e minimizar o tempo de viagem dos passageiros, alcançando um equilíbrio eficiente entre oferta e demanda.

A estimação da demanda tem sido tratada, em grande parte, por meio de técnicas baseadas em modelos de escolha discreta, como os modelos *logit* e os modelos de classes latentes, per-

mitindo capturar a heterogeneidade nas preferências dos usuários quanto a horários, preços e atributos do serviço ofertado (Hetrakul and Cirillo, 2014; Tang et al., 2022). Mais recentemente, observa-se uma aplicação crescente de inteligência artificial e aprendizado de máquina em diferentes estágios do sistema ferroviário — desde a previsão de demanda e falhas operacionais até a otimização em tempo real, aproveitando-se da ampla disponibilidade de dados gerados por sistemas de bilhetagem, sensores embarcados e plataformas digitais (Besinovi et al., 2022; Tang et al., 2022).

2.2.2 Controle de inventário

É importante destacar que esta pesquisa está voltada à aplicação do RM no contexto do transporte ferroviário de passageiros. Dentro desse escopo, a literatura especializada identifica dois grandes eixos de desenvolvimento. O primeiro diz respeito ao controle de inventário, reconhecido como o alicerce operacional do RM ferroviário. Essa área tem como principal objetivo determinar, ao longo do horizonte de reservas, quantos assentos devem ser protegidos para cada tarifa ou classe de controle, considerando mercados origem-destino distintos. O objetivo é maximizar a receita esperada ao final do ciclo de vendas. Para isso, as políticas de aceitação e rejeição de solicitações devem lidar com um dilema fundamental: rejeitar hoje uma reserva de menor valor que talvez não seja substituída, ou aceitá-la e comprometer a disponibilidade futura para passageiros dispostos a pagar tarifas mais altas.

Diversos trabalhos ao longo das últimas décadas têm aprofundado esse campo sob diferentes enfoques metodológicos. Feng and Xiao (2001), por exemplo, adaptaram pela primeira vez ao transporte ferroviário de longa distância o modelo dinâmico de controle de inventário originalmente desenvolvido para companhias aéreas. Utilizando processos de decisão de Markov com chegadas Poisson independentes por classe tarifária, os autores propuseram uma política ótima baseada no tempo restante até a partida e no número de assentos disponíveis, resultando em uma regra de limiar estacionária de fácil implementação, com ganhos simulados de aproximadamente 6% frente à política tradicional de ordem de chegada. No entanto, a independência entre classes tarifárias pressuposta pelo modelo ignora substituições entre tarifas, o que limita sua aplicabilidade prática.

Em uma linha complementar, [Bertsimas and de Boer \(2002\)](#) abordaram o problema em redes com rotas sobrepostas, propondo um modelo não linear convexo com decomposição hierárquica. Seus resultados indicam que proteger assentos em nível de itinerário completo pode gerar ganhos entre 3% e 6% em relação a políticas locais por trecho, embora o modelo trate a demanda como fixa e desconsidere interações com os preços. Posteriormente, [Walczak and Brumelle \(2007\)](#) introduziram um modelo semi-Markov que incorpora o tempo de permanência em cada estado como variável influente sobre a demanda. Através de simulações de Monte Carlo, demonstraram que em cenários com aceleração da demanda próxima à data de partida, é possível obter melhorias de receita entre 5% e 8%, ainda que o modelo se limite a apenas dois níveis tarifários e não tenha validação empírica.

Em 2009, [Chew et al. \(2009\)](#) integraram, pela primeira vez, decisões conjuntas de tarifa e proteção de inventário para produtos perecíveis, com um modelo biestágio resolvido por programação dinâmica. Comparando abordagens simultâneas e sequenciais, evidenciaram ganhos médios de receita de até 18% em um cenário de trem de alta velocidade na Ásia, embora o estudo tenha sido restrito a um único par origem-destino e não considere efeitos de rede. Na mesma direção, [Cizaire \(2011\)](#) estendeu o horizonte de análise para múltiplos períodos com demanda estocástica, aplicando um modelo linear inteiro misto com heurísticas de horizonte rolante. Os ganhos reportados variaram entre 10% e 12% em comparação com políticas fixas, mas a alta sensibilidade aos erros de previsão e os custos computacionais dificultam sua aplicação em tempo real.

No campo da escalabilidade, [Méndez-Díaz et al. \(2014\)](#) propuseram uma formulação inteira mista com algoritmo *branch-and-cut* e geração dinâmica de colunas, conseguindo gaps ótimos inferiores a 2% em instâncias reais, dentro de tempos computacionais aceitáveis. Ainda assim, a demanda continua sendo tratada como exógena, e o impacto das tarifas dinâmicas sobre as escolhas dos passageiros não é modelado. Em uma abordagem mais integrada, [Hetrakul and Cirillo \(2014\)](#) combinaram um modelo de classes latentes com uma função log-linear de demanda, permitindo otimização simultânea de preços e proteção de inventário. Os autores demonstraram que incorporar a heterogeneidade de preferências dos passageiros pode gerar ganhos de 14% a 25%, reforçando a relevância de considerar o comportamento individual na modelagem da

demanda. No entanto, o estudo foi limitado a um único corredor e não explorou a robustez da solução frente a perturbações operacionais.

Mais recentemente, [Besinovi et al. \(2022\)](#) revisaram o papel da inteligência artificial nesse domínio, propondo uma taxonomia de aplicações de aprendizado de máquina ao controle de inventário. Identificaram que algoritmos de aprendizado por reforço oferecem promissoras políticas adaptativas que dispensam pressupostos rígidos sobre a distribuição da demanda. Contudo, destacam que barreiras regulatórias e desafios de interpretabilidade ainda limitam sua adoção em contextos industriais reais.

2.2.3 Modelagem da demanda

Além do controle de inventário, outro eixo essencial da literatura é a modelagem da demanda, com destaque para a distinção entre abordagens que assumem demanda independente e aquelas que adotam uma perspectiva comportamental. Nos primeiros modelos, como os propostos por [Dana \(1999\)](#); [Feng and Xiao \(2001\)](#), cada classe tarifária é representada como um fluxo estocástico separado, cuja chegada não é afetada pela disponibilidade de outras tarifas. Essa simplificação facilita a modelagem dinâmica e a aplicação de processos markovianos, mas ignora os efeitos de substituição tarifária observados na prática.

Esse panorama começa a mudar a partir de 2007, com os estudos de [Walczak and Brumelle \(2007\)](#), que introduzem uma estrutura semi-Markov em que a probabilidade de chegada de cada segmento passa a depender do estado atual das reservas, capturando assim os primeiros efeitos de desvio entre tarifas. Contudo, o avanço mais significativo ocorre em 2014, quando [Hettrakul and Cirillo \(2014\)](#) propõem um modelo de escolha baseado em classes latentes que permite prever com maior precisão quando e qual tarifa será adquirida por cada passageiro, levando em conta preço, tempo de antecipação e atributos do serviço. Ao integrar esse modelo à otimização de inventário, os autores demonstram que considerar a heterogeneidade de preferências pode elevar a receita em até 25% em comparação com estratégias baseadas em demandas independentes.

Nos últimos anos, a gestão de reservas de bilhetes no transporte ferroviário de passageiros evoluiu significativamente graças à aplicação de modelos matemáticos avançados. Esses

modelos têm como objetivo otimizar a alocação de assentos, o planejamento de paradas e as estratégias de preços, buscando maximizar as receitas e melhorar a satisfação dos passageiros.

Um dos modelos destacados é o desenvolvido por [Zhou and Others \(2023\)](#), que integra a teoria das perspectivas, o modelo logit e um modelo de transferência de fluxo de passageiros para alocar a demanda de maneira eficaz. Esse enfoque permite estabelecer preços diferenciados e distribuir os assentos de forma a maximizar as receitas, considerando as preferências e comportamentos de diferentes segmentos de passageiros.

Além disso, a demanda de passageiros está sujeita a incertezas que tornam a gestão operacional mais desafiadora. [Han and Ren \(2020\)](#) desenvolveram um modelo que otimiza conjuntamente o planejamento de paradas e a alocação de bilhetes, utilizando a teoria da incerteza. Esse modelo busca maximizar a satisfação dos passageiros e a taxa média de ocupação dos assentos, oferecendo soluções robustas frente às flutuações na demanda.

Posteriormente, [Schöbel and Urban \(2021\)](#) investigaram como a escolha da rota dos passageiros é influenciada pelas estruturas tarifárias e pelos preços dos bilhetes. Sua pesquisa abordou o problema de determinar a tarifa mais econômica em sistemas de transporte público, avaliando diferentes estruturas tarifárias, como aquelas baseadas em distância ou zonas, e propondo algoritmos altamente eficientes para resolver esses problemas.

A evolução da literatura mostra de forma clara que os modelos de demanda comportamental tornaram-se indispensáveis para estimar de forma realista a substituição entre horários e níveis tarifários, desenvolver estratégias de preços personalizados por meio de canais digitais e avaliar como segmentos mais sensíveis ao preço reagem a metas de sustentabilidade ou justiça tarifária. Apesar desses avanços, revisões recentes como as de [Ammirato et al. \(2020\)](#) e [Besinovi et al. \(2022\)](#) indicam que grande parte dos estudos sobre RM ferroviário ainda operam sob suposições de demanda independente, o que evidencia a necessidade urgente de aprofundar abordagens comportamentais apoiadas por aprendizado de máquina e dados massivos de transações.

2.3 Aplicação de RM ao transporte ferroviário de passageiros

O RM aplicado ao transporte ferroviário de passageiros evoluiu de maneira desigual ao longo dos últimos vinte e cinco anos, passando de modelos conceituais inspirados na aviação para propostas integradas que combinam previsão de demanda, precificação dinâmica e alocação de capacidade com o uso de técnicas de inteligência artificial.

O marco inicial pode ser atribuído ao estudo de [Dana \(1999\)](#), que, embora não tenha foco específico no setor ferroviário, introduz o conceito de dispersão tarifária em mercados com capacidade limitada. Sua abordagem analítica demonstra que, mesmo diante de custos fixos, a diferenciação de preços gera equilíbrios de mercado mais lucrativos que políticas de preços uniformes. Essa conclusão antecipa a lógica de proteção de assentos por classe tarifária, mais tarde adotada amplamente no setor ferroviário. Na mesma época, não se encontram estudos ferroviários diretamente comparáveis, o que evidencia um período de transição e adoção inicial de conceitos oriundos da aviação comercial.

Com o avanço da década, [Feng and Xiao \(2001\)](#) propõem um modelo dinâmico de controle de inventário voltado à gestão de assentos perecíveis, cujo algoritmo determina políticas ótimas de aceitação e rejeição de reservas. Apesar do caso base estar focado na aviação, a estrutura matemática do modelo — um processo de decisão de Markov — revela-se diretamente aplicável ao transporte ferroviário de longa distância, estabelecendo as bases para os estudos posteriores em redes ferroviárias. Em relação ao trabalho de [Dana \(1999\)](#), Feng e Xiao ampliam o horizonte de análise ao introduzir decisões periódicas no tempo e substituem a estática de preços por regras de controle que incorporam a estocasticidade nas chegadas de demanda, característica alinhada à realidade operacional dos trens.

Nos anos seguintes, a literatura ainda era fortemente marcada por abordagens conceituais e revisões setoriais. Contudo, o trabalho de [Vinod \(2004\)](#), traz uma importante contribuição ao introduzir a noção de integração entre o RM e os sistemas de distribuição, enfatizando a necessidade de alinhar previsões de demanda com canais de venda multicanais — uma questão que se tornaria central para o sucesso do RM no setor ferroviário de alta velocidade europeu.

Em paralelo, [Netessine and Shumsky \(2005\)](#) modelam a competição tarifária entre operadores utilizando jogos de inventário. Seus resultados indicam que a coordenação horizontal entre empresas pode aumentar os lucros totais do sistema. Embora o estudo se aplique ao setor aéreo, as conclusões são diretamente comparáveis a observações do mercado ferroviário interurbano liberalizado, no qual acordos de compartilhamento de código e redes integradas atuam para mitigar guerras de preços, como já destacado por [Ammirato et al. \(2020\)](#).

Nos anos seguintes, dois estudos ganham destaque. [Walczak and Brumelle \(2007\)](#) propõem um modelo de precificação dinâmica com base em informação semi-Markov, otimizando a receita ao considerar a probabilidade de chegada de diferentes classes de demanda heterogêneas. Simultaneamente, [Fröidh \(2008\)](#) analisa a viabilidade comercial do trem de alta velocidade na Suécia, alertando que seu êxito econômico dependerá da implementação de estratégias de RM que combinem preços variáveis com ajustes finos nas frequências de operação. Enquanto o modelo de Walczak apresenta rigor matemático, carece de aplicação empírica no contexto ferroviário; por outro lado, Fröidh oferece evidência de campo, mas sem formalização teórica, evidenciando uma lacuna metodológica característica daquele momento.

No biênio seguinte, [Chew et al. \(2009\)](#) formulam um problema conjunto de precificação e alocação de inventário para produtos perecíveis com dois períodos de vida útil, resolvido via programação dinâmica. Demonstram que alinhar tarifas e capacidade oferece vantagens significativas sobre políticas sequenciais. Esses achados dialogam diretamente com [Gao et al. \(2010\)](#), que aplicam um algoritmo de alocação de assentos no contexto ferroviário chinês, considerando elasticidades cruzadas. Enquanto Chew comprova os ganhos em termos de receita (até 20% em simulações), Gao valida a eficácia do modelo no mundo real, com melhorias de ocupação e equilíbrio entre trajetos curtos e longos. A comparação entre ambos os trabalhos evidencia a transição de marcos teóricos para aplicações operacionais concretas.

Prosseguindo, [Guo et al. \(2012\)](#), abordam a questão da amostragem truncada da demanda — problema recorrente no setor ferroviário, onde os dados de rejeições de reserva nem sempre são observáveis. A solução proposta, baseada em algoritmos de Expectation-Maximization, aprimora as estimativas para alimentar os modelos de controle, complementando o trabalho anterior de [Walczak and Brumelle \(2007\)](#) ao fornecer dados mais consistentes.

Em 2014, uma mudança de paradigma é estabelecida com a contribuição de [Hettrakul and Cirillo \(2014\)](#). Esses autores introduzem um sistema baseado em modelos de classes latentes que integra a escolha do momento da compra com regressões log-lineares de demanda e otimização conjunta de tarifas e alocação de capacidade em uma rede real. A calibração com dados históricos demonstra aumentos de receita entre 14% e 25% em comparação com políticas fixas, confirmando a importância de adaptar os preços à antecipação da compra. Comparado ao estudo de [Dobson and Piga \(2013\)](#), que se concentra na dinâmica de fusões no setor aéreo, a pesquisa de [Hettrakul and Cirillo \(2014\)](#) destaca a microsegmentação da demanda como fator crítico, ilustrando a transição do foco em estruturas de mercado para o modelamento comportamental individualizado.

Nos anos seguintes, observa-se uma crescente convergência entre otimização de redes e políticas tarifárias. [Zheng and Geroliminis \(2016\)](#) aplicam o RM ao desenho de redes multimodais com estacionamento limitado e tarifas dinâmicas, demonstrando que a coordenação entre trem e automóvel pode reduzir tempos de viagem e aumentar receitas. Em paralelo, [Casey \(2014\)](#), embora publicado no final do período anterior, propõe um protótipo industrial que conecta *scheduling* com RM em ferrovias interurbanas dos Estados Unidos, reforçando a tendência de integração entre planejamento e estratégia tarifária.

subsequentemente, [Tang et al. \(2022\)](#) revisam o uso da inteligência artificial em diversas subáreas do setor ferroviário, constatando que a aplicação da IA à precificação dinâmica ainda é incipiente. Ao mesmo tempo, [Ammirato et al. \(2020\)](#) reportam a carência de estudos que integrem RM com planejamento estratégico. Ambos concordam na necessidade de migrar de modelos isolados para sistemas holísticos de apoio à decisão, baseados em big data.

Já nos anos mais recentes, [Besinovi et al. \(2022\)](#) propõem uma taxonomia detalhada sobre IA no setor ferroviário, identificando o RM como uma das áreas com maior potencial para aplicação de técnicas de machine learning, especialmente na definição de preços em tempo real e otimização de inventário. Essa análise complementa a síntese de [Tang et al. \(2022\)](#), que quantifica a concentração da literatura em manutenção e evidencia a defasagem na vertente comercial. A convergência dos estudos reforça a popularização do uso de redes neurais profundas na previsão de demanda e a ausência de sua articulação com algoritmos de precificação.

Mais recentemente, [Guan et al. \(2023\)](#) oferecem a primeira revisão dedicada exclusivamente à precificação ferroviária sob a ótica do RM, classificando os métodos em três grupos: sistemas de tarifa base, programação matemática e abordagens orientadas por dados. Os autores observam que os modelos dinâmicos ainda dependem fortemente de suposições de elasticidade linear e que a aplicação de aprendizado de máquina na estimativa de parâmetros ainda está em estágio inicial.

Em paralelo, [Shan et al. \(2024\)](#) articulam uma estrutura generalizada de RM, já implementada na operação ferroviária chinesa, que integra previsão, planejamento de oferta, controle de inventário e precificação. Seus resultados reportam ganhos de utilização e rentabilidade decorrentes da segmentação baseada em big data, embora ressaltem o desafio de equilibrar lucro e inclusão social. Assim, enquanto Guan fornece uma síntese teórica robusta, Shan comprova a viabilidade prática do RM em larga escala, evidenciando a transição concreta do plano acadêmico para aplicações industriais.

2.4 Outras aplicações industriais de RM

As práticas de RM são mais comuns em setores que apresentam estoques perecíveis, capacidade fixa, altos custos fixos e uma sensibilidade variável ao preço por parte do cliente. Diversas indústrias adotaram essas técnicas para otimizar suas operações e maximizar a lucratividade. A seguir, são exploradas duas das mais reconhecidas nesta área.

2.4.1 Aviação

No setor aéreo, as companhias enfrentam o desafio de administrar um número limitado de assentos por voo, os quais são ofertados com preços variados conforme o perfil do cliente, a antecedência da compra ou a classe da passagem. O foco principal da gestão de receitas na aviação não é simplesmente vender todos os assentos, mas sim maximizar a receita total do voo, priorizando o ganho por assento disponível (conhecido como *Revenue per Available Seat Kilometer* - RASK).

Para isso, são tomadas decisões estratégicas como: quantos assentos disponibilizar em cada

faixa tarifária; quando abrir ou fechar o acesso a determinadas tarifas — por exemplo, bloqueando tarifas promocionais quando há alta demanda —; e quais ações promocionais implementar para estimular a procura em períodos de baixa ocupação.

Entre os pilares desse modelo estão: *A segmentação tarifária*, na qual os mesmos assentos são vendidos por preços diferentes (como tarifas promocionais versus flexíveis); *A previsão de demanda*, que estima o volume de bilhetes que será vendido em cada categoria; *O controle de inventário*, que busca reservar lugares para clientes com maior disposição de pagamento, geralmente mais próximos da data do voo; E por fim, *A gestão de overbooking*, que autoriza vender mais bilhetes do que assentos disponíveis, considerando possíveis cancelamentos ou faltas.

A *American Airlines* foi pioneira na aplicação do RM na indústria aérea com o desenvolvimento do sistema DINAMO (*Dynamic Inventory and Maintenance Optimizer*), considerado o primeiro sistema operacional de RM. Esse sistema possibilitou o aumento da rentabilidade ao controlar a disponibilidade de assentos por classes tarifárias, antecipando o comportamento da demanda e segmentando os passageiros com base em sua disposição a pagar (Smith et al., 1992).

Nas suas fases iniciais, o RM baseava-se em modelos estáticos para a alocação ótima de capacidade entre diferentes classes tarifárias. Um dos primeiros modelos formais foi a Regra de Littlewood (Littlewood, 2005), que sugeria aceitar uma reserva de uma classe com tarifa mais baixa apenas se a receita esperada por manter o assento disponível para uma classe superior fosse inferior à tarifa oferecida. Essa regra foi posteriormente estendida por Belobaba (1987), que introduziu o modelo EMSR (*Expected Marginal Seat Revenue*), generalizando o princípio de Littlewood para múltiplas classes tarifárias. O EMSR tornou-se um padrão nos sistemas comerciais de RM e, até hoje, continua sendo utilizado em versões adaptadas.

Com o aumento da complexidade das redes de voos, surgiu a necessidade de otimizar não apenas cada voo individualmente, mas também a rede como um todo. Essa demanda levou ao desenvolvimento do conceito de *Network Revenue Management* (NRM), que considera as interdependências entre voos conectados. Pesquisadores como Gallego and van Ryzin (1997) propuseram modelos de controle estocástico baseados em programação dinâmica para maxi-

mizar a receita esperada em redes sob incerteza de demanda. [Williamson \(1992\)](#) desenvolveu metodologias de controle de inventário em redes aéreas com múltiplas classes tarifárias.

Um componente crítico do RM no setor aéreo tem sido o gerenciamento de *overbooking*, ou seja, a prática de aceitar mais reservas do que a capacidade física disponível, com o objetivo de compensar cancelamentos e a ausência de passageiros. [Brumelle and McGill \(1993\)](#) propuseram modelos probabilísticos que determinam níveis ótimos de sobrevenda, equilibrando a receita esperada com o risco de incorrer em custos com compensações. Esses modelos têm sido essenciais para aprimorar a eficiência de ocupação sem comprometer a experiência do passageiro.

Durante a segunda metade da década de 1990, a abordagem do RM evoluiu para modelos mais dinâmicos e adaptativos. [Talluri and van Ryzin \(1998\)](#) introduziram os controles por preços sombra (bid-price controls), uma técnica de implementação eficiente para redes, que estabelece limites mínimos de aceitação com base no valor marginal esperado de um assento. Paralelamente, [Gallego and van Ryzin \(1994\)](#) desenvolveram modelos de precificação dinâmica ótima sob demanda estocástica e horizonte finito, integrando a definição de preços ao modelo de alocação de capacidade — um marco importante na transição para uma gestão conjunta de tarifas e recursos.

No final da década de 1990 e início dos anos 2000, a literatura passou a incorporar também o componente comportamental do consumidor. [McGill and van Ryzin \(1999\)](#) realizaram uma revisão crítica da pesquisa em RM, destacando a necessidade de compreender melhor a percepção dos consumidores diante de políticas tarifárias complexas. Nesse período, começou-se a considerar o comportamento estratégico do passageiro, no qual os consumidores ajustam suas decisões de compra antecipando possíveis alterações nos preços ou na disponibilidade futura. Esse fenômeno introduziu um novo nível de complexidade ao campo, exigindo modelos capazes de prever não apenas a demanda, mas também as reações racionais dos passageiros.

No final dos anos 2000, a pesquisa em RM passou a se diversificar para cenários com incerteza, substituição de produtos e decisões estruturais. [Birbil et al. \(2009\)](#) propuseram modelos robustos de alocação de assentos sob incerteza, enquanto [Zhang and Cooper \(2009\)](#) introduziram processos de decisão de Markov para preços em voos substituíveis, representando uma

transição para estratégias de precificação sensíveis ao contexto competitivo. Ambos os estudos expandiram o arcabouço tradicional, incorporando a análise de concorrência direta e decisões de natureza estrutural.

Nos anos seguintes, [Huang and Liang \(2011\)](#) avançaram no desenvolvimento de algoritmos de programação dinâmica para problemas de rede, utilizando aproximações de receitas esperadas. Paralelamente, [Rusdiansyah et al. \(2013\)](#) aplicaram modelos de precificação dinâmica que consideram a variação de inventário e o comportamento dos concorrentes. Já [Aslani et al. \(2014\)](#) exploraram a percepção de justiça tarifária com o uso de heurísticas e simulações, destacando o conflito entre equidade percebida e maximização de receita.

Entre 2015 e 2018, surgiram modelos que integravam controle de capacidade, sobrevenda e cancelamentos. [Otero and Akhavan-Tabatabaei \(2015\)](#) apresentaram um modelo estocástico de precificação dinâmica em contextos multiclasse, ampliando a literatura ao incorporar estruturas mais realistas de demanda. [Wang et al. \(2018\)](#), por sua vez, demonstraram que a alocação dinâmica de capacidade em canais de venda diferenciados aumenta a receita e reduz custos com intermediários, reforçando a importância de decisões simultâneas em ambientes multicanal.

Mais recentemente, observou-se o uso crescente de técnicas de otimização combinatória e modelos de programação estocástica inteira. [Li et al. \(2022\)](#) desenvolveram um modelo combinado para alocação de assentos e upgrade de classe sob incerteza. [Fukushi et al. \(2022\)](#) integraram simulação com modelos de escolha discreta, capturando o comportamento heterogêneo dos passageiros e permitindo decisões personalizadas de precificação e capacidade. Esses avanços consolidam um arcabouço integrado que une demanda, precificação e disponibilidade em ambientes simulativos.

Paralelamente, o uso de aprendizado profundo tem revolucionado a previsão de demanda. [He et al. \(2023\)](#) aplicaram redes do tipo *Long Short-Term Memory* (LSTM) para prever a demanda aérea, obtendo uma melhora significativa na acurácia das previsões em relação aos métodos tradicionais - com uma redução de 45,1% no erro absoluto médio. Esse tipo de abordagem facilita a tomada de decisão adaptativa em tempo real, fator essencial em mercados altamente voláteis.

Além disso, a aplicação de *machine learning* permitiu aprimorar estratégias de precificação

personalizada. [Thirumuruganathan et al. \(2023\)](#) desenvolveram o modelo *Price Elasticity Model* (PREM), capaz de identificar segmentos com maior propensão a aceitar *upgrades* de classe. Utilizando uma base com mais de 64 milhões de registros, o modelo previu um aumento de 37,2% na receita proveniente de ofertas aceitas e uma redução de 7,94% no envio de ofertas irrelevantes, evidenciando o valor da segmentação baseada no comportamento do consumidor.

2.4.2 Hotelaria

Na indústria hoteleira, o RM é aplicado para maximizar a receita por quarto disponível (RevPAR), considerando a variação de preços e a ocupação dos quartos. Os hotéis utilizam técnicas de previsão de demanda para ajustar suas tarifas em tempo real, levando em conta fatores como sazonalidade, eventos locais e comportamento do consumidor. A segmentação de clientes também desempenha um papel crucial, permitindo que os hotéis ofereçam pacotes personalizados e promoções direcionadas.

Entre 2006 e 2008, os estudos sobre RM no setor hoteleiro passaram a sistematizar os fundamentos do RM aplicados ao contexto da hospitalidade. [Avinal \(2006\)](#) apresentou uma análise dos sistemas de gestão de receitas (RMS) sob uma perspectiva estratégica e operacional, destacando seu principal objetivo: maximizar a receita por meio de técnicas de precificação dinâmica e controle da duração da estadia. Ressaltou-se a importância da integração entre os RMS e os sistemas de gestão de propriedades (PMS), bem como da aplicação de regras operacionais — como datas específicas de chegada e estadias mínimas — para segmentar a demanda, especialmente entre os públicos corporativo e de lazer. Esse período também se caracteriza pela identificação de fatores críticos de sucesso, como o comprometimento da liderança, a avaliação contínua do desempenho dos sistemas e a capacitação da equipe para alimentar os algoritmos com dados confiáveis e de alta qualidade.

No intervalo de 2009 a 2012, consolida-se uma abordagem mais estrutural e sistêmica do RM na hotelaria. [Ivanov and Zhechev \(2011\)](#) propuseram uma revisão crítica do RM hoteleiro, organizando-o como um sistema composto por centros geradores de receita (quartos, alimentos e bebidas, eventos, spa), ferramentas de precificação (como discriminação de preços e garantias de tarifa mínima), processos operacionais (controle de *overbooking* e gestão de disponibilidade)

e fases sequenciais que abrangem a coleta de dados, análise, previsão, tomada de decisão, implementação e monitoramento. Além disso, os autores introduzem uma discussão inovadora sobre os aspectos éticos do RM, relacionados à percepção de justiça por parte dos clientes, e reforçam a necessidade de integração entre o RM e os sistemas de gestão de relacionamento com o cliente (CRM), estabelecendo as bases para abordagens mais centradas no consumidor em etapas posteriores.

Durante o triênio de 2013 a 2015, a atenção da literatura se volta à implementação de modelos estatísticos avançados. Observa-se a adoção sistemática de métodos como o modelo ARIMA com sazonalidade (SARIMA), modelos de suavização exponencial com dupla sazonalidade (*Holt-Winters*) e regressões com variáveis econômicas exógenas. Embora fora do intervalo em questão, o estudo de [Pereira \(2016\)](#) é representativo dessa linha de pesquisa, ao aprofundar o uso de séries temporais de alta frequência (diárias), com múltiplos e complexos padrões de demanda. Esses métodos passam a servir de base para avaliar o desempenho de abordagens mais recentes baseadas em inteligência artificial, estabelecendo métricas comparativas para medir o valor agregado por modelos emergentes.

Entre 2016 e 2018, tem início a incorporação sistemática de modelos de aprendizado de máquina (*machine learning*, ML) na previsão de demanda hoteleira. [Henriques and Pereira \(2024\)](#) explicam que, nesse período, os estudos passaram a combinar técnicas estatísticas tradicionais com algoritmos de ML, ampliando a capacidade preditiva ao integrar grandes volumes de dados estruturados e não estruturados. Destacam-se modelos como as redes neurais artificiais (ANN), máquinas de vetores de suporte (SVM) e regressões regularizadas (como *Ridge* e *Lasso*), aplicados tanto a séries históricas quanto a reservas futuras, com destaque para o uso do modelo pickup. Esta fase também revela uma preocupação crescente com a qualidade dos dados, a seleção de variáveis relevantes e a robustez dos modelos diante de padrões não lineares e oscilações no comportamento do consumidor.

A partir de 2019 e até 2021, observa-se uma expansão significativa das técnicas de *deep learning* (DL) na previsão de demanda na hotelaria. [Dowlut and Gobin-Rahimbux \(2023\)](#) documentam essa evolução por meio de uma revisão sistemática que contempla 50 artigos publicados entre 2017 e 2022. O estudo identifica as redes neurais LSTM (*Long Short-Term Memory*)

como a arquitetura mais adotada, devido à sua capacidade de capturar dependências temporais de longo alcance e lidar com séries com alta sazonalidade. Além disso, surgem modelos híbridos, como o CNN-LSTM, que combinam a extração de características espaciais das redes convolucionais com o modelamento sequencial das LSTM. Essa etapa também marca o uso de algoritmos como *Random Forest*, *XGBoost* e técnicas de ensemble dinâmico, como *stacking* e *arbitrating*. [Pereira and and \(2022\)](#), por exemplo, compararam 22 modelos e constataram que o uso de ML pode reduzir o RMSE em até 54% em previsões de curto prazo, quando comparado a abordagens tradicionais.

Entre 2022 e 2024, a literatura passa a adotar soluções ainda mais avançadas, como o aprendizado por reforço (*Reinforcement Learning*, RL) e a integração da IA a ecossistemas digitais inteligentes. [Chen et al. \(2023\)](#) apresentam a aplicação de um modelo de RL em uma rede hoteleira na China, totalmente integrado ao sistema ERP corporativo. Por meio de um experimento de campo controlado, o sistema obteve melhorias significativas em métricas-chave, como taxa de ocupação (OR), tarifa média diária (ADR) e RevPAR, superando de forma consistente o grupo de controle. O algoritmo demonstrou capacidade para tomada de decisão automatizada, adaptativa e em tempo real, evidenciando o potencial da IA para substituir intervenções manuais na gestão de receitas diária. Em paralelo, [Henriques and Pereira \(2024\)](#) desenvolvem uma revisão sobre a aplicação da IA na hotelaria, na qual destacam a consolidação de modelos híbridos que integram LSTM, SVR, *Random Forest* e *XGBoost* com dados internos (reservas, cancelamentos, tarifas) e dados externos (eventos, clima, avaliações de clientes e preços da concorrência). Além disso, propõem um enfoque de “*smart hospitality*”, voltado à sustentabilidade, personalização, decisões orientadas por *feedback* digital e à construção de sistemas autônomos e inteligentes.

Por fim, [Shaik \(2024\)](#) inaugura uma nova linha de investigação com os chamados *Lang Chain Models*, uma arquitetura de IA encadeada que integra previsão de demanda, precificação dinâmica, otimização de inventário e gestão da percepção de justiça em um sistema único e interconectado. Esses modelos são projetados para operar em tempo real dentro de ecossistemas hoteleiros 4.0, os quais incorporam tecnologias como *blockchain*, robótica e reconhecimento facial. A proposta busca substituir progressivamente as decisões humanas táticas por processos

automatizados, inteligentes e sustentáveis em rede.

De forma geral, essa evolução representa uma transformação profunda nas abordagens de previsão de demanda hoteleira, que passaram de metodologias manuais e estáticas para sistemas altamente automatizados, adaptativos e integrados. As contribuições analisadas não apenas aumentam a precisão preditiva, mas também redefinem o papel do gestor de receitas, que passa a atuar como um estrategista de soluções inteligentes, sustentáveis e centradas no cliente. O uso crescente da IA abre caminho para sistemas que não apenas maximizam receitas, mas também promovem uma gestão ética, personalizada e resiliente frente a ambientes competitivos e em constante mudança.

2.5 Contextualização desta pesquisa

Para contextualizar essa pesquisa dentro do estado da arte, a Tabela 2.1 apresenta uma síntese dos estudos mais relevantes sobre o transporte ferroviário de passageiros nos últimos 25 anos.

Tabela 2.1: Resumo dos trabalhos revisados

Autor(es)	Objetivo	Multi-Trem	Indústria	Tipo de função objetivo	Modelagem	Método de solução	Tipo de Demanda	Inteligência artificial
Claessens et al. (1998)	Minimizar os custos operacionais, ao mesmo tempo que designa as rotas	Não	Ferrovária	Objetivo único	MIP	Aproximado	-	-
(Chang et al., 2000)	Minimizar os custos totais e minimizar a perda de tempo de viagem, ao mesmo tempo em que determina o plano ideal de paradas	Não	Ferrovária	Multi-objetivo	Matemática difusa	Exata	Independente	-
(Maged M. Dessouky and Leachman, 2006)	Determinar os tempos ótimos de partidas dos trens	Sim	Ferrovária	-	-	Algoritmo de ramificação	-	-
(Zhang and Adelman, 2009)	Maximizar a receita	-	Aérea	Objetivo único	Programação dinâmica	Algoritmo de geração de colunas	Comportamental	-
(Corman et al., 2011)	Reprogramar trens com diferentes classes prioritárias	Sim	Ferrovária	Objetivo único	Formulação gráfica	Aproximado	-	-
(Erdelyi Alexander, 2011)	Maximizar a receita, ao mesmo tempo que define os preços	-	Aérea	Objetivo único	Programação linear determinística	Aproximado	-	-
(Hettrakul and Cirillo, 2013)	Maximizar a receita, ao mesmo tempo que encontra a melhor distribuição da demanda	Não	Ferrovária	Objetivo único	Modelos <i>logit multinomial</i> , classe latente e logit misto	Aproximado	Comportamental	-
(Hettrakul and Cirillo, 2014)	Maximizar as receitas, enquanto se realiza a definição de preços e a alocação de assentos	Sim	Ferrovária	Objetivo único	Estocástica (MNL e LC)	Aproximado	-	-
(Wen and Chen, 2017)	Examinar a relação entre o momento da compra de passagens aéreas e diferentes características do viajante	-	Aérea	Objetivo único	Programação não linear	Exata	-	-
(Qi et al., 2018)	Minimizar o número de assentos vazios e o número total de paradas	Sim	Ferrovária	Objetivo único	Programação linear de volume duplo de integração mista	Exata	Independente	-
(Xu et al., 2018)	Minimizar os custos de reserva antecipada ao escolher itinerários	Sim	Ferrovária	Objetivo único	Programação linear usando multiplicadores de <i>Lagrange</i>	Exata	Independente	-

Continua na próxima página

Tabela 2.1 – Continuação da página anterior

Autor(es)	Objetivo	Multi-Trem	Indústria	Tipo de função objetivo	Modelagem	Método de solução	Tipo de Demanda	Inteligência artificial
(Sun et al., 2018)	Previsão das escolhas dos passageiros do trem de alta velocidade (HSR) quanto aos horários de compra de passagens, tipos de trem e classes de viagem	-	Ferroviária	Objetivo único	Modelo de aprendizado de máquina não paramétrico	Aproximado	-	Regressão vetorial (SVR); Redes neurais artificiais (ANN)
(Zhao and Zhao, 2019)	Maximizar a receita, ao mesmo tempo que calcula a reserva de assentos	Sim	Ferroviária	Objetivo único	LP	Aproximado	Comportamental	-
(Barbier et al., 2020)	Maximizar a receita, controlando o estoque de assentos homogêneos	-	Aérea	Objetivo único	MIP	Aproximado	Comportamental	-
(Agasucci et al., 2023)	Otimizar o despacho de trens	Sim	Ferroviária	Objetivo único	Abordagem de aprendizado Q profundo	Aproximado	-	Deep Q-Learning (Descentralizado e Centralizado)
(Sarhani and Voß, 2024)	Melhorar a previsão de atrasos de trens	-	Ferroviária	Objetivo único	Aprendizado de máquina	-	-	Aprendizado de máquina
(Tang et al., 2025)	Reduzir o tempo total de atraso do trem	Sim	Ferroviária	Objetivo único	Modelo de aprendizado por reforço profundo multitarefa	Aproximado	-	Aprendizado por reforço e redes neurais
Esta pesquisa	Maximizar a receita, ao mesmo tempo em que calcula as autorizações e reservas de assentos	Não	Ferroviária	Objetivo único	MIP	Exata	Comportamental	-

É importante destacar que esta pesquisa está fundamentada em características clássicas que são comuns a diversas investigações realizadas até o momento, conforme ilustrado na Tabela 2.1. Contudo, embora o enfoque metodológico adotado compartilhe semelhanças com os estudos revisados, a proposta apresentada se distingue pela aplicação simultânea de abordagens baseados em problemas de transporte de veículos e fluxos em redes. Embora essas abordagens individuais já tenham sido exploradas de forma separada na literatura, não se encontrou um modelo que integre ambas as perspectivas ao mesmo tempo.

Dessa forma, o trabalho desenvolvido representa uma contribuição relevante ao avaliar e validar a eficiência dessa combinação de abordagens, fornecendo novas perspectivas para a resolução do problema de transporte ferroviário de passageiros do ponto de vista do RM.

CAPÍTULO 3

Modelagem matemática

3.1 Conceitos importantes

Esta seção apresenta alguns dos termos comumente utilizados na gestão de receitas no transporte ferroviário de passageiros, além de aprofundar-se em conceitos específicos que frequentemente geram confusão entre si.

Viagem: Um trem programado para uma data específica é denominado "viagem". Uma viagem inclui uma estação de partida (estação de origem) e uma estação de chegada (estação de destino final). A Figura 3.1 representa um exemplo de viagem, onde se tem um trem com o nome #03450-1 e data de partida em 12 de junho de 2024.




Figura 3.1: Representação de viagem

Trecho: Um trecho é uma conexão direta entre duas estações, também pode ser denominado como origem-destino. Além disso, será dito que um trecho é adjacente se, e somente se, não houver estações intermediárias entre elas; caso contrário, serão não adjacentes. Por exemplo,

a Figura 3.2 apresenta vários trechos, sendo que o trecho AC não é adjacente, enquanto os trechos AB e BC são adjacentes. É importante aclarar que os trechos não adjacentes podem conter outros trechos, tanto adjacentes quanto não adjacentes.




Figura 3.2: Representação de trechos

Itinerário: Um itinerário é uma combinação única de origem, destino, horário de partida e trem. Como mostrado na Figura 3.3, um itinerário pode consistir em um ou mais trechos, e uma viagem pode englobar um ou mais itinerários.




Figura 3.3: Representação de itinerários

Classes de controle: Uma classe de controle é um produto oferecido por um operador de transporte a passageiros potenciais por um preço específico. As classes de controle também são conhecidas como classes tarifárias, produtos tarifários ou classes de reservas. Uma classe de controle define os benefícios e/ou restrições que o passageiro terá como resultado do preço pago pelo bilhete.

Horizonte de reserva: É o período de tempo entre o momento em que os bilhetes para o trem em questão são disponibilizados para venda pela primeira vez e a data de partida do trem. O horizonte de reserva geralmente é discretizado por dias, de forma que cada período representa um dia específico antes da partida (*DBD*). Frequentemente, realiza-se uma agregação temporal para reduzir o tamanho do horizonte de reserva, selecionando alguns *DBD* específicos como pontos de controle (*CP*), essa situação é representada na Figura 3.4. Nesse contexto, o horizonte de contabilização é discretizado por períodos, onde o tamanho de cada período corresponde ao intervalo de tempo entre dois *CP* consecutivos.




Figura 3.4: Representação do horizonte de reserva

Reservas: As reservas representam o número de assentos protegidos para atender à demanda potencial de uma classe de controle específica em um determinado itinerário, durante um período específico do horizonte de reserva. O tamanho da reserva é definido no processo de otimização, considerando a demanda potencial do itinerário e da classe de controle correspondente. As reservas também são conhecidas como níveis de proteção.

Autorizações: As autorizações representam o número de assentos disponíveis para venda em um determinado itinerário e classe de controle. Elas podem ser entendidas como a quantidade de bilhetes apresentados aos passageiros como disponíveis para compra. As autorizações têm como objetivo controlar o volume de passageiros ao longo de um itinerário ou trecho.

As Autorizações podem ser classificadas como *estáticas* ou *dinâmicas*. As Autorizações estáticas não estão indexadas no tempo, enquanto as dinâmicas estão. Para uma melhor compreensão, observe a Figura 3.5, onde, no caso de uma classe de controle A_1 , ela assume apenas um valor para todo o horizonte de reserva no caso de autorização estática, e toma valores distintos em função de cada período para as autorizações dinâmicas.




Figura 3.5: Classes de autorização

Demanda comportamental: Neste modelo, assume-se que o comportamento de compra dos passageiros é influenciado pelo conjunto de classes de controle disponíveis. Um exemplo desse conceito é ilustrado na Figura 3.6. Considere um cenário em que 4 clientes desejam comprar a tarifa A3, sendo essa sua primeira opção. Caso a tarifa A3 não esteja disponível, um dos clientes desiste da compra, enquanto os outros 3 permanecem no sistema e estão dispostos a adquirir a tarifa A2. Se A2 também não estiver disponível, mais 2 clientes abandonam a compra, restando apenas um cliente que opta por A1 (geralmente, a opção de maior valor).




Figura 3.6: Representação de demanda comportamental

Demanda independente: Os clientes compram um produto específico, independentemente da oferta disponível no momento. Para exemplificar essa situação, observe a Figura 3.7, no qual é representado um modelo de demanda independente, onde se assume que um cliente disposto a pagar R\$100 por um bilhete nunca optaria por um bilhete mais barato (por exemplo, R\$50), mesmo que este estivesse disponível.




Figura 3.7: Representação de demanda independente

Skip lagging: No contexto do transporte ferroviário de passageiros, skip lagging refere-se a uma estratégia de otimização na programação das paradas dos trens, na qual certos serviços omitem paradas intermediárias em determinados trechos. O objetivo é reduzir os tempos de viagem e aumentar a eficiência operacional, garantindo que essa omissão não comprometa a

acessibilidade e a qualidade do serviço oferecido aos passageiros. Na seção de modelagem matemática, será apresentado um conjunto de restrições associadas a esse conceito.

Fulfillments over periods: No contexto do transporte ferroviário de passageiros, *fulfillments over periods* refere-se ao cumprimento de determinados níveis de serviço, demanda ou capacidade ao longo de um período de tempo definido. Esse conceito é especialmente relevante na gestão de receitas, planejamento operacional e alocação de recursos, onde é essencial garantir que a oferta de serviços ferroviários atenda a objetivos estratégicos ao longo do tempo, em vez de se concentrar apenas em momentos específicos. Na seção de modelagem matemática, será apresentado um conjunto de restrições associadas a esse conceito.

Listas de preferência: Representam uma hierarquia de alternativas de compra que um passageiro está disposto a considerar no momento da aquisição de uma passagem ferroviária, baseando-se, principalmente, nos preços ofertados nesse momento. Essas listas são fundamentais para entender o comportamento do consumidor e otimizar as estratégias de preços e disponibilidade de assentos. Elas podem ser utilizadas para modelar a demanda de forma mais precisa, levando em conta as preferências dos passageiros e suas reações a diferentes ofertas tarifárias.

3.2 Descrição do problema

O problema em análise considera um trem com diferentes tipos de assentos que poderá realizar uma viagem entre uma estação de origem E_1 e uma estação de destino final E_n (onde n representa a última estação da rota). Esse trem terá um itinerário que inclui o nome do trem, a estação de origem, a estação de destino, bem como a data e o horário de partida.

Os assentos disponíveis são classificados conforme suas características — por exemplo, VIP, padrão, entre outros. Para cada tipo de assento, será definida uma lista de preços a ser disponibilizada para venda. Cada preço dessa lista é denominado classe de controle (*control class*) e constitui um parâmetro de entrada do modelo. Os bilhetes serão oferecidos ao público antes da partida do trem, sendo o intervalo entre o início das vendas e o momento da partida denominado *horizonte de reserva*. Esse horizonte será segmentado em diversos períodos, que

podem adotar diferentes granularidades temporais, como dias, semanas ou meses, inclusive de forma combinada. Os períodos são organizados de forma decrescente, sendo que o valor zero corresponde à data de partida, e o maior valor representa o início da disponibilização dos bilhetes, formando a sequência $[t, t - 1, t - 2, \dots, 0]$.

Diante dessas condições, o objetivo é controlar a disponibilidade de assentos — tanto os reservados quanto os autorizados para venda — em cada período do horizonte de reserva, visando à maximização da receita total obtido com a comercialização dos assentos reservados.

Para alcançar esse objetivo, o modelo deve considerar restrições que assegurem: a capacidade física do trem, a integridade das variáveis inteiras, a relação entre os assentos reservados e a demanda, bem como a coerência entre os assentos reservados e os efetivamente disponibilizados para venda.

Essas restrições compõem o **modelo básico**. No entanto, esta pesquisa propõe a inserção de dois conjuntos adicionais de restrições que, segundo os autores, refletem práticas amplamente utilizadas em ambientes reais. Esses conjuntos — *Fulfillments over Periods* e *Skip Lagging* — fazem parte integrante do modelo como um todo. No entanto, para fins de clareza e melhor exposição, serão apresentados de forma separada.

O primeiro conjunto, de tipo *Fulfillments over Periods*, está relacionado a condições temporais e garante que: i) os preços das classes de controle ofertadas aumentem progressivamente à medida que se aproxima a data de partida do trem; ii) uma determinada classe de controle para um trecho específico só possa ser reservada se já tiver sido reservada em um período anterior dentro do horizonte de reserva.

O segundo conjunto, de tipo *Skip Lagging*, refere-se ao padrão de paradas do trem e assegura que: i) os passageiros não possam adquirir bilhetes para estações posteriores com a intenção de desembarcar antes do destino indicado no bilhete. Em outras palavras, para uma origem dada, os preços das passagens para destinos mais distantes devem ser proporcionais à distância percorrida; ii) para um par origem-destino, a soma dos preços dos trechos intermediários contínuos não seja inferior ao valor de uma passagem direta.

Além das restrições, destaca-se também a caracterização do tipo de demanda considerada. Neste trabalho, utilizam-se duas abordagens: a **demand independente**, definida por decisões

de compra que não consideram a oferta disponível no momento da aquisição; e a **demanda comportamental**, baseada em listas de preferência, em que os passageiros escolhem entre diferentes preços conforme sua disponibilidade e preferências no momento da compra.

Todos os aspectos apresentados são tratados no contexto de uma **autorização estática**, a qual determina os valores dos assentos a serem disponibilizados ao longo de todo o horizonte de reserva. Contudo, os autores optaram também por explorar o caso de **autorizações dinâmicas**, em que, a cada período do horizonte de reserva, é liberada uma quantidade específica de assentos para venda. Ambas as modalidades são amplamente reconhecidas na literatura e na prática da indústria. De fato, a empresa fornecedora dos dados adota o modelo de autorização estática.

3.3 Formulação matemática

Para facilitar a compreensão da proposta, apresenta-se a seguir uma versão simplificada do problema, conforme ilustrado na Figura 3.8, na qual são considerados os seguintes elementos:

- 4 estações pelas quais o trem deve passar em um único sentido, ou seja, o trem não tem retorno.
- O trem tem uma capacidade física máxima de assentos;
- Há apenas um tipo de classe de controle;
- Existe apenas um período no horizonte de reserva;
- Considera-se, neste caso, apenas a variável de decisão associada à quantidade de assentos reservados em um trecho com origem e destino específicos;
- Todos os assentos reservados serão vendidos;
- É considerada um tipo de demanda independente;
- É considerada somente a restrição de capacidade física do trem.




Figura 3.8: Versão gráfica simples do Problema de Transporte Ferroviário de Passageiros

Com base no exposto, é possível definir os seguintes parâmetros e variáveis de decisão:

Variáveis :

x_{ij} : Quantidade de assentos que serão reservados no trecho com origem em i e destino em j , onde $j > i$ (variável de decisão);

A_i : Quantidade de assentos vagos na estação i (variável auxiliar);

Parâmetros :

P_{ij} : Preço da passagem no trecho com origem em i e destino em j ;

Q : Capacidade física do trem.

Assim, a função objetivo será maximizar a receita para cada possível reserva em cada trecho (i, j) , matematicamente seria:

$$FO : \max \quad x_{12}P_{12} + x_{13}P_{13} + x_{14}P_{14} + x_{23}P_{23} + x_{24}P_{24} + x_{34}P_{34}$$

s.a.

$$\text{Estação 1: } x_{12} + x_{13} + x_{14} \leq A_1 \quad \text{onde } A_1 = Q$$

$$\text{Estação 2: } x_{23} + x_{24} \leq A_2 \quad \text{onde } A_2 = A_1 - (x_{12} + x_{13} + x_{14}) + x_{12}$$

$$\text{Estação 3: } x_{34} \leq A_3 \quad \text{onde } A_3 = A_2 - (x_{23} + x_{24}) + x_{13} + x_{23}$$

Observe que as restrições de capacidade são aplicadas apenas às três primeiras estações — E_1, E_2 e E_3 —, já que são as únicas que possuem pelo menos um destino associado. A estação E_4 é excluída, pois não possui nenhum destino.

Cada uma das restrições leva em consideração o fluxo de pessoas que sairão e entrarão no trem. Levando isso em conta, é necessário calcular a quantidade de assentos vagos do trem para cada estação. Considere uma solução viável para o modelo, conforme mostrado na Figura 3.9, com uma capacidade total de 100 assentos para um trem.

		DESTINOS			Disponibilidade (A)	Não Atribuídos
		E2	E3	E4		
ORIGENS	E1	X_{12} 10	X_{13} 5	X_{14} 15	100	70
	E2	...	X_{23} 40	X_{24} 20	$70 + 10$	20
	E3	...	...	X_{34} 60	$20 + 5 + 40$	5

Figura 3.9: Solução factível para o problema simplificado

Note que, para a restrição da estação 1, o trem está com todos os assentos vazios, ou seja, $A_1 = 100$, e que a soma das variáveis seria $x_{12} + x_{13} + x_{14} = 10 + 5 + 15 = 30$. Portanto, a restrição é satisfeita com $30 \leq 100$, ou seja, foram reservados 30 assentos dos 100 que o trem possui. Nesse sentido, no momento da partida do trem da estação 1, haveria 70 assentos vazios ou disponíveis para reservar em estações posteriores.

Agora, para a estação 2, teríamos $A_2 = 100 - 30 + 10 = 70 + 10 = 80$. Já era conhecido que havia 70 assentos disponíveis vindos da estação 1, mas também é preciso levar em conta que os assentos com destino à estação 2 também ficarão disponíveis da estação 2 em diante, para este caso $x_{12} = 10$. Portanto, para a estação 2, teríamos 80 assentos vazios para reservar, é assim que a restrição é cumprida com $60 \leq 80$. Analogamente, o mesmo raciocínio seria aplicado para a estação 3, ou seja, teríamos a soma de todos os assentos que chegaram à estação 3, $x_{13} = 5$ e $x_{23} = 40$, assim teríamos $A_3 = 80 - 60 + 5 + 40 = 20 + 5 + 40 = 65$, e no final, a restrição é satisfeita com $60 \leq 65$.

Nas seções seguintes, para cada abordagem, serão apresentados os modelos propostos, iniciando por um modelo base, em seguida, a esse modelo base serão adicionados, de forma separada, tanto os conjuntos de restrições do tipo *Fulfillment over periods* quanto os conjuntos de restrições do tipo *Skip Lagging*. Por fim, também será apresentado o modelo completo, no qual todos os conjuntos de restrições são incorporados simultaneamente.

3.4 Abordagem dos modelos propostos

Foram abordados dois enfoques distintos para o desenho dos modelos. O primeiro enfoque, baseado nos tipos de demanda, abrange a demanda independente e a demanda comportamental.

O segundo enfoque trata da indexação das passagens autorizadas para venda, sendo classificado em estático e dinâmico. No enfoque estático, a quantidade de assentos a serem autorizados é calculada para todo o horizonte de reserva de uma vez, sem considerar variações temporais. Já no enfoque dinâmico, os assentos autorizados são calculados por períodos dentro do horizonte de reserva, levando em conta a evolução da demanda ao longo do tempo.

Os dois enfoques resultaram em quatro modelos distintos, no entanto, os autores desta pesquisa buscaram analisar como a solução de cada modelo variava ao adicionar ou remover os conjuntos de restrições específicos (*fulfillment over periods* e *skip lagging*). Para isso, cada modelo foi inicialmente dividido em uma versão básica, à qual foram incorporados, de forma separada, os conjuntos de restrições. Por fim, obteve-se o modelo completo, que inclui todos os conjuntos de restrições. Essa classificação pode ser visualizada na Tabela 3.1.

Além do exposto, é importante salientar que os modelos serão apresentados por abordagem. Cada modelo encontra-se estruturado em blocos, e cada bloco possui um nome ou código próprio, reunindo um conjunto específico de restrições. O modelo completo de uma abordagem corresponde, portanto, à união de todos os blocos. Essa organização está sintetizada na Tabela 3.1, em cuja coluna “Bloco” se apresentam as combinações correspondentes de blocos que definem cada modelo completo, bem como as frações de blocos associadas aos demais modelos.

Tipo de Autorização	Tipo de Demanda	Modelo	Nome do Modelo	Bloco
Estática	Independente	Modelo Básico	Basic_Independ_Est	EI1
		Modelo <i>fulfillments over periods</i>	Fulfill_Independ_Est	EI1+EI2+EI3
		Modelo <i>skip lagging</i>	Skipla_Independ_Est	EI1+EI2+EI4
		Modelo Completo	Comp_Independ_Est	EI1+EI2+EI3+EI4
	Comportamental	Modelo Básico	Basic_Comporta_Est	EC1
		Modelo <i>fulfillments over periods</i>	Fulfill_Comporta_Est	EC1+EI2+EI3
		Modelo <i>skip lagging</i>	Skipla_Comporta_Est	EC1+EI2+EI4
		Modelo Completo	Comp_Comporta_Est	EC1+EI2+EI3+EI4
Dinâmica	Independente	Modelo Básico	Basic_Independ_Din	DI1
		Modelo <i>fulfillments over periods</i>	Fulfill_Independ_Din	DI1+DI2+EI3
		Modelo <i>skip lagging</i>	Skipla_Independ_Din	DI1+DI2+EI4
		Modelo Completo	Comp_Independ_Din	DI1+DI2+EI3+EI4
	Comportamental	Modelo Básico	Basic_Comporta_Din	DC1
		Modelo <i>fulfillments over periods</i>	Fulfill_Comporta_Din	DC1+DI2+EI3
		Modelo <i>skip lagging</i>	Skipla_Comporta_Din	DC1+DI2+EI4
		Modelo Completo	Comp_Comporta_Din	DC1+DI2+EI3+EI4

Tabela 3.1: Descrição dos modelos matemáticos propostos

3.4.1 Primeira abordagem: modelos com autorizações estáticas e demanda independente

Nos modelos desta seção, considera-se uma demanda independente, ou seja, assume-se que cada cliente realiza sua decisão de compra de forma isolada em relação à oferta disponível no momento da aquisição. Em termos práticos, isso implica que, se um passageiro estiver disposto a pagar, por exemplo, R\$10 por um determinado assento, ele efetuará a compra apenas se encontrar esse valor específico, mesmo que existam tarifas mais baixas disponíveis. Caso não encontre o preço correspondente à sua disposição de pagamento, optará por não realizar a compra.

Para esta proposta considere os seguintes conjuntos:

O : Conjunto de estações de origem.

D : Conjunto de estações de destino.

OD : Conjunto de trechos com itinerário.

NAD : Conjunto de trechos que NÃO são adjacentes e que tem itinerário.

$CR_{(o,d)}$: É um conjunto que contém outros subconjuntos, onde cada subconjunto é uma rota possível para ir desde a origem o até o destino d , sendo (o,d) não adjacente.

S : Representa cada subconjunto dentro de $CR_{(o,d)}$.

V : Conjunto de tipos de assento do trem.

T : Conjunto de períodos.

K_v : Conjunto das classes de controle para cada tipo de assento v . Onde os índices de cada K_v estão em ordem decrescente, enquanto seus valores são crescentes.

Considere os seguintes parâmetros:

Q_v : Capacidade física do trem para cada tipo de assento v , onde $v \in V$.

P_{ijk} : Preços das passagens no trecho (i,j) , tipo de assento v e classe de controle k , onde $(i,j) \in OD, v \in V, k \in K_v$.

d_{ijkvt} : Demanda independente no trecho (i,j) , tipo de assento v , classe de controle k e período t , onde $(i,j) \in OD, v \in V, k \in K_v, t \in T$.

Considere as seguintes variáveis de decisão:

X_{ijvkt} : Quantidade de passagens reservadas no trecho (i, j) , tipo de assento v e com classe de controle k no período t , onde $(i, j) \in OD, v \in V, k \in K_v, t \in T$.

Y_{ijvk} : Quantidade de passagens autorizadas em todo o horizonte de reserva, no trecho (i, j) , tipo de assento v e com classe de controle k , onde $(i, j) \in OD, v \in V, k \in K_v$.

β_{ijvkt} : É uma variável binária que toma o valor de 1 quando a classe k é a classe mais barata que foi autorizada para venda, no trecho (i, j) , tipo de assento v e período t ; e toma valor de 0 caso contrario, onde $(i, j) \in OD, v \in V, k \in K_v, t \in T$.

α_{ijvkt} : É uma variável binária que toma o valor de 1 quando $X_{ijvkt} \neq 0$ e toma valor de 0 caso contrario, onde $(i, j) \in OD, v \in V, k \in K_v, t \in T$.

Considere a seguinte variável auxiliar:

A_{iv} : Armazena a quantidade de assentos vazios disponíveis para venda em cada estação de origem i e cada tipo de assento v durante todo o horizonte de reserva, onde $i \in O, v \in V$. Cabe esclarecer que esta não é uma variável de decisão, pois esta variável apenas armazena um cálculo com base na capacidade física do trem e nas variáveis de decisão de passagens reservadas.

Dessa maneira, as restrições do modelo, organizadas por bloco, são descritas a seguir:

Bloco EI1

Modelo básico

$$\text{Max } Z = \sum_{(i,j) \in OD} \sum_{v \in V} \sum_{k \in K_v} \sum_{t \in T} P_{ijvk} X_{ijvkt} \quad (3.1)$$

s.a.

$$A_{iv} = A_{i-1,v} - \sum_{(i,j) \in OD / j \geq i} \sum_{k \in K_v} \sum_{t \in T} X_{i-1,j,v,k,t} + \sum_{(i,j) \in OD / j < i} \sum_{k \in K_v} \sum_{t \in T} X_{jivkt}, \quad \forall i \in O, v \in V \quad (3.2)$$

$$Y_{ijvk} \geq \sum_{t \in T} X_{ijvkt}, \quad k = \max\{K_v\}, \forall (i, j) \in OD, v \in V \quad (3.3)$$

$$Y_{ijvk} \geq \sum_{t \in T} X_{ijvkt} + Y_{i,j,v,k+1}, \quad \forall (i, j) \in OD, v \in V, k \in K_v / k < |K_v| \quad (3.4)$$

$$\sum_{(i,j) \in OD} Y_{ijvk} \leq A_{iv}, \quad k = \min\{K_v\}, \forall i \in O / (i, j) \in OD, \forall v \in V \quad (3.5)$$

$$X_{ijvkt} \leq d_{ijvkt}, \quad \forall (i, j) \in OD / i < j, v \in V, k \in K_v, t \in T \quad (3.6)$$

$$A_{0,v} = Q_v \quad \forall v \in V \quad (3.7)$$

$$X_{0,j,v,k,t} = 0 \quad \forall j \in D, v \in V, k \in K_v, t \in T \quad (3.8)$$

$$X_{ijvkt} \in \mathbb{Z}^+ \quad \forall (i, j) \in OD, v \in V, k \in K_v, t \in T \quad (3.9)$$

$$Y_{ijvk} \in \mathbb{Z}^+ \quad \forall (i, j) \in OD, v \in V, k \in K_v \quad (3.10)$$

$$A_{iv} \in \mathbb{Z}^+ \quad \forall i \in O, v \in V \quad (3.11)$$

Bloco EI2

Restrições das variáveis binárias

$$\alpha_{ijvkt} \leq X_{ijvkt} \leq \alpha_{ijvkt} d_{ijvkt}, \quad \forall (i, j) \in OD, v \in V, k \in K_v, t \in T \quad (3.12)$$

$$\beta_{ijvkt} = \alpha_{ijvkt} - \alpha_{i,j,v,k+1,t}, \quad \forall (i, j) \in OD, v \in V, k \in K_v / k < \max\{K_v\}, t \in T \quad (3.13)$$

$$\beta_{ijvkt} = \alpha_{ijvkt}, \quad \forall (i, j) \in OD, v \in V, k = \max\{K_v\}, t \in T \quad (3.14)$$

Bloco EI3

Restrições *fulfillments over periods*

$$\alpha_{ijvkt} \leq \alpha_{i,j,v,k,t+1}, \quad \forall (i, j) \in OD, v \in V, k \in K_v, t \in T / t \neq \max\{T\} \quad (3.15)$$

$$\sum_{k \in K_v} \beta_{ijvkt} P_{ijvk} \geq \sum_{k \in K_v} \beta_{i,j,v,k,t+1} P_{ijvk}, \quad \forall (i, j) \in OD, v \in V, t \in T / t \neq \max\{T\} \quad (3.16)$$

Bloco EI4

Restrições *skip lagging*

$$\sum_{k \in K_v} \beta_{ijvkt} P_{ijvk} \leq \sum_{k \in K_v} \beta_{i,j',v,k,t} P_{ijvk}, \quad \forall i \in O, j \in D, j' \in D / j' > j, v \in V, t \in T \quad (3.17)$$

$$\sum_{k \in K_v} \beta_{odvkt} P_{odvk} \leq \sum_{(i,j) \in S} \sum_{k \in K_v} \beta_{ijvkt} P_{ijvk}, \quad \forall (o, d) \in NAD, \quad (3.18)$$

$$v \in V, t \in T, \quad \forall S \in CR_{o,d} / S \subset CR_{o,d}$$

Em primeiro lugar, define-se a função objetivo conforme apresentada na equação (3.1). Observa-se que seu propósito é maximizar a receita total, considerando as quantidades de assentos reservados para cada combinação de trechos, tipo de assento, classes de controle e periodos, ponderadas pelos respectivos preços associados.

As restrições (3.2) tem como finalidade calcular, de forma sistemática, a quantidade de assentos disponíveis em cada estação de origem em todo o horizonte de reserva. Essa restrição representa uma generalização do procedimento apresentado no exemplo simplificado utilizado anteriormente para o cálculo de A_i , expandindo-o para capturar a dinâmica completa do sistema ao longo do tempo, entre múltiplas classes de controle e considerando cada tipo de assento de forma específica.

A variável de decisão Y_{ijk} adota uma estrutura do tipo *nesting*, onde cada classe tarifária mais cara (classe “pai”) engloba todas as classes mais baratas (classes “filhas”). Nesse encadeamento, todas as classes possuem um pai e um filho, com exceção da classe mais cara — que não possui pai — e da classe mais barata — que não possui filho. Dessa forma, o valor mínimo da variável Y_{ijk} para uma determinada classe deve ser igual ou superior à soma das reservas dessa própria classe e das autorizações concedidas à sua classe filha (como visto na Figura 3.10 para as classes 1, 2, 3). As restrições (3.3) formalizam esse comportamento especificamente para a classe mais barata, enquanto as restrições (3.4) garantam essa hierarquia para as demais classes de controle.




Figura 3.10: Exemplo de *nesting* para o trecho $E_1 - E_2$ e tipo de assento P

Considerando que a variável Y_{ijk} é do tipo *nesting* e levando em conta os dois conjuntos de restrições (3.3) e (3.4), fica evidente que a classe mais cara engloba as quantidades das demais classes; portanto, deve-se assegurar que ela não exceda o número de assentos vazios. Essa condição é garantida pelas restrições (3.5).

As restrições (3.6) asseguram que, para cada trecho, classe, tipo de assento e período do horizonte de reserva, a quantidade de passagens reservadas não exceda a demanda correspondente.

As restrições (3.7) e (3.8) são usadas para inicializar as restrições (3.2) quando $i = 1$. E as

restrições de (3.9) a (3.11) representam o domínio das variáveis.

Por outro lado, as restrições (3.12) são utilizadas para determinar quando a variável de decisão X assume valores iguais e diferentes de zero. Assim, α toma o valor de 1 no primeiro caso e 0 no segundo.

As restrições (3.13) e (3.14) têm como objetivo identificar a classe de assento mais barata reservada em um determinado trecho, tipo de assento e período. As restrições (3.13) são utilizadas exclusivamente para as classes mais baratas, enquanto as restrições (3.14) se aplica às demais classes de assento. Assim, a variável β assume o valor de 1 quando a classe k é a mais barata reservada e 0 caso contrário (veja a Figura 3.11).



$E_1 - E_2$			
Classe	X	α	β
1	10	1	1 - 1
2	5	1	1 - 0
3	0	0	0

$E_1 - E_2$			
Classe	X	α	β
1	10	1	0
2	5	1	1
3	0	0	0

Figura 3.11: Exemplo cálculo da variável β para o trecho $E_1 - E_2$, um período e um tipo de assento

Convém recordar que as restrições do tipo *fulfillment over periods* dizem respeito ao cumprimento de determinados níveis de serviço, demanda ou capacidade ao longo do horizonte de reservas. O seguinte conjunto de restrições define em quais momentos os assentos de determinadas classes devem ou não ser reservados. Além disso, estabelece regras específicas para a evolução temporal dos preços das classes.

Assim, uma condição importante estabelece que uma classe pode ser reservada desde que essa mesma classe já tenha sido reservada em períodos anteriores. Para isso, definem-se a restrição (3.15). Cabe lembrar que o tempo t representa os t períodos antes da saída do trem, sendo que a partida do trem ocorre em $t = 0$.

Outra condição especial deste problema está relacionada à disponibilização dos preços dos bilhetes ao longo do tempo. Esses preços devem seguir uma lógica contínua, sem oscilações. Em outras palavras, os preços dos bilhetes devem sempre aumentar conforme a data de partida do trem se aproxima. A restrição (3.16) é responsável por garantir que essa condição seja

atendida.

A seguir, apresentam-se as restrições do tipo *skip lagging*. Esse conjunto refere-se à prática de reservar um assento para um destino intermediário com a intenção de não prosseguir até o destino final. As restrições de *skip lagging* regulam a viabilidade e as condições em que tal prática pode ocorrer, considerando a gestão da capacidade, as políticas de precificação e os níveis de serviço a serem assegurados ao longo do horizonte de reservas.

Porem, dentro do problema, é necessário garantir que, para todos os trechos com a mesma estação de origem, os trechos mais curtos disponibilizados para venda sejam mais baratos que os trechos mais longos. Isso é estabelecido para evitar que passageiros comprem bilhetes para um trecho maior e desembarquem em estações anteriores. Essa situação é controlada pela restrição (3.17).

Além disso, deve-se garantir que todas as possíveis combinações dos preços mais baratos dos trechos contidos dentro dos trechos não adjacentes sejam maiores ou iguais ao preço desse trecho não adjacente. Em outras palavras, deve-se evitar que os passageiros comprem bilhetes para trechos intermediários com o objetivo de alcançar seu destino final. Essa situação é controlada pela restrição (3.18).

Em função do exposto, destaca-se que o modelo `Basic_Independ_Est` corresponde apenas ao conjunto de restrições contidas no Bloco [EI1](#). Já o modelo `Fulfill_Independ_Est` é constituído pela união de todas as restrições presentes nos Blocos [EI1](#), [EI2](#) e [EI3](#). De forma análoga, o modelo `Skipla_Independ_Est` é composto pelas restrições dos Blocos [EI1](#), [EI2](#) e [EI4](#). Por fim, o modelo completo `Comp_Independ_Est` abrange a totalidade das restrições, ou seja, aquelas incluídas nos Blocos [EI1](#), [EI2](#), [EI3](#) e [EI4](#).

3.4.2 Segunda abordagem: modelos com autorizações estáticas e demanda comportamental

Nesta seção, serão apresentados modelos baseados em demandas comportamentais, os quais buscam capturar o comportamento dos consumidores em contextos de reserva e consumo de serviços. Ao incorporar elementos da teoria comportamental, esses modelos permitem uma melhor compreensão das escolhas dos clientes, levando em consideração fatores psicológicos

e contextuais que influenciam suas decisões. Para modelar a demanda comportamental, serão utilizadas listas de preferência, que refletem as preferências individuais dos consumidores em relação a diferentes opções de produtos ou serviços.

Para compreender melhor essa situação, analisa-se o seguinte exemplo: considera-se um trecho $E_1 - E_2$, com três classes de controle (c_1, c_2, c_3) , onde $c_1 > c_2 > c_3$. Além disso, existe um único período, um único tipo de assento disponível e cada classe terá uma demanda de 10, 20 e 30, respectivamente.

$d_{12c1} = 10$ $d_{12c2} = 20$ $d_{12c3} = 30$	$d'_{12c1} = 10 = \{c_3 > c_2 > c_1 > NC\}$ $d'_{12c2} = 20 = \{c_3 > c_2 > NC\}$ $d'_{12c3} = 30 = \{c_3 > NC\}$
(a) Demanda Independente [d]	(b) Demanda Comportamental [d']

Figura 3.12: Exemplo: Tipos de Demanda


Para interpretar a demanda independente, podemos dizer (segundo a Figura 3.12a) que: existem 10 pessoas dispostas a comprar passagens **a um preço** de c_1 , 20 pessoas a comprar **a um preço** de c_2 e 30 pessoas a comprar **a um preço** de c_3 . No entanto, se as 10 pessoas dispostas a pagar c_1 encontrarem um valor melhor no momento da compra (por exemplo, c_3), essas pessoas prefeririam não comprar, situação que, na realidade, não faria sentido.

Por outro lado, temos a demanda comportamental, denotada como d' , que está representada com uma lista de preferência, conforme visto na Figura 3.12b. Esta lista significa que, por exemplo, 10 pessoas estão dispostas a comprar **até um preço** com valor c_1 (antes de preferir não comprar (NC)), 20 pessoas estão dispostas a comprar **até um preço** de c_2 (antes de preferir não comprar) e 30 pessoas estão dispostas a comprar **até um preço** de c_3 (antes de preferir não comprar).

O funcionamento seria o seguinte: imagine que as 10 pessoas dispostas a comprar até um valor de c_1 vão tentar comprar primeiro a um valor mais barato, neste caso c_3 . Se c_3 não estiver disponível, elas procurariam assentos com valor c_2 . Se c_2 também não estiver disponível, subiriam na lista e procurariam passagens com valor de c_1 . Se estes não estiverem disponíveis, então não comprariam. Note que esse comportamento é o que comumente se usa na realidade.

Agora, analisa-se como o modelo interpretaria esse novo comportamento. Para isso, calcula-se a nova demanda potencial:

Para c_1 , analisa-se a lista e verifica-se quem está disposto a pagar por esse valor.




$$\begin{aligned} d'_{12c1} &= 10 = \{c_3 > c_2 > c_1 > NC\} \\ d'_{12c2} &= 20 = \{c_3 > c_2 > NC\} \\ d'_{12c3} &= 30 = \{c_3 > NC\} \end{aligned}$$

Figura 3.13: Exemplo: demanda comportamental para a classe c_1

Segundo a Figura 3.13, apenas 10 possíveis passageiros estão dispostos a pagar esse valor.

Agora, analisa-se quem está disposto a pagar um valor por um bilhete da classe c_2




$$\begin{aligned} d'_{12c1} &= 10 = \{c_3 > c_2 > c_1 > NC\} \\ d'_{12c2} &= 20 = \{c_3 > c_2 > NC\} \\ d'_{12c3} &= 30 = \{c_3 > NC\} \end{aligned}$$

Figura 3.14: Exemplo: demanda comportamental para a classe c_2

Neste caso, 30 possíveis pessoas estariam dispostas a pagar esse valor. Observe que, desta nova demanda, 10 pessoas correspondentes à demanda de c_1 também estariam dispostas a comprar pelo valor da classe c_2 .

Por último, para a classe mais barata c_3 , veja a Figura 3.15.



$$\begin{aligned} d'_{12c1} &= 10 = \{c_3 > c_2 > c_1 > NC\} \\ d'_{12c2} &= 20 = \{c_3 > c_2 > NC\} \\ d'_{12c3} &= 30 = \{c_3 > NC\} \end{aligned}$$

Figura 3.15: Exemplo: demanda comportamental para a classe c_3

Note que, neste caso, 60 pessoas estariam dispostas a pagar um bilhete da classe c_3 , ou seja, toda a demanda do trecho $(E_1 - E_2)$ compraria pelo valor mais barato se este estivesse

disponível.

Assim, a demanda potencial comportamental para o modelo seria como se apresenta na Figura 3.16.

$$\begin{aligned} d'_{12c1} &= 10 \\ d'_{12c2} &= 20 + 10 = 30 \\ d'_{12c3} &= 30 + 10 + 20 = 60 \end{aligned}$$

Figura 3.16: Exemplo: demanda comportamental total potencial

No entanto, é importante lembrar que a demanda potencial inicial era de 60 pessoas, mas até este ponto, a demanda poderia ser maior, pois a demanda de cada classe comercial agora é o acúmulo das demandas das classes mais caras. Essa situação precisa ser controlada para não criar uma demanda inexistente; para isso, serão consideradas as seguintes restrições, relacionando neste caso as variáveis de decisão de assentos reservados:

$$X_{12c_1} \leq d'_{12c_1} = 10 \quad (3.19)$$

$$X_{12c_2} \leq d'_{12c_2} = 30 \quad (3.20)$$

$$X_{12c_3} \leq d'_{12c_3} = 60 \quad (3.21)$$

$$X_{12c_1} + X_{12c_2} \leq d'_{12c_2} = 30 \quad (3.22)$$

$$X_{12c_1} + X_{12c_2} + X_{12c_3} \leq d'_{12c_3} = 60 \quad (3.23)$$

Observe-se que as restrições de (3.19) até (3.21) são restrições conhecidas que limitam os valores que as passagens reservadas podem assumir, enquanto as restrições (3.22) e (3.23) são as que auxiliarão no controle para que não se ultrapasse a demanda potencial total inicial.

Por exemplo, se X_{12c_2} assume o valor de 30 (na restrição 3.20), a restrição (3.22) garantiria que X_{12c_1} seja igual a 0, pois a demanda de 10 pessoas correspondente preferiu comprar ao preço da classe c_2 . A mesma situação ocorreria se X_{12c_3} assumisse o valor de 60 (na restrição 3.21), então a restrição (3.23) garantiria que a demanda por X_{12c_1} e X_{12c_2} fosse igual a zero, já que esses clientes decidiram comprar pelo valor da classe c_3 . Dessa forma, esse conjunto de restrições funcionaria para cada combinação possível das variáveis descritas.

As características dos modelos que serão apresentados nesta seção possuem grande semelhança com os modelos com demanda independente, apresentados na seção anterior. Desta forma, as definições de conjuntos, variáveis de decisão e parâmetros seguem a mesma definição apresentada anteriormente. Serão realizadas as devidas anotações sempre que houver alguma mudança ou ajuste necessário.

Dito isso, nesta abordagem mantêm-se as mesmas restrições apresentadas na seção anterior, com exceção das restrições (3.6), que conservam a estrutura original, mas passam a empregar a demanda comportamental em lugar da demanda independente. Adicionalmente, são consideradas as seguintes especificações:

Parâmetros:

d'_{ijvk} : Demanda comportamental no trecho (i, j) , tipo de assento v e classe de controle k , onde $(i, j) \in OD, v \in V, k \in K_v, t \in T$.

M : É um número suficientemente grande.

σ_{ijvk} : É a probabilidade (baseada na simulação de Monte Carlo) de que um passageiro disposto a pagar o valor do bilhete da classe k e tipo de assento v chegue no período t do trecho (i, j) . Onde $(i, j) \in OD, v \in V, k \in K_v, t \in T$.

Variáveis de decisão:

δ_{ijvk} : Variável binária que assume o valor de 1 quando o preço da classe mais cara é maior do que a soma dos preços das classes mais baratas, e o valor de 0 em caso contrário., onde $(i, j) \in OD, v \in V, k = \min\{K_v\}, t \in T$.

Dessa forma, as restrições referentes à segunda abordagem são apresentadas a seguir, estruturadas de acordo com os respectivos blocos:

Bloco EC1

Modelo básico

$$\text{Max } Z = \sum_{(i,j) \in OD} \sum_{v \in V} \sum_{k \in K_v} \sum_{t \in T} \sigma_{ijvk} P_{ijvk} X_{ijvk} \quad (3.24)$$

s.a.

$$A_{iv} = A_{i-1,v} - \sum_{(i,j) \in OD} \sum_{j \geq i} \sum_{k \in K_v} \sum_{t \in T} X_{i-1,j,v,k,t} + \sum_{(i,j) \in OD} \sum_{j < i} \sum_{k \in K_v} \sum_{t \in T} X_{jivkt}, \quad \forall i \in O, v \in V \quad (3.2)$$

$$Y_{ijvk} \geq \sum_{t \in T} X_{ijvkt}, \quad k = \max\{K_v\}, \forall (i, j) \in OD, v \in V \quad (3.3)$$

$$Y_{ijvk} \geq \sum_{t \in T} X_{ijvkt} + Y_{i,j,v,k+1}, \quad \forall (i, j) \in OD, v \in V, k \in K_v / k < |K_v| \quad (3.4)$$

$$\sum_{(i,j) \in OD} Y_{ijvk} \leq A_{iv}, \quad k = \min\{K_v\}, \forall i \in O / (i, j) \in OD, \forall v \in V \quad (3.5)$$

$$A_{0,v} = Q_v \quad \forall v \in V \quad (3.7)$$

$$X_{0,j,v,k,t} = 0 \quad \forall j \in D, v \in V, k \in K_v, t \in T \quad (3.8)$$

$$X_{ijvkt} \in \mathbb{Z}^+ \quad \forall (i, j) \in OD, v \in V, k \in K_v, t \in T \quad (3.9)$$

$$Y_{ijvk} \in \mathbb{Z}^+ \quad \forall (i, j) \in OD, v \in V, k \in K_v \quad (3.10)$$

$$A_{iv} \in \mathbb{Z}^+ \quad \forall i \in O, v \in V \quad (3.11)$$

Restrições da demanda comportamental

$$X_{ijvkt} \leq d'_{ijvkt}, \quad \forall (i, j) \in OD / i < j, v \in V, k \in K_v, t \in T \quad (3.25)$$

$$\sum_{k' \in K_v / k' \leq k} X_{i,j,v,k',t} \leq d'_{ijvkt} \quad \forall (i, j) \in OD, v \in V, k \in K_v / k > 1, t \in T \quad (3.26)$$

Restrições de ajuste da demanda

$$\alpha_{ijvkt} + \sum_{k' \in K_v / k' > k} \alpha_{i,j,v,k',t} \leq 1 + M(1 - \delta_{ijvkt}), \quad k = \min\{K_v\}, \forall (i, j) \in OD, v \in V, t \in T \quad (3.27)$$

$$\sigma_{ijvk} P_{ijvk} X_{ijvkt} + M(1 - \delta_{ijvkt}) \geq \sum_{k' \in K_v / k' > k} \sigma_{ijvk} P_{i,j,v,k'} X_{i,j,v,k',t}, \quad (3.28)$$

$$k = \min\{K_v\}, \forall (i, j) \in OD, v \in V, t \in T$$

$$\alpha_{ijvkt} \leq \delta_{ijvkt}, \quad k = \min\{K_v\}, \forall (i, j) \in OD, v \in V, t \in T \quad (3.29)$$

Bloco EI2

Restrições das variáveis binárias

$$\alpha_{ijvkt} \leq X_{ijvkt} \leq \alpha_{ijvkt} d_{ijvkt}, \quad \forall (i, j) \in OD, v \in V, k \in K_v, t \in T \quad (3.12)$$

$$\beta_{ijvkt} = \alpha_{ijvkt} - \alpha_{i,j,v,k+1,t}, \quad \forall (i, j) \in OD, v \in V, k \in K/k < \max\{K_v\}, t \in T \quad (3.13)$$

$$\beta_{ijvkt} = \alpha_{ijvkt}, \quad \forall (i, j) \in OD, v \in V, k = \max\{K_v\}, t \in T \quad (3.14)$$

Bloco EI3

Restrições *fulfillments over periods*

$$\alpha_{ijvkt} \leq \alpha_{i,j,v,k,t+1}, \quad \forall (i, j) \in OD, v \in V, k \in K_v, t \in T/t \neq \max\{T\} \quad (3.15)$$

$$\sum_{k \in K_v} \beta_{ijvkt} P_{ijvk} \geq \sum_{k \in K_v} \beta_{i,j,v,k,t+1} P_{ijvk}, \quad \forall (i, j) \in OD, v \in V, t \in T/t \neq \max\{T\} \quad (3.16)$$

Bloco EI4

Restrições *skip lagging*

$$\sum_{k \in K_v} \beta_{ijvkt} P_{ijvk} \leq \sum_{k \in K_v} \beta_{i,j',v,k,t} P_{ijvk}, \quad \forall i \in O, j \in D, j' \in D/j' > j, v \in V, t \in T \quad (3.17)$$

$$\sum_{k \in K_v} \beta_{odvkt} P_{odvk} \leq \sum_{(i,j) \in S} \sum_{k \in K_v} \beta_{ijvkt} P_{ijvk}, \quad \forall (o, d) \in NAD, \quad (3.18)$$

$$v \in V, t \in T, \quad \forall S \in CR_{o,d}/S \subset CR_{o,d}$$

Inicialmente, deve-se notar que os três últimos blocos deste abordagem (EI2, EI3, EI4) são exatamente os mesmos utilizados no primeiro, de modo que, nesta parte, apenas algumas restrições foram modificadas e incorporadas ao modelo base, as quais serão explicadas a seguir.

Em primeiro lugar, destaca-se a função objetivo (3.24), que agora considera a probabilidade de chegada de um passageiro a cada classe de controle, em função do trecho, do tipo de assento e do período de reserva. Essa probabilidade foi estimada com base em simulação de Monte Carlo e considerada da seguinte forma: para cada instância, o modelo foi executado 1000 vezes, sendo o valor de σ variado aleatoriamente em cada execução. Ao final das rodadas, calculou-se a média dos valores obtidos da função objetivo em todas as simulações. É importante ressaltar que a quantidade de simulações foi definida pelo autor a partir da suposição de que esse número seria suficiente para representar adequadamente o comportamento do sistema por meio da simulação.

Na sequência, observa-se que as restrições (3.25) estão limitando a quantidade de assentos reservados, garantindo que estes não ultrapassem o valor da demanda comportamental. Já as restrições (3.26) correspondem à generalização da situação descrita anteriormente nas restrições (3.22) e (3.23).

É importante notar que, ao se adicionar as restrições (3.25) e (3.26), e eliminar a restrição (3.6) do modelo básico independente, obtém-se, em teoria, um modelo com demanda comportamental (como se observa no Bloco EC1). No entanto, essa afirmação não é totalmente verdadeira. Embora as novas restrições limitem a demanda do modelo de maneira que seja possível utilizar as listas de preferência, o modelo ainda se comportará como um modelo independente.

Isso ocorre porque a demanda independente é um caso particular de todas as combinações possíveis que podem ser geradas ao usar as listas de preferência. De fato, a demanda independente é o caso que geraria a maior receita possível entre todas essas combinações. Vale lembrar que as listas de preferência oferecem a flexibilidade de permitir que um cliente disposto a pagar mais caro adquira um produto a um preço mais barato, caso essa possibilidade exista.

Portanto, torna-se necessário indicar ao modelo que ele deve considerar outras possibilidades mais realistas durante a resolução do problema. Para isso, as restrições (3.27), (3.28) e (3.29) atuam de maneira integrada para realizar o ajuste necessário. Esse ajuste consiste em identificar a classe mais cara e verificar se seu preço é superior à soma dos preços das classes mais baratas. Se a condição for verdadeira, as classes mais baratas serão desabilitadas, e apenas a classe mais cara será mantida. Caso contrário, o modelo permanecerá livre para selecionar a opção mais vantajosa, de acordo com as condições estabelecidas.

Em síntese, a partir do exposto, destaca-se que o modelo `Basic_Comporta_Est` corresponde ao conjunto de restrições apenas do Bloco EC1; o modelo `Fulfill_Comporta_Est` resulta da união dos Blocos EC1, EI2 e EI3; o modelo `Skipla_Comporta_Est` é formado pela integração dos Blocos EC1, EI2 e EI4; e, por fim, o modelo completo `Comp_Comporta_Est` contempla a totalidade das restrições, abrangendo os Blocos EC1, EI2, EI3 e EI4.

3.4.3 Terceira abordagem: modelos com autorizações dinâmicas e demanda independente

As autorizações dinâmicas são um tipo de política utilizada na gestão de capacidade e alocação de recursos, na qual o valor das autorizações varia ao longo do tempo, de acordo com o período específico dentro do horizonte de reservas. Diferentemente das autorizações estáticas, onde os recursos (por exemplo, os assentos de um trem ou avião) são alocados de maneira fixa para todo o horizonte de reserva, as autorizações dinâmicas permitem ajustar a quantidade de recursos disponíveis em cada período, levando em consideração a demanda e outras condições variáveis. Esse enfoque permite maior flexibilidade e adaptabilidade no planejamento e na alocação de recursos, otimizando a utilização da capacidade com base na evolução da demanda ao longo do tempo.

Para esta seção, toma-se como referência a abordagem estática com demanda independente, diferenciando-se, porém, pelo fato de que a variável de decisão de autorizações passa a ser indexada no tempo, além da inclusão de uma nova variável de decisão, conforme apresentado a seguir.

Variáveis de decisão:

Y_{ijvkt} : Quantidade de passagens autorizadas no trecho (i, j) , tipo de assento v , com classe de controle k no período t , onde $(i, j) \in OD, v \in V, k \in K_v, t \in T$.

γ_{ijvkt} : É uma variável binária que toma o valor de 1 quando $Y_{ijvkt} \neq 0$ e toma valor de 0 caso contrário, onde $(i, j) \in OD, v \in V, k \in K_v, t \in T$.

Assim, a classificação dos modelos desta abordagem por blocos pode ser apresentada da seguinte forma:

Bloco DI1

Modelo básico

$$\text{Max } Z = \sum_{(i,j) \in OD} \sum_{v \in V} \sum_{k \in K_v} \sum_{t \in T} P_{ijvk} X_{ijvkt} \quad (3.1)$$

s.a.

$$A_{iv} = A_{i-1,v} - \sum_{(i,j) \in OD/j \geq i} \sum_{k \in K_v} \sum_{t \in T} X_{i-1,j,v,k,t} + \sum_{(i,j) \in OD/j < i} \sum_{k \in K_v} \sum_{t \in T} X_{jivkt}, \quad \forall i \in O, v \in V \quad (3.2)$$

$$Y_{ijvkt} \geq X_{ijvkt}, \quad k = \max\{K_v\}, \forall (i, j) \in OD, v \in V, t \in T \quad (3.30)$$

$$Y_{ijvkt} \geq X_{ijvkt} + Y_{i,j,v,k+1,t}, \quad \forall (i, j) \in OD, v \in V, k \in K_v/k < |K_v|, t \in T \quad (3.31)$$

$$\sum_{(i,j) \in OD} \sum_{t \in T} Y_{ijvkt} \leq A_v, \quad k = \min\{K_v\}, \forall i \in O/(i, j) \in OD, \forall v \in V \quad (3.32)$$

$$X_{ijvkt} \leq d_{ijvkt}, \quad \forall (i, j) \in OD/i < j, v \in V, k \in K_v, t \in T \quad (3.6)$$

$$A_{0,v} = Q_v \quad \forall v \in V \quad (3.7)$$

$$X_{0,j,v,k,t} = 0 \quad \forall j \in D, v \in V, k \in K_v, t \in T \quad (3.8)$$

$$X_{ijvkt} \in \mathbb{Z}^+ \quad \forall (i, j) \in OD, v \in V, k \in K_v, t \in T \quad (3.9)$$

$$Y_{ijvkt} \in \mathbb{Z}^+ \quad \forall (i, j) \in OD, v \in V, k \in K_v, t \in T \quad (3.33)$$

$$A_{iv} \in \mathbb{Z}^+ \quad \forall i \in O, v \in V \quad (3.11)$$

Bloco DI2

Restrições das variáveis binárias

$$\alpha_{ijvkt} \leq X_{ijvkt} \leq \alpha_{ijvkt} d_{ijvkt}, \quad \forall (i, j) \in OD, v \in V, k \in K_v, t \in T \quad (3.12)$$

$$\beta_{ijvkt} = \gamma_{ijvkt} - \gamma_{i,j,v,k+1,t}, \quad \forall (i, j) \in OD, v \in V, k \in K/k < \max\{K_v\}, t \in T \quad (3.34)$$

$$\beta_{ijvkt} = \gamma_{ijvkt}, \quad \forall (i, j) \in OD, v \in V, k = \max\{K_v\}, t \in T \quad (3.35)$$

Bloco EI3

Restrições *fulfillments over periods*

$$\alpha_{ijvkt} \leq \alpha_{i,j,v,k,t+1}, \quad \forall (i, j) \in OD, v \in V, k \in K_v, t \in T/t \neq \max\{T\} \quad (3.15)$$

$$\sum_{k \in K_v} \beta_{ijvkt} P_{ijvk} \geq \sum_{k \in K_v} \beta_{i,j,v,k,t+1} P_{ijvk}, \quad \forall (i, j) \in OD, v \in V, t \in T/t \neq \max\{T\} \quad (3.16)$$

Bloco EI4

Restrições *skip lagging*

$$\sum_{k \in K_v} \beta_{ijvkt} P_{ijvk} \leq \sum_{k \in K_v} \beta_{i,j',v,k,t} P_{ijvk}, \quad \forall i \in O, j \in D, j' \in D/j' > j, v \in V, t \in T \quad (3.17)$$

$$\sum_{k \in K_v} \beta_{odvkt} P_{odvk} \leq \sum_{(i,j) \in S} \sum_{k \in K_v} \beta_{ijvkt} P_{ijvk}, \quad \forall (o,d) \in NAD, \quad (3.18)$$

$$v \in V, t \in T, \quad \forall S \in CR_{o,d}/S \subset CR_{o,d}$$

No Bloco [DI1](#), verifica-se que as restrições que anteriormente vinculavam a variável de autorizações (3.3), (3.4) e (3.5) foram substituídas pelas restrições (3.30), (3.31) e (3.32), respectivamente. Essas novas restrições preservam a lógica de aninhamento (*nesting*), mas passam a ser aplicadas em cada período específico, em vez de considerar o horizonte de reservas de forma geral.

Em complemento a essa modificação estrutural, observa-se também que o valor de β passa a ser determinado em função de γ e não de α (restrições (3.34) e (3.35) no Bloco [DI2](#)). Essa alteração faz com que β se refira à classe mais barata disponibilizada para venda, em substituição à classe mais barata reservada. Tal mudança configura uma das diferenças mais relevantes desta abordagem em relação à abordagem estática.

Dito o exposto, o modelo `Basic_Independ_Din` é composto apenas pelo Bloco [DI1](#); o modelo `Fulfill_Independ_Din` é formado pelos Blocos [DI1](#), [DI2](#) e [EI3](#); o modelo `Skipla_Independ_Din` é constituído pelos Blocos [DI1](#), [DI2](#) e [EI4](#); e, por fim, o modelo `Comp_Independ_Din` integra todos os blocos [DI1](#), [DI2](#), [EI3](#) e [EI4](#).

3.4.4 Quarta abordagem: modelos com autorizações dinâmicas e demanda comportamental

Esta seção utilizará os mesmos ajustes realizados na seção anterior, mas com a demanda comportamental.

Bloco DC1

Modelo básico

$$\text{Max } Z = \sum_{(i,j) \in OD} \sum_{v \in V} \sum_{k \in K_v} \sum_{t \in T} \sigma_{ijvk} P_{ijvk} X_{ijvkt} \quad (3.24)$$

s.a.

$$A_{iv} = A_{i-1,v} - \sum_{(i,j) \in OD} \sum_{j \geq i} \sum_{k \in K_v} \sum_{t \in T} X_{i-1,j,v,k,t} + \sum_{(i,j) \in OD} \sum_{j < i} \sum_{k \in K_v} \sum_{t \in T} X_{jivkt}, \quad \forall i \in O, v \in V \quad (3.2)$$

$$Y_{ijvkt} \geq X_{ijvkt}, \quad k = \max\{K_v\}, \forall (i,j) \in OD, v \in V, t \in T \quad (3.30)$$

$$Y_{ijvkt} \geq X_{ijvkt} + Y_{i,j,v,k+1,t}, \quad \forall (i,j) \in OD, v \in V, k \in K_v/k < |K_v|, t \in T \quad (3.31)$$

$$\sum_{(i,j) \in OD} \sum_{t \in T} Y_{i,j,v,k,t} \leq A_v, \quad k = \min\{K_v\}, \forall i \in O/(i,j) \in OD, \forall v \in V \quad (3.32)$$

$$A_{0,v} = Q_v \quad \forall v \in V \quad (3.7)$$

$$X_{0,j,v,k,t} = 0 \quad \forall j \in D, v \in V, k \in K_v, t \in T \quad (3.8)$$

$$X_{ijvkt} \in \mathbb{Z}^+ \quad \forall (i,j) \in OD, v \in V, k \in K_v, t \in T \quad (3.9)$$

$$Y_{ijvkt} \in \mathbb{Z}^+ \quad \forall (i,j) \in OD, v \in V, k \in K_v, t \in T \quad (3.33)$$

$$A_{iv} \in \mathbb{Z}^+ \quad \forall i \in O, v \in V \quad (3.11)$$

Restrições da demanda comportamental

$$X_{ijvkt} \leq d'_{ijvkt}, \quad \forall (i,j) \in OD/i < j, v \in V, k \in K_v, t \in T \quad (3.25)$$

$$\sum_{k' \in K_v/k' \leq k} X_{i,j,v,k',t} \leq d'_{ijvkt} \quad \forall (i,j) \in OD, v \in V, k \in K_v/k > 1, t \in T \quad (3.26)$$

Restrições de ajuste da demanda

$$\alpha_{ijvkt} + \sum_{k' \in K_v/k' > k} \alpha_{i,j,v,k',t} \leq 1 + M(1 - \delta_{ijvkt}), \quad k = \min\{K_v\}, \forall (i,j) \in OD, v \in V, t \in T \quad (3.27)$$

$$\sigma_{ijvk} P_{ijvk} X_{ijvkt} + M(1 - \delta_{ijvkt}) \geq \sum_{k' \in K_v/k' > k} \sigma_{ijvk} P_{i,j,v,k'} X_{i,j,v,k',t}, \quad (3.28)$$

$$k = \min\{K_v\}, \forall (i,j) \in OD, v \in V, t \in T$$

$$\alpha_{ijvkt} \leq \delta_{ijvkt}, \quad k = \min\{K_v\}, \forall (i,j) \in OD, v \in V, t \in T \quad (3.29)$$

Bloco DI2

Restrições das variáveis binárias

$$\alpha_{ijvkt} \leq X_{ijvkt} \leq \alpha_{ijvkt} d_{ijvkt}, \quad \forall (i,j) \in OD, v \in V, k \in K_v, t \in T \quad (3.12)$$

$$\beta_{ijvkt} = \gamma_{ijvkt} - \gamma_{i,j,v,k+1,t}, \quad \forall (i,j) \in OD, v \in V, k \in K/k < \max\{K_v\}, t \in T \quad (3.34)$$

$$\beta_{ijvkt} = \gamma_{ijvkt}, \quad \forall (i,j) \in OD, v \in V, k = \max\{K_v\}, t \in T \quad (3.35)$$

Bloco EI3

Restrições *fulfillments over periods*

$$\alpha_{ijvkt} \leq \alpha_{i,j,v,k,t+1}, \quad \forall (i,j) \in OD, v \in V, k \in K_v, t \in T/t \neq \max\{T\} \quad (3.15)$$

$$\sum_{k \in K_v} \beta_{ijvkt} P_{ijvk} \geq \sum_{k \in K_v} \beta_{i,j,v,k,t+1} P_{ijvk}, \quad \forall (i,j) \in OD, v \in V, t \in T/t \neq \max\{T\} \quad (3.16)$$

Bloco EI4

Restrições *skip lagging*

$$\sum_{k \in K_v} \beta_{ijvkt} P_{ijvk} \leq \sum_{k \in K_v} \beta_{i,j',v,k,t} P_{ijvk}, \quad \forall i \in O, j \in D, j' \in D/j' > j, v \in V, t \in T \quad (3.17)$$

$$\sum_{k \in K_v} \beta_{odvkt} P_{odvk} \leq \sum_{(i,j) \in S} \sum_{k \in K_v} \beta_{ijvkt} P_{ijvk}, \quad \forall (o,d) \in NAD, \quad (3.18)$$

$$v \in V, t \in T, \quad \forall S \in CR_{o,d}/S \subset CR_{o,d}$$

Dessa maneira, o modelo Basic_Comporta_Din é composto apenas pelo Bloco DC1; o modelo Fulfill_Comporta_Din é formado pelos Blocos DC1, DI2 e EI3; de forma análoga o modelo Skipla_Comporta_Din é constituído pelos Blocos DC1, DI2 e EI4; e, por fim, o modelo Comp_Comporta_Din abrange todos os blocos DC1, DI2, EI3 e EI4.

CAPÍTULO 4

Análise e resultados computacionais

Após a realização dos experimentos, todas as informações foram consolidadas para permitir as devidas análises, compreender os resultados e avaliar o desempenho de cada modelo na busca pela solução. Foram avaliados aspectos como a demanda atendida, o tempo de execução e criação dos modelos, a quantidade de nós explorados e a unimodalidade da matriz de coeficientes das restrições.

4.1 Instâncias

Para verificar as características dos modelos propostos, foram utilizadas 10 instâncias reais fornecidas por uma empresa canadense parceira. As características de cada uma dessas instâncias estão apresentadas na Tabela [4.1](#).

A coluna "# Trechos" representa a quantidade de trechos que a viagem do trem possui em cada instância. A coluna "# Períodos" indica a quantidade de períodos considerados na programação desse trajeto dentro do seu horizonte de reserva. Por fim, a coluna "# Classes" mostra o número máximo de classes disponíveis para cada viagem de cada trem; Observe que, para cada trecho, podem estar disponíveis todas as classes indicadas na coluna correspondente

Instância	Nome Trem	Capacidade Trem	Data Partida	# Trechos	# Períodos	# Classes
Inst1	68	561	2023-11-21	256	120	15
Inst2	13	637	2023-11-26	252	146	15
Inst3	71	563	2023-10-13	250	105	16
Inst4	71	561	2023-11-21	241	124	15
Inst5	8	561	2022-12-04	152	116	17
Inst6	40	565	2023-11-21	149	68	16
Inst7	74	491	2023-07-25	136	70	16
Inst8	72	493	2023-10-25	100	85	16
Inst9	45	563	2023-03-16	90	73	16
Inst10	15	493	2023-08-07	50	60	12

Tabela 4.1: Resumo das instâncias utilizadas no experimento

ou uma quantidade menor.

Por outro lado, estabeleceu-se que as instâncias compreendidas entre a instância Inst1 e a instância Inst4 foram classificadas como grandes, as instâncias entre a instância Inst5 e a instância Inst7 como médias, e as demais foram classificadas como pequenas.

4.2 Ferramentas e ambiente computacional

O experimento foi conduzido em um computador ASUS, com sistema operacional Windows 11 Pro de 64 bits. O equipamento conta com um processador Intel(R) Core(TM) i9-13900KF (32 CPUs) de 13ª geração, com frequência de 3.0 GHz e arquitetura x64 e 128 GB de memória RAM.

Para o desenvolvimento e execução do experimento, foi utilizada a linguagem de programação Python na versão 3.12.7, juntamente com o solver Gurobi, versão 12.0.2.

4.3 Análise por abordagem

Nesta seção, analisam-se os diferentes enfoques descritos na metodologia (ver Tabela 3.1). Parte-se do modelo básico e, em seguida, acresce-se isoladamente o conjunto de restrições de *fulfillment* e o de *skip-lagging*; finalmente, consolida-se a versão completa com ambos os conjuntos de restrições. Esse mesmo procedimento é aplicado a todas as instâncias consideradas, permitindo analisar o impacto de cada componente sobre o desempenho de cada abordagem.

Nas Tabelas 4.2 a 4.5, são apresentados os resultados ótimos encontrados e suas respectivas variações relativas em relação aos modelos básicos, para cada modelo, em cada instância e em cada abordagem. Em cada tabela, as linhas representam as instâncias analisadas, enquanto as colunas correspondem aos modelos considerados.

Instância	Basic_	Fulfill_	Skipla_	Comp_	Fulfill_	Skipla_	Comp_
	Independ_Est	Independ_Est	Independ_Est	Independ_Est	Independ_Est	Independ_Est	Independ_Est
Inst1	170.484,85	69.615,76	133.236,75	45.618,26	-59,17	-21,85	-73,24
Inst2	314.883,03	276.888,38	303.634,13	192.405,53	-12,07	-3,57	-38,90
Inst3	141.121,96	102.020,87	95.625,49	36.501,03	-27,71	-32,24	-74,14
Inst4	166.118,29	64.075,21	130.810,41	38.573,12	-61,43	-21,25	-76,78
Inst5	127.847,39	93.042,29	95.981,84	19.226,71	-27,22	-24,92	-84,96
Inst6	67.715,07	35.491,02	51.708,29	23.458,32	-47,59	-23,64	-65,36
Inst7	48.719,71	41.178,51	20.996,45	8.649,95	-15,48	-56,90	-82,25
Inst8	53.844,31	34.476,59	28.675,46	13.788,90	-35,97	-46,74	-74,39
Inst9	55.282,08	32.170,53	32.609,11	9.715,04	-41,81	-41,01	-82,43
Inst10	21.548,62	12.188,66	13.102,66	3.372,46	-43,44	-39,19	-84,35

(a) Z* (\$)

(b) Variação das diferenças no Z* (%)

Tabela 4.2: Valores ótimos e variações em função do modelo Basic_Independ_Est para a abordagem de demanda independente com autorizações estáticas.

Instância	Basic_	Fulfill_	Skipla_	Comp_	Fulfill_	Skipla_	Comp_
	Comporta_Est	Comporta_Est	Comporta_Est	Comporta_Est	Comporta_Est	Comporta_Est	Comporta_Est
Inst1	166.210,42	67.437,39	128.329,40	44.421,86	-59,43	-22,79	-73,27
Inst2	312.778,79	276.854,70	301.334,80	192.405,53	-11,49	-3,66	-38,49
Inst3	134.046,41	96.171,04	90.800,12	36.278,57	-28,26	-32,26	-72,94
Inst4	162.415,46	62.373,53	127.795,15	38.457,27	-61,60	-21,32	-76,32
Inst5	123.795,24	90.664,68	90.262,21	18.959,99	-26,76	-27,09	-84,68
Inst6	64.816,45	33.670,68	48.627,58	22.362,62	-48,05	-24,98	-65,50
Inst7	36.643,80	24.149,73	17.668,88	7.962,69	-34,10	-51,78	-78,27
Inst8	43.172,74	23.992,24	23.207,98	10.888,16	-44,43	-46,24	-74,78
Inst9	47.796,57	25.866,57	27.209,34	9.569,26	-45,88	-43,07	-79,98
Inst10	18.945,34	6.174,09	11.248,64	3.042,05	-67,41	-40,63	-83,94

(a) Z* (\$)

(b) Variação das diferenças no Z* (%)

Tabela 4.3: Valores ótimos e variações em função do modelo Basic_Comporta_Est para a abordagem de demanda comportamental com autorizações estáticas.

Instância	Basic_	Fulfill_	Skipla_	Comp_	Fulfill_	Skipla_	Comp_
	Independ_Din	Independ_Din	Independ_Din	Independ_Din	Independ_Din	Independ_Din	Independ_Din
Inst1	170.484,85	82.536,11	133.236,75	51.409,96	-51,59	-21,85	-69,84
Inst2	314.883,03	285.695,28	303.634,13	203.208,98	-9,27	-3,57	-35,47
Inst3	140.788,61	103.947,42	95.625,49	37.214,03	-26,17	-32,08	-73,57
Inst4	166.118,29	79.065,35	130.810,41	40.602,31	-52,40	-21,25	-75,56
Inst5	127.371,39	93.343,29	95.981,84	28.628,14	-26,72	-24,64	-77,52
Inst6	67.715,07	42.175,87	51.708,29	24.722,37	-37,72	-23,64	-63,49
Inst7	48.719,71	41.481,51	20.996,45	9.382,95	-14,86	-56,90	-80,74
Inst8	53.844,31	34.753,59	28.675,46	13.985,90	-35,46	-46,74	-74,03
Inst9	55.282,08	33.942,53	32.609,11	10.029,04	-38,60	-41,01	-81,86
Inst10	21.548,62	12.525,66	13.102,66	3.637,46	-41,87	-39,19	-83,12

(a) Z* (\$)

(b) Variação das diferenças no Z* (%)

Tabela 4.4: Valores ótimos e variações em função do modelo Basic_Independ_Din para a abordagem de demanda independente com autorizações dinâmicas.

Instância	Basic_	Fulfill_	Skipla_	Comp_	Fulfill_	Skipla_	Comp_
	Comporta_Din	Comporta_Din	Comporta_Din	Comporta_Din	Comporta_Din	Comporta_Din	Comporta_Din
Inst1	166.209,42	80.966,16	129.950,27	50.857,49	-51,29	-21,82	-69,40
Inst2	312.770,91	284.781,34	302.064,54	203.219,44	-8,95	-3,42	-35,03
Inst3	133.706,86	100.397,12	92.614,95	36.763,69	-24,91	-30,73	-72,50
Inst4	162.402,95	76.947,77	128.595,17	40.465,13	-52,62	-20,82	-75,08
Inst5	123.370,78	91.665,19	92.362,85	28.413,68	-25,70	-25,13	-76,97
Inst6	64.808,07	40.486,69	50.055,05	23.970,25	-37,53	-22,76	-63,01
Inst7	36.647,28	30.655,67	18.991,14	8.672,76	-16,35	-48,18	-76,33
Inst8	43.116,46	26.348,72	25.052,38	11.543,90	-38,89	-41,90	-73,23
Inst9	47.779,63	28.708,04	29.558,14	9.857,24	-39,92	-38,14	-79,37
Inst10	18.932,83	10.307,76	11.897,58	3.245,57	-45,56	-37,16	-82,86

(a) Z* (\$)

(b) Variação das diferenças no Z* (%)

Tabela 4.5: Valores ótimos e variações em função do modelo Basic_Comporta_Din para a abordagem de demanda comportamental com autorizações estáticas.

Cumprir destacar que cada um dos modelos apresentados nas tabelas anteriores resulta da combinação entre as abordagens baseadas em tipos de demanda e tipos de autorizações. Em cada tabela são reportados, na parte (a), os valores ótimos obtidos para os modelos estáticos, bem como as médias dos 1000 valores ótimos provenientes das simulações do enfoque com demanda comportamental. Na parte (b), apresentam-se as variações percentuais em relação ao modelo básico correspondente a cada instância. Observa-se que todas as variações percentuais na parte (b) assumem valores negativos, indicando que, em comparação à versão básica, houve uma redução no valor do *revenue*.

Assim, a partir dos resultados apresentados nas tabelas anteriores, foi possível perceber que os modelos básicos de todas as abordagens apresentaram a maior receita em comparação com os modelos que incluem os conjuntos de restrições de *skip lagging* e *fulfillment over periods*. A diferença é ainda mais evidente quando comparados com o modelo completo. Essa situação era esperada, uma vez que os modelos básicos têm mais liberdade no espaço de busca, permitindo a obtenção de soluções mais globais, ao não considerar os outros conjuntos mencionados. Além disso, de todos os abordagens, também se observa que, em média, o conjunto de *fulfillment* tem maior impacto na solução em comparação com o conjunto de *skip lagging*, mostrando, de fato, que suas restrições são mais sensíveis ao problema. Ao final, o modelo completo obteve resultados significativamente inferiores aos do modelo básico; no entanto, esse é o custo de se considerar ambos os conjuntos de restrições simultaneamente.

4.4 Comparação entre modelos

Nesta seção, realiza-se uma análise comparativa entre todas as abordagens propostas, classificadas segundo suas respectivas categorias — básicas, *fulfillment*, *skip lagging* e completas — com o objetivo de avaliar o desempenho dos modelos em diferentes contextos operacionais. Por exemplo, realiza-se uma comparação entre todos os modelos básicos, entre todos os modelos completos, e assim por diante para todas as categorias. Isso foi feito dessa forma, pois não é equivalente comparar um modelo de uma categoria com outro de categoria diferente. Por exemplo, não seria apropriado comparar um modelo básico com um modelo completo, já que eles estão resolvendo situações relativamente distintas.

Na Tabela 4.6, as abordagens são organizadas por grupos de linhas conforme suas categorias, enquanto as colunas representam as diferentes instâncias analisadas. São apresentados os valores ótimos obtidos para cada combinação.

Nome Modelo	Inst1	Inst2	Inst3	Inst4	Inst5	Inst6	Inst7	Inst8	Inst9	Inst10
Basic_Independ_Est	170.484,85	314.883,03	141.121,96	166.118,29	127.847,39	67.715,07	48.719,71	53.844,31	55.282,08	21.548,62
Basic_Comporta_Est	166.210,42	312.778,79	134.046,41	162.415,46	123.795,24	64.816,45	36.643,80	43.172,74	47.796,57	18.945,34
Basic_Independ_Din	170.484,85	314.883,03	140.788,61	166.118,29	127.371,39	67.715,07	48.719,71	53.844,31	55.282,08	21.548,62
Basic_Comporta_Din	166.209,42	312.770,91	133.706,86	162.402,95	123.370,78	64.808,07	36.647,28	43.116,46	47.779,63	18.932,83
Fulfill_Independ_Est	69.615,76	276.888,38	102.020,87	64.075,21	93.042,29	35.491,02	41.178,51	34.476,59	32.170,53	12.188,66
Fulfill_Comporta_Est	67.437,39	276.854,70	96.171,04	62.373,53	90.664,68	33.670,68	24.149,73	23.992,24	25.866,57	6.174,09
Fulfill_Independ_Din	82.536,11	285.695,28	103.947,42	79.065,35	93.343,29	42.175,87	41.481,51	34.753,59	33.942,53	12.525,66
Fulfill_Comporta_Din	80.966,16	284.781,34	100.397,12	76.947,77	91.665,19	40.486,69	30.655,67	26.348,72	28.708,04	10.307,76
Skipla_Independ_Est	133.236,75	303.634,13	95.625,49	130.810,41	95.981,84	51.708,29	20.996,45	28.675,46	32.609,11	13.102,66
Skipla_Comporta_Est	128.329,40	301.334,80	90.800,12	127.795,15	90.262,21	48.627,58	17.668,88	23.207,98	27.209,34	11.248,64
Skipla_Independ_Din	133.236,75	303.634,13	95.625,49	130.810,41	95.981,84	51.708,29	20.996,45	28.675,46	32.609,11	13.102,66
Skipla_Comporta_Din	129.950,27	302.064,54	92.614,95	128.595,17	92.362,85	50.055,05	18.991,14	25.052,38	29.558,14	11.897,58
Comp_Independ_Est	45.618,26	192.405,53	36.501,03	38.573,12	19.226,71	23.458,32	8.649,95	13.788,90	9.715,04	3.372,46
Comp_Comporta_Est	44.421,86	192.405,53	36.278,57	38.457,27	18.959,99	22.362,62	7.962,69	10.888,16	9.569,26	3.042,05
Comp_Independ_Din	51.409,96	203.208,98	37.214,03	40.602,31	28.628,14	24.722,37	9.382,95	13.985,90	10.029,04	3.637,46
Comp_Comporta_Din	50.857,49	203.219,44	36.763,69	40.465,13	28.413,68	23.970,25	8.672,76	11.543,90	9.857,24	3.245,57

Tabela 4.6: Resultados ótimos de cada modelo para cada instância

De acordo com a Tabela 4.6, pode-se observar o seguinte:

1. Os modelos básicos, tanto para a abordagem de demanda independente quanto para a abordagem de demanda comportamental, apresentaram os melhores resultados em todas as instâncias analisadas. Isso se deve ao fato de que esses modelos não consideram as restrições de *skip lagging* e *fulfillment over periods*, o que lhes confere maior liberdade na busca por soluções.
2. Observa-se que os modelos Basic_Independ_Est e Basic_Independ_Din apresentaram receitas idênticas na maior parte das instâncias analisadas, com exceção das instân-

cias Inst3 e Inst5, nas quais foram observados valores distintos, embora com variação reduzida. De forma inesperada, comportamento análogo foi identificado nos modelos Skipla_Independ_Est e Skipla_Independ_Din; neste caso, ambos os modelos obtiveram exatamente os mesmos valores em todas as instâncias.

3. De maneira geral, os modelos dinâmicos apresentaram valores iguais ou superiores na receita em comparação com os modelos estáticos, isso para cada categoria e instância.
4. Pode-se perceber que as variações entre os modelos do mesmo tipo de autorizações apresentam variações relativamente baixas.

Para ilustrar os itens 3 e 4, foi selecionada a instância Inst1, utilizando os modelos da categoria completa. A Tabela 4.7 apresenta as variações percentuais entre cada par de modelos, sendo os valores dos modelos indicados na primeira coluna utilizados como base de comparação. Observa-se que, ao comparar os modelos com autorizações estáticas aos modelos com autorizações dinâmicas, estes últimos registram um aumento de receita entre 11,48% e 15,73%. Essa diferença está diretamente relacionada ao tipo de política de autorização adotada, indicando que a flexibilidade das autorizações dinâmicas tende a melhorar o desempenho econômico do modelo.

	Comp_ Independ_Est	Comp_ Comporta_Est	Comp_ Independ_Din	Comp_ Comporta_Din
Comp_Independ_Est	0,00 %	-2,62 %	12,70 %	11,48 %
Comp_Comporta_Est	2,69 %	0,00 %	15,73 %	14,49 %
Comp_Independ_Din	-11,27 %	-13,59 %	0,00 %	-1,07 %
Comp_Comporta_Din	-10,30 %	-12,65 %	1,09 %	0,00 %

Tabela 4.7: Comparação das variações das diferenças dos modelos completos para a instância Inst1

No entanto, ao comparar modelos que compartilham o mesmo tipo de política de autorização — ou seja, ao confrontar os modelos com demanda independente com aqueles baseados em demanda comportamental, dentro do mesmo tipo de autorização —, observam-se variações em torno de 2,6% para os modelos com autorizações estáticas e aproximadamente 1,1% para os modelos com autorizações dinâmicas. Esses resultados indicam que as diferenças entre os

Trecho	Tipo de assento	Periodo	Quant. classes de controle
$E_1 - E_2$	Z	0	1
$E_1 - E_3$	Z	0	3
$E_2 - E_3$	P	1	5

Tabela 4.8: Exemplo de combinações

modelos com diferentes abordagens de demanda são relativamente pequenas quando a política de autorização é mantida constante.

Para compreender a situação anteriormente descrita, é necessário considerar as combinações específicas geradas em cada instância no momento da composição dos trechos, tipos de assento e períodos de reserva, bem como a quantidade total de classes resultantes dessas combinações. A Tabela 4.8 apresenta três combinações distintas e o respectivo número de classes em cada uma delas.

Note que, na Tabela 4.8 a primeira combinação apresenta apenas uma classe, enquanto a segunda e a terceira possuem três e cinco classes, respectivamente. Isso significa que, para a primeira combinação, não há diferença entre os modelos de demanda independente e comportamental, pois ambos têm apenas uma opção de classe. Por outro lado, nas combinações com mais de uma classe, as diferenças entre os modelos se tornam mais evidentes, pois se criam listas de preferência com mais de um possível valor de compra, no caso dos modelos comportamentais.

Dito isso, a Tabela 4.9 apresenta, para cada instância, a quantidade de combinações que possuem mais de uma classe de controle, o total de combinações e a respectiva proporção percentual entre elas.

Instância	Quant. Combinações > 1	Total Combinações	% Combinações > 1
Inst1	82	1.106	7,41 %
Inst2	31	1.368	2,27 %
Inst3	119	1.065	11,17 %
Inst4	69	990	6,97 %
Inst5	76	679	11,19 %
Inst6	44	488	9,02 %
Inst7	121	554	21,84 %
Inst8	107	526	20,34 %
Inst9	80	452	17,70 %
Inst10	70	290	24,14 %

Tabela 4.9: Quantidade de combinações, por instância, que possuem mais de 1 classe de controle

Dessa forma, com base nos dados apresentados na Tabela 4.9, é possível explicar as variações reduzidas observadas na comparação entre os modelos comportamentais e os modelos independentes, dentro de cada tipo de política de autorização. Os valores da tabela indicam que a maioria das combinações geradas possui apenas uma única classe de controle, o que resulta na formação de listas de preferência com uma única opção nos modelos comportamentais. Nesses casos, o comportamento do cliente é forçado a uma única opção de compra, o que torna os resultados equivalentes aos obtidos com os modelos independentes. Assim, as variações observadas decorrem apenas daquelas poucas combinações que apresentam múltiplas classes.

4.5 Quantidade de soluções

Uma característica interessante observada nos resultados da função objetivo foi a quantidade de soluções ótimas encontradas por cada modelo em cada uma das instâncias. Esse resultado indica que o problema em estudo admite múltiplas soluções ótimas, o que significa que existem diferentes formas de aproveitar a demanda, gerando combinações distintas de autorizações e reservas que, embora apresentem valores diferentes, conduzem ao mesmo valor da função objetivo. A Tabela 4.10 apresenta a quantidade de soluções ótimas obtidas por cada modelo em cada instância analisada. Tenha em conta que, naqueles modelos em que a demanda é comportamental, os valores apresentados correspondem à aproximação inteira da média das 1000

simulações.

Nome Modelo	Inst1	Inst2	Inst3	Inst4	Inst5	Inst6	Inst7	Inst8	Inst9	Inst10
Basic_Independ_Est	2	2	5	3	5	1	1	1	1	1
Basic_Comporta_Est	2	2	5	3	4	1	3	2	1	1
Basic_Independ_Din	2	2	5	2	3	1	1	1	1	1
Basic_Comporta_Din	2	2	5	2	3	1	3	2	1	1
Fulfill_Independ_Est	3	4	2	4	3	1	1	1	1	1
Fulfill_Comporta_Est	4	4	3	4	4	1	1	1	1	1
Fulfill_Independ_Din	2	2	3	2	2	1	1	1	1	1
Fulfill_Comporta_Din	3	3	7	3	3	1	5	1	5	5
Skipla_Independ_Est	3	3	3	3	3	1	1	1	1	1
Skipla_Comporta_Est	3	2	3	3	2	1	1	1	1	1
Skipla_Independ_Din	2	2	2	2	4	1	1	1	1	1
Skipla_Comporta_Din	3	3	4	3	4	4	2	5	3	6
Comp_Independ_Est	3	3	4	3	4	1	1	1	1	1
Comp_Comporta_Est	4	4	4	3	4	1	1	1	1	1
Comp_Independ_Din	4	2	3	3	3	1	1	1	1	1
Comp_Comporta_Din	5	2	3	4	4	1	2	3	1	4

Tabela 4.10: Quantidade de soluções ótimas para cada modelo e instância

De acordo com os resultados obtidos na Tabela 4.10, as múltiplas soluções não dependem do modelo em si, mas sim da instância. Observe que as instâncias de Inst1 a Inst5, ou seja, as instâncias de grande e médio porte, geram múltiplas soluções para todos os modelos, com uma média de 3 soluções por modelo e instância, embora as instâncias Inst5, Inst8 e Inst9 para o modelo Basic_Comporta_Din se afastem da média, apresentando valores de 8, 10 e 10, respectivamente. Por outro lado, as instâncias de Inst6 a Inst10 apresentam, em sua maioria, soluções únicas.

A existência de múltiplas soluções ótimas tratado neste estudo, não apenas evidencia a flexibilidade estrutural dos modelos, mas também oferece vantagens práticas significativas no contexto operacional.

Em primeiro lugar, ter diferentes soluções com o mesmo valor da função objetivo permite ao tomador de decisão selecionar, entre as alternativas ótimas, aquela que melhor se adapta a restrições não modeladas diretamente — como preferências comerciais, limitações operacionais específicas, políticas de atendimento ao cliente ou equilíbrio entre classes de assentos. Além disso, em cenários reais de planejamento de receitas, onde pequenas variações na demanda, nos custos ou nas preferências dos passageiros podem ocorrer com frequência, dispor de múltiplas

soluções ótimas proporciona maior robustez. Isso significa que o sistema pode se ajustar com mais facilidade a mudanças contextuais sem comprometer o desempenho econômico.

Por fim, do ponto de vista da simulação e da análise de sensibilidade, as múltiplas soluções ótimas permitem explorar diferentes cenários de alocação de classes ou de aproveitamento da demanda, contribuindo para o desenvolvimento de políticas mais resilientes e alinhadas às incertezas do ambiente de transporte ferroviário.

4.6 Métricas de Avaliação

As métricas utilizadas para avaliar a eficácia da metodologia incluem diversos aspectos essenciais para garantir a qualidade e a precisão dos modelos. Primeiramente, a demanda atendida foi analisada, verificando a capacidade dos modelos em atender à maior quantidade possível de necessidades dentro das restrições definidas. O tempo de execução e a criação dos modelos também foram considerados, a fim de avaliar a eficiência computacional e a complexidade na geração das soluções. Além disso, a quantidade de nós explorados foi mensurada para entender a profundidade da busca realizada pelos modelos. Por fim, a unimodalidade foi verificada como um critério para garantir que as soluções obtidas fossem obtidas em tempos relativamente curtos. Esses parâmetros permitiram uma avaliação abrangente da metodologia, garantindo a robustez dos resultados.

4.6.1 Demanda atendida

Nesta seção, apresenta-se o percentual de demanda atendida por cada modelo na resolução das diferentes instâncias do problema. Esse indicador foi calculado pela razão entre o número total de assentos efetivamente reservados ao longo de todo o horizonte de planejamento — considerando todos os trechos, tipos de assento e classes de controle — e a demanda potencial total associada a cada instância. É importante destacar que, nos modelos baseados em demanda comportamental, o número total de assentos efetivamente reservados corresponde à média das 1000 simulações realizadas. A demanda potencial total representa a quantidade máxima de passageiros que poderiam ser atendidos, sendo estimada com base na demanda independente,

sem levar em conta o tipo de modelo adotado. Essa definição está formalizada na Equação (4.1).

A Figura 4.1 apresenta, de forma consolidada, as proporções de demanda atendida para cada modelo e para cada instância, com base nos valores calculados segundo a equação mencionada.

$$\% Dem. Atendida = \frac{\sum_{(i,j) \in OD} \sum_{v \in V} \sum_{k \in K_v} \sum_{i \in T} X_{ijvkt}}{\sum_{(i,j) \in OD} \sum_{v \in V} \sum_{k \in K_v} \sum_{i \in T} d_{ijvkt}} * 100 \quad (4.1)$$

Nome Modelo	Inst1	Inst2	Inst3	Inst4	Inst5	Inst6	Inst7	Inst8	Inst9	Inst10
Basic_Independ_Est	99,25	99,95	91,12	98,60	95,06	98,55	95,07	98,30	96,60	93,49
Basic_Comporta_Est	99,93	99,95	91,29	99,04	94,99	98,84	99,15	99,27	97,01	96,22
Basic_Independ_Din	99,32	99,95	90,30	99,04	94,23	98,55	95,07	98,30	96,60	93,49
Basic_Comporta_Din	99,93	99,95	90,41	99,04	94,14	98,84	99,16	99,28	97,06	96,22
Fulfill_Independ_Est	46,97	75,48	60,58	37,03	65,27	53,18	71,38	51,65	48,22	53,78
Fulfill_Comporta_Est	43,71	75,48	55,10	35,86	61,59	51,01	50,52	40,75	41,58	31,09
Fulfill_Independ_Din	55,68	82,91	62,41	45,78	65,27	63,87	71,91	51,31	51,62	54,20
Fulfill_Comporta_Din	56,14	82,74	63,20	45,62	64,35	64,02	74,93	50,43	49,60	54,42
Skipla_Independ_Est	78,18	93,70	70,91	78,47	76,90	81,94	57,23	62,43	63,83	69,96
Skipla_Comporta_Est	75,12	92,63	63,79	76,41	72,72	77,75	52,41	58,12	57,03	63,87
Skipla_Independ_Din	78,04	93,70	70,40	77,88	76,74	81,21	56,39	61,86	63,68	67,02
Skipla_Comporta_Din	77,55	93,34	70,24	77,58	75,66	80,50	55,42	60,81	62,68	66,11
Comp_Independ_Est	23,25	48,45	20,21	18,15	16,82	32,66	23,17	16,23	17,31	18,07
Comp_Comporta_Est	21,55	48,45	19,84	18,07	16,49	31,50	22,33	15,66	17,00	17,23
Comp_Independ_Din	26,58	52,24	22,10	19,91	21,42	34,54	22,22	16,00	17,62	19,75
Comp_Comporta_Din	26,60	52,30	23,17	20,03	21,38	34,69	22,28	15,80	17,58	19,71

Figura 4.1: Porcentagem de demanda atendida (%)

Observe que os modelos que melhor aproveitam a demanda são os modelos básicos, enquanto os modelos completos são os que menos a aproveitam. Isso está em consonância com os resultados apresentados nas seções 4.3 e 4.4. De fato, essa é a explicação de por que os modelos básicos obtêm uma receita melhor em comparação com os demais modelos. Além disso, pode-se observar que os modelos com restrições de *skiplagging* aproveitam melhor a demanda em comparação com os modelos de *fulfillment over periods*, devido à mesma situação já mencionada. Adicionalmente, observa-se que, mesmo quando há modelos que apresentam o mesmo valor da função objetivo — como é o caso dos modelos *Skipla_Independ_Est* e *Skipla_Independ_Din* —, o percentual de aproveitamento da demanda não é necessariamente igual. Isso é coerente com o fato de que a maioria dos modelos admite múltiplas soluções ótimas, o que implica que, ainda que o valor da função objetivo seja idêntico, podem ocorrer

variações nos valores assumidos pelas variáveis de decisão.

4.6.2 Tempos de construção e de resolução

Nesta seção são apresentados: i) o tempo de construção do modelo, que corresponde ao tempo necessário para que o solver realize a leitura e o pré-processamento dos dados, defina as variáveis de decisão, formule as restrições, estabeleça a função objetivo e gere a estrutura interna do modelo; e ii) o tempo de resolução, que corresponde ao tempo utilizado pelo solver para inicializar o processo de solução, executar o pré-solver, identificar o tipo de problema, selecionar os algoritmos apropriados, explorar o espaço de soluções e verificar a otimalidade da solução encontrada.

Assim, a Figura 4.2 apresenta os tempos de construção utilizados por cada modelo em cada uma das instâncias analisadas, no caso dos modelos comportamentais, reporta-se a média dos tempos ao longo de 1.000 simulações. Nela, pode-se observar que os tempos de construção dependem de cada instância e não dos modelos propostos, isso pode ser verificado pela pouca variação que existe para cada instância. Para a instância Inst10, os tempos são mais curtos, em torno de 0,9 segundos, enquanto os tempos mais longos são observados para a instância Inst3, com uma média de 19,67 segundos.

Nome Modelo	Inst1	Inst2	Inst3	Inst4	Inst5	Inst6	Inst7	Inst8	Inst9	Inst10
Basic_Independ_Est	4,89	5,32	13,97	3,72	2,61	1,54	1,50	1,30	1,15	0,57
Basic_Comporta_Est	4,97	5,97	16,43	3,99	2,62	2,03	2,10	1,42	1,18	0,64
Basic_Independ_Din	4,71	5,97	14,85	3,90	2,77	1,50	1,57	1,40	1,21	0,65
Basic_Comporta_Din	5,18	6,59	16,65	4,16	2,77	2,14	2,22	1,45	1,23	0,64
Fulfill_Independ_Est	6,65	8,04	18,36	5,28	3,48	2,06	2,07	1,89	1,62	0,86
Fulfill_Comporta_Est	7,37	9,08	21,37	5,72	3,72	2,97	3,22	2,10	1,84	1,02
Fulfill_Independ_Din	6,90	8,54	18,97	5,46	3,64	2,08	2,22	2,02	1,75	0,92
Fulfill_Comporta_Din	7,59	9,70	21,56	5,93	3,85	3,03	3,40	2,24	1,94	1,05
Skipla_Independ_Est	6,48	7,28	19,20	4,79	6,05	1,72	1,92	1,66	1,48	0,72
Skipla_Comporta_Est	7,14	8,49	22,10	5,38	3,28	2,62	2,95	1,90	1,67	0,92
Skipla_Independ_Din	6,63	7,86	20,26	4,97	3,29	1,82	2,02	1,78	1,55	0,79
Skipla_Comporta_Din	7,36	9,10	22,36	5,59	3,54	2,68	3,07	2,00	1,72	0,87
Comp_Independ_Est	7,74	9,08	20,36	5,66	7,27	2,17	2,40	2,15	1,87	0,93
Comp_Comporta_Est	8,36	10,12	23,31	6,40	3,98	3,15	3,59	2,36	2,06	1,08
Comp_Independ_Din	7,57	9,61	21,36	6,15	3,97	2,23	2,50	2,27	1,93	1,03
Comp_Comporta_Din	8,57	10,74	23,56	6,59	4,06	3,31	3,75	2,45	2,11	1,10

Figura 4.2: Tempos de construção, em segundos, de cada modelo para cada instância

Por outro lado, a Figura 4.3 apresenta os tempos de resolução de cada modelo para cada uma das instâncias analisadas. Pode-se observar que os tempos são semelhantes, independentemente da instância e do modelo, sendo o tempo mais alto de 0,15 segundos e o mais baixo de 0,00 segundos. Ou seja, neste último caso, o modelo encontrou a solução ótima de forma instantânea, o que ocorreu para a instância mais pequena (Inst10).

Com base nos dois tipos de tempos anteriores, pode-se afirmar que todos os modelos são eficientes na hora de resolver qualquer tipo de instância, seja de pequeno ou grande porte. Esse aspecto assume importância fundamental no contexto industrial, considerando que, na prática, é necessário resolver centenas de viagens associadas a múltiplos trens. Diante disso, a utilização eficiente do tempo computacional torna-se um requisito crucial para a viabilidade operacional do sistema. Na Seção 4.6.4 será apresentada, de forma mais detalhada, a justificativa para a eficiência observada nos modelos. Serão discutidos os principais fatores que contribuíram para os resultados obtidos.

Nome Modelo	Inst1	Inst2	Inst3	Inst4	Inst5	Inst6	Inst7	Inst8	Inst9	Inst10
Basic_Independ_Est	0,03	0,05	0,05	0,05	0,04	0,03	0,02	0,02	0,02	0,00
Basic_Comporta_Est	0,05	0,06	0,05	0,05	0,05	0,04	0,04	0,03	0,03	0,01
Basic_Independ_Din	0,05	0,08	0,05	0,05	0,04	0,02	0,02	0,02	0,01	0,00
Basic_Comporta_Din	0,05	0,06	0,06	0,05	0,05	0,04	0,04	0,03	0,03	0,01
Fulfill_Independ_Est	0,05	0,07	0,04	0,05	0,05	0,01	0,02	0,02	0,02	0,00
Fulfill_Comporta_Est	0,05	0,07	0,06	0,05	0,06	0,04	0,04	0,03	0,03	0,01
Fulfill_Independ_Din	0,06	0,15	0,07	0,07	0,08	0,03	0,03	0,05	0,02	0,02
Fulfill_Comporta_Din	0,06	0,08	0,08	0,06	0,06	0,06	0,08	0,05	0,05	0,03
Skipla_Independ_Est	0,06	0,08	0,05	0,09	0,10	0,02	0,02	0,02	0,02	0,00
Skipla_Comporta_Est	0,06	0,07	0,06	0,06	0,06	0,04	0,04	0,03	0,03	0,01
Skipla_Independ_Din	0,07	0,08	0,07	0,09	0,08	0,03	0,02	0,02	0,02	0,00
Skipla_Comporta_Din	0,07	0,09	0,08	0,07	0,07	0,06	0,06	0,05	0,04	0,02
Comp_Independ_Est	0,05	0,09	0,04	0,04	0,07	0,02	0,02	0,03	0,02	0,02
Comp_Comporta_Est	0,05	0,06	0,05	0,05	0,05	0,04	0,04	0,03	0,03	0,01
Comp_Independ_Din	0,06	0,09	0,04	0,04	0,05	0,02	0,02	0,03	0,02	0,00
Comp_Comporta_Din	0,05	0,07	0,06	0,05	0,06	0,05	0,05	0,04	0,03	0,02

Figura 4.3: Tempos de resolução, em segundos, de cada modelo para cada instância

4.6.3 Nós explorados

Com o objetivo de aprofundar a análise do desempenho computacional dos modelos propostos, esta seção apresenta a quantidade de nós explorados durante o processo de resolução

de cada instância. Esse indicador, comumente utilizado na avaliação de métodos baseados em *branch-and-bound*, fornece uma medida do esforço computacional requerido pelo solver para atingir a solução ótima. Na Tabela 4.11, são apresentados os nós explorados pelo solver para encontrar a solução ótima (ou a média das soluções ótimas, no caso comportamental) de cada modelo em cada instância. Os valores indicam a quantidade de nós explorados, sendo que o valor 0 indica que o solver não precisou explorar nenhum nó para encontrar a solução ótima.

Nome Modelo	Inst1	Inst2	Inst3	Inst4	Inst5	Inst6	Inst7	Inst8	Inst9	Inst10
Basic_Independ_Est	1	1	1	1	1	0	0	0	0	0
Basic_Comporta_Est	1	1	1	1	1	0	1	0	0	0
Basic_Independ_Din	1	1	1	1	1	0	0	0	0	0
Basic_Comporta_Din	1	1	1	1	1	0	1	0	0	0
Fulfill_Independ_Est	1	1	1	1	1	0	0	0	0	0
Fulfill_Comporta_Est	1	1	1	1	1	0	0	0	0	0
Fulfill_Independ_Din	1	1	1	1	1	0	0	0	0	0
Fulfill_Comporta_Din	1	1	1	1	1	0	1	0	1	1
Skipla_Independ_Est	1	1	1	1	1	0	0	0	0	0
Skipla_Comporta_Est	1	1	1	1	1	0	0	0	0	0
Skipla_Independ_Din	1	1	1	1	1	0	0	0	0	0
Skipla_Comporta_Din	1	1	1	1	1	0	0	1	1	1
Comp_Independ_Est	1	1	1	1	1	0	0	0	0	0
Comp_Comporta_Est	1	1	1	1	1	0	0	0	0	0
Comp_Independ_Din	1	1	1	1	1	0	0	0	0	0
Comp_Comporta_Din	1	1	1	1	1	0	1	0	0	0

Tabela 4.11: Nós explorados pelo solver para encontrar a solução ótima

Da Tabela 4.11, pode-se observar que, desde as instâncias Inst1 até Inst5, ao solver levou no máximo 1 nó para encontrar a solução ótima inteira, isso para cada um dos modelos propostos. Por outro lado, das instâncias Inst6 até Inst10, não foi explorado nenhum nó, com exceção dos modelos Basic_Comporta_Din, Fulfill_Comporta_Din e Skipla_Comporta_Din, que levaram a explorar 1 nó. O fato de a solução ter sido encontrada sem explorar nenhum nó significa que o solver obteve a solução no processo de pré-processamento, realizado antes de começar as ramificações. Essa informação está diretamente relacionada aos tempos de solução apresentados na seção anterior.

4.6.4 Matrizes totalmente unimodulares

Uma matriz $A \in \mathbb{R}^{m \times n}$ é totalmente unimodular (TU) se todo subdeterminante (determinante de qualquer submatriz quadrada) é igual a -1, 0 ou 1. Isso implica, em particular, que cada

entrada de A pertence a $\{-1, 0, 1\}$.

Como consequência, em otimização inteira, se A é TU e b é inteiro, então o politopo $P = \{x \in \mathbb{R}^n : Ax \leq b\}$ tem todas as soluções básicas (vértices) inteiras. Assim, a relaxação linear do problema já produz soluções inteiras sem impor a restrição de integralidade $x \in \mathbb{Z}^n$. Essa propriedade é fundamental e amplamente utilizada em algoritmos de otimização e em problemas de programação linear com restrições inteiras (Arifin and Muktyas, 2018). O procedimento descrito auxilia o solver no processo de resolução, pois, a solução relaxada do problema se torna a solução inteira. Isso contribui para uma maior eficiência tanto nos tempos de solução quanto na exploração de nós durante o processo de ramificação.

Com base na definição anterior, observa-se que o vetor b é inteiro em todas as instâncias analisadas — representando, conforme o caso, a capacidade do trem, as demandas de passageiros ou a quantidade de assentos vagos. Desse modo, a atenção concentrou-se na matriz de coeficientes A . Embora a verificação teórica exija confirmar que todos os subdeterminantes de submatrizes quadradas pertençam a $\{-1, 0, 1\}$, tal procedimento torna-se impraticável mesmo na menor instância (Inst10), dado o número explosivo de submatrizes. Em alternativa, adotou-se uma checagem empírica: executar cada modelo e instância com variáveis relaxadas e comparar os resultados com a formulação inteira. Sempre que os valores coincidiram, concluiu-se que a relaxação já produzia soluções inteiras — exatamente o comportamento observado nas instâncias e modelos sinalizados com “-” na Tabela 4.12.

Para complementar essa evidência, verificou-se ainda se a matriz A efetivamente utilizada na resolução continha somente coeficientes em $\{-1, 0, 1\}$. Essa conferência foi realizada após o pré-processamento (*presolve*), fase em que o solver pode eliminar restrições ou variáveis por dominância, fixações ou outras simplificações. Assim, mesmo que a formulação inicial pudesse apresentar coeficientes fora do conjunto desejado, o que importa para a prova computacional é a matriz resultante *pós-presolve*, que de fato fundamenta a solução do problema.

Os resultados das verificações estão apresentados na Tabela 4.12, onde, se um modelo para uma instância for TU, é exibida uma linha “-” na célula correspondente. Caso contrário, são mostrados três dados na mesma célula: o primeiro valor representa a quantidade de restrições que não são compostas apenas por valores no conjunto $\{-1, 0, +1\}$; o segundo valor indica o

total de restrições desse modelo para essa instância; e o último valor mostra a relação percentual entre os dois primeiros valores.

Nome Modelo	Inst1	Inst2	Inst3	Inst4	Inst5	Inst6	Inst7	Inst8	Inst9	Inst10
Basic_Independ_Est	-	-	-	-	-	-	-	-	-	-
Fulfill_Independ_Est	-	-	-	-	-	-	-	-	-	-
Skipla_Independ_Est	-	-	291 57.106 0,510 %	-	-	-	-	-	-	-
Comp_Independ_Est	-	-	-	-	-	-	-	-	-	-
Basic_Comporta_Est	-	-	-	-	-	-	-	-	-	-
Fulfill_Comporta_Est	-	-	-	-	-	-	-	-	-	-
Skipla_Comporta_Est	-	-	-	-	-	-	-	-	-	-
Comp_Comporta_Est	-	-	-	-	-	-	-	-	-	-
Basic_Independ_Din	-	-	-	-	-	-	-	-	-	-
Fulfill_Independ_Din	-	-	-	-	-	-	-	-	-	-
Skipla_Independ_Din	-	-	-	-	-	-	-	-	-	-
Comp_Independ_Din	-	-	-	-	-	-	-	-	-	3 10.944 0,027 %
Basic_Comporta_Din	135 63.984 0,211 %	5 80.284 0,006 %	232 61.649 0,376 %	5 66.612 0,008 %	76 71.235 0,107 %	4 36.014 0,011 %	180 32.940 0,546 %	135 33.248 0,406 %	130 32.074 0,405 %	7 11.936 0,059 %
Fulfill_Comporta_Din	-	-	3 62.784 0,005 %	-	3 72.016 0,004 %	-	4 33.488 0,012 %	8 33.836 0,024 %	3 32.533 0,009 %	8 12.262 0,065 %
Skipla_Comporta_Din	-	-	4 62.743 0,006 %	3 67.455 0,004 %	3 71.702 0,004 %	-	3 33.812 0,009 %	-	7 32.498 0,022 %	6 12.130 0,049 %
Comp_Comporta_Din	-	-	-	-	3 72.483 0,004 %	-	-	-	-	-

Tabela 4.12: Modelos não unimodulares para cada instância

É assim que, para cada modelo e instância da Tabela 4.12 que possui apenas uma linha, se explica por que os tempos de solução correspondentes são tão baixos, assim como a quantidade de nós explorados para a obtenção da solução ótima inteira. No entanto, observa-se que os tempos e nós explorados continuam baixos, mesmo para os modelos e instâncias que não são TU. Para explicar essa situação, é necessário considerar o trabalho de (Aprile et al., 2024), que introduz o conceito de Δ -*modular*. Segundo os autores, existem matrizes quase unimodulares, onde, se um conjunto de linhas (restrições) for eliminado, a matriz se tornaria TU. O tamanho desse conjunto é representado por Δ , ou seja, Δ é a quantidade de restrições que impede que a matriz seja TU. No final, os autores demonstram que as matrizes quase unimodulares ou Δ -*modular* ajudam a tornar o processo de resolução do problema muito mais eficiente, à medida que Δ se torna menor.

Observando a 4.12, nota-se que a maior parte dos modelos e instâncias que não são TU

apresenta um valor de Δ — ou seja, o primeiro valor de cada célula — abaixo de 8, o que, quando comparado com o número total de restrições, é extremamente baixo. Existem 7 exceções com valores de Δ entre 76 e 291; no entanto, novamente, em função do número total de restrições, essa relação não ultrapassa 0,5% do total. Assim, para as matrizes não TU, pode-se afirmar, com base na definição de Δ -modular, que também obtêm resultados em tempo competitivo e com uma quantidade baixa de nós explorados.

CAPÍTULO 5

Conclusões e trabalhos futuro

Esta pesquisa abordou o problema do transporte ferroviário de passageiros do ponto de vista do RM, desenvolvendo diferentes modelos matemáticos inteiros mistos com base em dois enfoques principais: o tipo de demanda e os tipos de autorizações. No primeiro caso, foram consideradas a demanda independente e a demanda comportamental, enquanto no segundo, foram tratadas as autorizações estáticas e dinâmicas. Como resultado, foram desenvolvidos quatro modelos matemáticos, sendo cada um dividido em quatro partes distintas: i) Uma versão básica do modelo com as restrições fundamentais do problema; ii) A adição das restrições de *fulfillment over periods* ao modelo base; iii) A inclusão das restrições de *skiplagging* no modelo base; iv) A integração simultânea das três primeiras partes em um único modelo completo.

Com base nos resultados obtidos, pode-se concluir que:

Do ponto de vista computacional, todos os modelos desenvolvidos são altamente eficientes, encontrando soluções em frações de segundo, independentemente do tamanho da instância escolhida. Vale ressaltar que, para a validação, foram selecionadas instâncias de diferentes tamanhos (grande, médio e pequeno). No caso das instâncias pequenas, todos os modelos conseguiram encontrar as soluções ótimas inteiras quase que instantaneamente. Para a instância maior (Inst2), os resultados foram obtidos em, no máximo, 0,15 segundos.

Do ponto de vista empresarial, como efeito do ponto anterior, cada modelo se mostrou atraente e aplicável a ambientes reais. Considerando que os tempos apresentados referem-se apenas a um único trajeto de trem, os modelos continuam sendo altamente vantajosos, principalmente devido à rapidez de resolução. É importante notar que qualquer abordagem escolhida tem suas vantagens e desvantagens. Por exemplo, um modelo básico garantiria um aproveitamento da demanda superior a 90%, mas não levaria em conta condições importantes no desenvolvimento real do negócio. Por outro lado, um modelo completo consideraria todas essas condições para garantir um serviço excelente, mas o aproveitamento da demanda poderia ser reduzido em até 50%, ou mais, em comparação com os modelos básicos.

Os modelos de demanda do tipo independente apresentaram resultados ligeiramente superiores aos dos modelos comportamentais para as instâncias estudadas. Essa variação, embora pequena, deve-se às características das instâncias, já que existe um alto percentual de combinações de trecho, tipo de assento e período que têm apenas uma classe. Isso gera uma lista de preferências com uma única opção ao aplicar os modelos comportamentais, o que torna ambas as abordagens muito semelhantes. As pequenas variações observadas ocorrem em casos onde há mais de uma classe por combinação.

Um resultado interessante foi que o modelo com autorizações dinâmicas obteve resultados significativamente melhores que o modelo com autorizações estáticas, apresentando uma diferença da receita superior a 10%. Este é um valor representativo em um ambiente real.

Os modelos propostos possuem uma característica importante, a unimodularidade, onde 10 dos 16 modelos são TU para as 10 instâncias, o que contribui para os baixos tempos de execução mencionados. Para os modelos que não são TU, o valor de Δ é pequeno em comparação ao total de restrições do problema, o que também contribui para uma resolução eficiente usando a definição de Δ -modular. Esse aspecto explica de forma concisa os baixos tempos de solução e o número reduzido de nós explorados durante o processo de resolução.

Como trabalho futuro, recomenda-se modelar adicionalmente a estimativa da demanda, uma vez que esta pesquisa utilizou a demanda como um parâmetro e confiou nos métodos de tratamento com os quais foi estimada pela empresa fornecedora dos dados. A inclusão dessa abordagem poderia melhorar ainda mais as projeções, assim como as quantidades de reservas

e autorizações, lembrando que a demanda é um ponto crucial para resolver problemas como o transporte ferroviário de passageiros.

Com base nisso, recomenda-se a abordagem da modelagem estocástica, que é adequada para problemas onde há grande incerteza. A modelagem estocástica permitiria incorporar variáveis dinâmicas de maneira mais flexível, refletindo melhor as flutuações e incertezas da demanda e as escolhas nas listas de preferência, ao longo do horizonte de reserva.

Adicionalmente, seria interessante explorar o problema sob a ótica da inteligência artificial, utilizando, por exemplo, aprendizagem por reforço (*reinforcement learning*), seja para gerenciar a demanda ou para resolver o problema em si. Nos últimos anos, diversas propostas surgiram, mas esse é um campo ainda pouco explorado, o que o torna uma área promissora a ser investigada.

Referências

- Valerio Agasucci, Giorgio Grani, and Leonardo Lamorgese. Solving the train dispatching problem via deep reinforcement learning. *Journal of Rail Transport Planning and Management*, 26:100394, 2023. ISSN 2210-9706. doi: <https://doi.org/10.1016/j.jrtpm.2023.100394>. URL <https://www.sciencedirect.com/science/article/pii/S2210970623000264>.
- Salvatore Ammirato, Alberto Michele Felicetti, Roberto Linzalone, Antonio Palmiro Volpentesta, and Giovanni Schiuma. A systematic literature review of revenue management in passenger transportation. *Measuring Business Excellence*, 24(2):223–242, 2020. ISSN 1368-3047. doi: 10.1108/MBE-09-2019-0096. URL <https://doi.org/10.1108/MBE-09-2019-0096>.
- Manuel Aprile, Samuel Fiorini, Gwenaël Joret, Stefan Kober, Michał T. Seweryn, Stefan Weltge, and Yelena Yuditsky. Integer programs with nearly totally unimodular matrices: the cographic case, 2024. URL <https://arxiv.org/abs/2407.09477>.
- Samsul Arifin and Indra Bayu Muktyas. Membangkitkan suatu matriks unimodular dengan python. *Jurnal Derivat: Jurnal Matematika dan Pendidikan Matematika*, 2018. URL <https://api.semanticscholar.org/CorpusID:216848700>.
- Shirin Aslani, Mohammad Modarres, and Soheil Sibdari. On the fairness of airlines’ ticket pricing as a result of revenue management techniques. *Journal of Air Transport Management*,

- 40:56–64, 2014. ISSN 0969-6997. doi: <https://doi.org/10.1016/j.jairtraman.2014.05.004>. URL <https://www.sciencedirect.com/science/article/pii/S0969699714000556>.
- Erhan Atilla Avinal. Revenue management in hotels. *Journal of Foodservice Business Research*, 7(4):51–57, 2006. doi: 10.1300/J369v07n04_02. URL https://doi.org/10.1300/J369v07n04_02.
- Thibault Barbier, Miguel F. Anjos, Fabien Cirinei, and Gilles Savard. Product-closing approximation for ranking-based choice network revenue management. *European Journal of Operational Research*, 286(3):1002–1017, 2020. ISSN 0377-2217. doi: <https://doi.org/10.1016/j.ejor.2020.04.042>. URL <https://www.sciencedirect.com/science/article/pii/S0377221720303957>.
- Peter P. Belobaba. Survey paper—airline yield management an overview of seat inventory control. *Transportation Science*, 21(2):63–73, 1987. doi: 10.1287/trsc.21.2.63. URL <https://doi.org/10.1287/trsc.21.2.63>.
- Dimitris Bertsimas and S de Boer. Joint network pricing and resource allocation. Technical report, Technical report, 2002.
- Nikola Besinovi, Lorenzo De Donato, Francesco Flammini, Rob M. P. Goverde, Zhiyuan Lin, Ronghui Liu, Stefano Marrone, Roberto Nardone, Tianli Tang, and Valeria Vittorini. Artificial intelligence in railway transport: Taxonomy, regulations, and applications. *IEEE Transactions on Intelligent Transportation Systems*, 23(9):14011–14024, 2022. doi: 10.1109/TITS.2021.3131637.
- Ş. İlker Birbil, J. B. G. Frenk, Joaquim A. S. Gromicho, and Shuzhong Zhang. The role of robust optimization in single-leg airline revenue management. *Management Science*, 55(1):148–163, 2009. doi: 10.1287/mnsc.1070.0843. URL <https://doi.org/10.1287/mnsc.1070.0843>.
- S. L. Brumelle and J. I. McGill. Airline seat allocation with multiple nested fare classes. *Operations Research*, 41(1):127–137, 02 1993. doi: 10.1287/opre.41.1.127. URL <https://ideas.repec.org/a/inm/oropre/v41y1993i1p127-137.html>.

- Don B Casey. Past, present and future challenges of revenue management, pricing and scheduling. *Journal of Revenue and Pricing Management*, 13(5):343–346, 2014. ISSN 1477-657X. doi: 10.1057/rpm.2014.16. URL <https://doi.org/10.1057/rpm.2014.16>.
- Yu-Hern Chang, Chung-Hsing Yeh, and Ching-Cheng Shen. A multiobjective model for passenger train services planning: application to taiwan’s high-speed rail line. *Transportation Research Part B: Methodological*, 34(2):91–106, 2000. ISSN 0191-2615. doi: [https://doi.org/10.1016/S0191-2615\(99\)00013-2](https://doi.org/10.1016/S0191-2615(99)00013-2). URL <https://www.sciencedirect.com/science/article/pii/S0191261599000132>.
- Ji Chen, Yifan Xu, Peiwen Yu, and Jun Zhang. A reinforcement learning approach for hotel revenue management with evidence from field experiments. *Journal of Operations Management*, 69(7):1176–1201, 2023. doi: <https://doi.org/10.1002/joom.1246>. URL <https://onlinelibrary.wiley.com/doi/abs/10.1002/joom.1246>.
- S.Hossein Cheraghi, Mohammad Dadashzadeh, and Prakash Venkitachalam. Revenue management in manufacturing: A research landscape. *Journal of Business & Economics Research*, 8, 2010. URL <https://api.semanticscholar.org/CorpusID:154873467>.
- Ek Peng Chew, Chulung Lee, and Rujing Liu. Joint inventory allocation and pricing decisions for perishable products. *International Journal of Production Economics*, 120(1):139–150, 2009. ISSN 0925-5273. doi: <https://doi.org/10.1016/j.ijpe.2008.07.018>. URL <https://www.sciencedirect.com/science/article/pii/S0925527308003368>. Special Issue on Operations Strategy and Supply Chains Management.
- Claire Cizaire. Optimization models for joint airline pricing and seat inventory control: Multiple products, multiple periods. 09 2011.
- M.T. Claessens, N.M. van Dijk, and P.J. Zwaneveld. Cost optimal allocation of rail passenger lines. *European Journal of Operational Research*, 110(3):474–489, 1998. ISSN 0377-2217. doi: [https://doi.org/10.1016/S0377-2217\(97\)00271-3](https://doi.org/10.1016/S0377-2217(97)00271-3). URL <https://www.sciencedirect.com/science/article/pii/S0377221797002713>.

- Francesco Corman, Andrea D'Ariano, Ingo A. Hansen, and Dario Pacciarelli. Optimal multi-class rescheduling of railway traffic. *Journal of Rail Transport Planning and Management*, 1(1):14–24, 2011. ISSN 2210-9706. URL <https://www.sciencedirect.com/science/article/pii/S2210970611000023>. Robust Modelling of Capacity, Delays and Rescheduling in Regional Networks.
- Robert G. Cross. An introduction to revenue management. 1995. URL <https://api.semanticscholar.org/CorpusID:166489213>.
- Robert G. Cross. Launching the revenue rocket: How revenue management can work for your business. *Cornell Hotel and Restaurant Administration Quarterly*, 38(2):32–43, 1997. doi: 10.1177/001088049703800222. URL <https://doi.org/10.1177/001088049703800222>.
- James D. Dana. Equilibrium price dispersion under demand uncertainty: The roles of costly capacity and market structure. *The RAND Journal of Economics*, 30(4):632–660, 1999. ISSN 07416261. URL <http://www.jstor.org/stable/2556068>.
- Paul Dobson and Claudio Piga. The impact of mergers on fares structure: Evidence from european low-cost airlines. *Economic Inquiry*, 51(2):1196–1217, 2013. URL <https://EconPapers.repec.org/RePEc:bla:ecinqu:v:51:y:2013:i:2:p:1196-1217>.
- Noomesh Dowlut and Baby Gobin-Rahimbux. Forecasting resort hotel tourism demand using deep learning techniques – a systematic literature review. *Heliyon*, 9(7), 2023. ISSN 2405-8440. doi: 10.1016/j.heliyon.2023.e18385. URL <https://doi.org/10.1016/j.heliyon.2023.e18385>.
- Topaloglu Huseyin Erdelyi Alexander. Using decomposition methods to solve pricing problems in network revenue management. *Journal of Revenue and Pricing Management*, 10(4):325–343, 2011. doi: 10.1057/rpm.2009.53.
- Youyi Feng and Baichun Xiao. A dynamic airline seat inventory control model and its optimal policy. *Operations Research*, 49(6):938–949, 2001. doi: 10.1287/opre.49.6.938.10026. URL <https://doi.org/10.1287/opre.49.6.938.10026>.

- Oskar Fröidh. Perspectives for a future high-speed train in the swedish domestic travel market. *Journal of Transport Geography*, 16(4):268–277, 2008. ISSN 0966-6923. doi: <https://doi.org/10.1016/j.jtrangeo.2007.09.005>. URL <https://www.sciencedirect.com/science/article/pii/S0966692307000919>.
- Mitsuyoshi Fukushi, Felipe Delgado, Sebastián Raveau, and Bruno F. Santos. Chairs: A choice-based air transport simulator applied to airline competition and revenue management. *Transportation Research Part A: Policy and Practice*, 155:297–315, 2022. ISSN 0965-8564. doi: <https://doi.org/10.1016/j.tra.2021.11.010>. URL <https://www.sciencedirect.com/science/article/pii/S0965856421002895>.
- G. Gallego and G. van Ryzin. Optimal dynamic auctions for revenue management. *Management Science*, 40(7):999–1020, 1994.
- Guillermo Gallego and Garrett van Ryzin. A multiproduct dynamic pricing problem and its applications to network yield management. *Operations Research*, 45(1):24–41, 1997. doi: 10.1287/opre.45.1.24. URL <https://doi.org/10.1287/opre.45.1.24>.
- Huina Gao, Michael O Ball, and Itir Z Karaesmen. Competitive seat inventory control decisions under the regret criterion. *Journal of Revenue and Pricing Management*, 9(1):49–65, 2010. ISSN 1477-657X. doi: 10.1057/rpm.2009.40. URL <https://doi.org/10.1057/rpm.2009.40>.
- Fred Glover, Randy Glover, Joe Lorenzo, and Claude McMillan. The passenger-mix problem in the scheduled airlines. *Interfaces*, 12(3):73–80, 1982. ISSN 00922102, 1526551X. URL <http://www.jstor.org/stable/25060268>.
- Xueyi Guan, Jin Qin, Chenghui Mao, and Wenliang Zhou. A literature review of railway pricing based on revenue management. *Mathematics*, 11(4), 2023. ISSN 2227-7390. doi: 10.3390/math11040857. URL <https://www.mdpi.com/2227-7390/11/4/857>.
- Francesca Guerriero, Martina Luzzi, and Giusy Macrina. *Revenue Management Approach for Passenger Transport Service: An Italian Case Study*, pages 237–247. Springer International Publishing, Cham, 2021. ISBN 978-3-030-86841-3. doi: 10.1007/978-3-030-86841-3_20. URL https://doi.org/10.1007/978-3-030-86841-3_20.

- Peng Guo, Baichun Xiao, and Jun Li. Unconstraining methods in revenue management systems: Research overview and prospects. *Advances in Operations Research*, 2012(1):270910, 2012. doi: <https://doi.org/10.1155/2012/270910>. URL <https://onlinelibrary.wiley.com/doi/abs/10.1155/2012/270910>.
- Jochen Gönsch, Robert Klein, Michael Neugebauer, and Claudius Steinhardt. Dynamic pricing with strategic customers. *Journal of Business Economics*, 83(5):505–549, July 2013. ISSN 1861-8928. doi: 10.1007/s11573-013-0663-7. URL <https://doi.org/10.1007/s11573-013-0663-7>.
- X. Han and Z. Ren. Joint optimization of stop planning and ticket allocation under uncertainty theory. *Soft Computing*, 24(9):7293–7308, 2020. doi: 10.1007/s00500-019-04617-9.
- Haonan He, Liangyu Chen, and Shanyong Wang. Flight short-term booking demand forecasting based on a long short-term memory network. *Computers & Industrial Engineering*, 186:109707, 2023. ISSN 0360-8352. doi: 10.1016/j.cie.2023.109707. URL <https://www.sciencedirect.com/science/article/pii/S0360835223007313>.
- Henrique Henriques and Luis Nobre Pereira. Hotel demand forecasting models and methods using artificial intelligence: A systematic literature review. *Tourism & Management Studies*, 20(3):39–51, 2024. doi: 10.18089/tms.20240304. URL <https://doi.org/10.18089/tms.20240304>.
- Cindy Yoonjung Heo and Seoki Lee. Application of revenue management practices to the theme park industry. *International Journal of Hospitality Management*, 28(3):446–453, 2009. ISSN 0278-4319. doi: <https://doi.org/10.1016/j.ijhm.2009.02.001>. URL <https://www.sciencedirect.com/science/article/pii/S0278431909000255>.
- Pratt Hettrakul and Cinzia Cirillo. Accommodating taste heterogeneity in railway passenger choice models based on internet booking data. *Journal of Choice Modelling*, 6:1–16, 2013. ISSN 1755-5345. doi: <https://doi.org/10.1016/j.jocm.2013.04.003>. URL <https://www.sciencedirect.com/science/article/pii/S1755534513000080>.

- Pratt Hetrakul and Cinzia Cirillo. A latent class choice based model system for railway optimal pricing and seat allocation. *Transportation Research Part E: Logistics and Transportation Review*, 61:68–83, 2014. ISSN 1366-5545. doi: <https://doi.org/10.1016/j.tre.2013.10.005>. URL <https://www.sciencedirect.com/science/article/pii/S1366554513001725>.
- Kuancheng Huang and Yu-Tung Liang. A dynamic programming algorithm based on expected revenue approximation for the network revenue management problem. *Transportation Research Part E: Logistics and Transportation Review*, 47(3):333–341, 2011. ISSN 1366-5545. doi: <https://doi.org/10.1016/j.tre.2010.11.005>. URL <https://www.sciencedirect.com/science/article/pii/S1366554510001092>. Selected papers from the 13th ATRS Conference, Abu Dhabi, 2009.
- Dennis Huisman, Leo G. Kroon, Ramon M. Lentink, and Michiel J. C. M. Vromans. Operations research in passenger railway transportation. *Statistica Neerlandica*, 59(4):467–497, 2005. doi: <https://doi.org/10.1111/j.1467-9574.2005.00303.x>. URL <https://onlinelibrary.wiley.com/doi/abs/10.1111/j.1467-9574.2005.00303.x>.
- Stanislav Ivanov and Vladimir Zhechev. Hotel revenue management - a critical literature review. *Tourism*, 60, 12 2011. doi: 10.2139/ssrn.1977467.
- Eva König. A review on railway delay management. *Public Transport*, 12(2):335–361, 2020. ISSN 1613-7159. doi: 10.1007/s12469-020-00233-1. URL <https://doi.org/10.1007/s12469-020-00233-1>.
- Yihua Li, Ahmadreza Mahmoudzadeh, and Xiubin Bruce Wang. Airlines seat pricing with seat upgrading. *Multimodal Transportation*, 1(4):100054, 2022. ISSN 2772-5863. doi: <https://doi.org/10.1016/j.multra.2022.100054>. URL <https://www.sciencedirect.com/science/article/pii/S2772586322000545>.
- Ken Littlewood. Special issue papers: Forecasting and control of passenger bookings. *Journal of Revenue and Pricing Management*, 4:111–123, 04 2005. doi: 10.1057/palgrave.rpm.5170134.

- Jiamin Zhao Maged M. Dessouky, Quan Lu and Robert C. Leachman. An exact solution procedure to determine the optimal dispatching times for complex rail networks. *IIE Transactions*, 38(2):141–152, 2006. doi: 10.1080/074081791008988. URL <https://doi.org/10.1080/074081791008988>.
- Jeffrey McGill and Garrett van Ryzin. Revenue management: Research overview and prospects. *Transportation Science*, 33:233–256, 05 1999. doi: 10.1287/trsc.33.2.233.
- Yuniar Mulyani. The forty-year history of revenue management: Bibliometric analysis. *OPSI*, 2021. URL <https://api.semanticscholar.org/CorpusID:237823656>.
- Isabel Méndez-Díaz, Juan José Miranda-Bront, Gustavo Vulcano, and Paula Zabala. A branch-and-cut algorithm for the latent-class logit assortment problem. *Discrete Applied Mathematics*, 164:246–263, 2014. ISSN 0166-218X. doi: <https://doi.org/10.1016/j.dam.2012.03.003>. URL <https://www.sciencedirect.com/science/article/pii/S0166218X12001072>. Combinatorial Optimization.
- Serguei Netessine and Robert A. Shumsky. Revenue management games: Horizontal and vertical competition. *Management Science*, 51(5):813–831, 2005. doi: 10.1287/mnsc.1040.0356. URL <https://doi.org/10.1287/mnsc.1040.0356>.
- B. M. Noone, K. A. McGuire, and K. V. Rohlf. Social media meets hotel revenue management: Opportunities, issues and unanswered questions. *Journal of Revenue and Pricing Management*, 10(4):293–305, 2011.
- Daniel F. Otero and Raha Akhavan-Tabatabaei. A stochastic dynamic pricing model for the multiclass problems in the airline industry. *European Journal of Operational Research*, 242(1):188–200, 2015. ISSN 0377-2217. doi: <https://doi.org/10.1016/j.ejor.2014.09.038>. URL <https://www.sciencedirect.com/science/article/pii/S0377221714007772>.
- Luis Nobre Pereira. An introduction to helpful forecasting methods for hotel revenue management. *International Journal of Hospitality Management*, 58:13–23, 2016. ISSN 0278-4319. doi: <https://doi.org/10.1016/j.ijhm.2016.07.003>. URL <https://www.sciencedirect.com/science/article/pii/S027843191630086X>.

- Luis Nobre Pereira and Vitor Cerqueira and. Forecasting hotel demand for revenue management using machine learning regression methods. *Current Issues in Tourism*, 25(17):2733–2750, 2022. doi: 10.1080/13683500.2021.1999397. URL <https://doi.org/10.1080/13683500.2021.1999397>.
- Jianguo Qi, Lixing Yang, Zhen Di, Shukai Li, Kai Yang, and Yuan Gao. Integrated optimization for train operation zone and stop plan with passenger distributions. *Transportation Research Part E: Logistics and Transportation Review*, 109:151–173, 2018. ISSN 1366-5545. doi: <https://doi.org/10.1016/j.tre.2017.11.003>. URL <https://www.sciencedirect.com/science/article/pii/S1366554517303812>.
- Ahmad Rusdiansyah, Rescha Dwi A. P., and Nia Puspitasari. Model dynamic pricing untuk penetapan harga tiket pesawat terbang berbasis waktu dan persediaan kursi dengan mempertimbangkan keputusan kompetitor. *Jurnal Teknik Industri: Jurnal Keilmuan dan Aplikasi Teknik Industri*, 15(1):45–56, 05 2013. doi: 10.9744/jti.15.1.45-56. URL <https://jurnalindustri.petra.ac.id/index.php/ind/article/view/18707>.
- Malek Sarhani and Stefan Voß. Prediction of rail transit delays with machine learning: How to exploit open data sources. *Multimodal Transportation*, 3(2):100120, 2024. ISSN 2772-5863. doi: <https://doi.org/10.1016/j.multra.2024.100120>. URL <https://www.sciencedirect.com/science/article/pii/S2772586324000017>.
- A. Schöbel and F. Urban. Optimal fare structures and algorithms for ticket assignment in public transportation systems. *ArXiv preprint*, abs/2106.10521, 2021. URL <https://arxiv.org/abs/2106.10521>.
- Mahaboobsubani Shaik. Ai-driven revenue management using lang chain models in hospitality. *International Journal of Leading Research Publication*, 5(3), 3 2024. doi: 10.5281/zenodo.14471629. URL <https://doi.org/10.5281/zenodo.14471629>.
- Xinghua Shan, Xiaoyan Lv, Jinfei Wu, Shuo Zhao, and Junfeng Zhang. Revenue management method and critical techniques of railway passenger transport. *Railway Sciences*, 3(5):636–

649, 2024. ISSN 2755-0907, 2755-0915. doi: 10.1108/RS-04-2024-0013. URL <https://doi.org/10.1108/RS-04-2024-0013>.

Zuo-Jun Max Shen and Xuanming Su. Customer behavior modeling in revenue management and auctions: A review and new research opportunities. *Production and Operations Management*, 16(6):713–728, 2007. doi: <https://doi.org/10.1111/j.1937-5956.2007.tb00291.x>. URL <https://onlinelibrary.wiley.com/doi/abs/10.1111/j.1937-5956.2007.tb00291.x>.

Barry C. Smith, John F. Leimkuhler, and Ross M. Darrow. Yield management at american airlines. *Interfaces*, 22(1):8–31, 1992. doi: 10.1287/inte.22.1.8. URL <https://doi.org/10.1287/inte.22.1.8>.

Arne K. Strauss, Robert Klein, and Claudius Steinhardt. A review of choice-based revenue management: Theory and methods. *European Journal of Operational Research*, 271(2): 375–387, 2018. ISSN 0377-2217. doi: <https://doi.org/10.1016/j.ejor.2018.01.011>. URL <https://www.sciencedirect.com/science/article/pii/S0377221718300110>.

Yanshuo Sun, Zhibin Jiang, Jinjing Gu, Min Zhou, Yeming Li, and Lei Zhang. Analyzing high speed rail passengers’ train choices based on new online booking data in china. *Transportation Research Part C: Emerging Technologies*, 97:96–113, 2018. ISSN 0968-090X. doi: <https://doi.org/10.1016/j.trc.2018.10.015>. URL <https://www.sciencedirect.com/science/article/pii/S0968090X18301694>.

Kalyan Talluri and Garrett van Ryzin. An analysis of bid-price controls for network revenue management. *Management Science*, 44(11-part-1):1577–1593, 1998. doi: 10.1287/mnsc.44.11.1577. URL <https://doi.org/10.1287/mnsc.44.11.1577>.

Kalyan T Talluri and Garrett J Van Ryzin. Theory and practice of revenue management. *Springer Science & Business Media*, 2004.

Kalyan T. Talluri, Garrett J. van Ryzin, Itir Z. Karaesmen, and Gustavo J. Vulcano. Revenue management: Models and methods. In *2008 Winter Simulation Conference*, pages 145–156, 2008. doi: 10.1109/WSC.2008.4736064.

- Ruifan Tang, Lorenzo De Donato, Nikola Bessinovic, Francesco Flammini, Rob M.P. Goverde, Zhiyuan Lin, Ronghui Liu, Tianli Tang, Valeria Vittorini, and Ziyulong Wang. A literature review of artificial intelligence applications in railway systems. *Transportation Research Part C: Emerging Technologies*, 140:103679, 2022. ISSN 0968-090X. doi: <https://doi.org/10.1016/j.trc.2022.103679>. URL <https://www.sciencedirect.com/science/article/pii/S0968090X22001206>.
- Tao Tang, Simin Chai, Wei Wu, Jiateng Yin, and Andrea D’Ariano. A multi-task deep reinforcement learning approach to real-time railway train rescheduling. *Transportation Research Part E: Logistics and Transportation Review*, 194:103900, 2025. ISSN 1366-5545. doi: <https://doi.org/10.1016/j.tre.2024.103900>. URL <https://www.sciencedirect.com/science/article/pii/S1366554524004915>.
- Saravanan Thirumuruganathan, Noora Al Emadi, Soon gyo Jung, Joni Salminen, Dianne Ramirez Robillos, and Bernard J. Jansen. Will they take this offer? a machine learning price elasticity model for predicting upselling acceptance of premium airline seating. *Information & Management*, 60(3):103759, 2023. ISSN 0378-7206. doi: 10.1016/j.im.2023.103759. URL <https://www.sciencedirect.com/science/article/pii/S0378720623000071>.
- Ben Vinod. Unlocking the value of revenue management in the hotel industry. *Journal of Revenue and Pricing Management*, 3(2):178–190, 2004. ISSN 1477-657X. doi: 10.1057/palgrave.rpm.5170105. URL <https://doi.org/10.1057/palgrave.rpm.5170105>.
- Darius Walczak and Shelby Brumelle. Semi-markov information model for revenue management and dynamic pricing. *OR Spectrum*, 29(1):61–83, 2007. ISSN 1436-6304. doi: 10.1007/s00291-005-0026-z. URL <https://doi.org/10.1007/s00291-005-0026-z>.
- Weidi Wang, Ou Tang, and Jiazhen Huo. Dynamic capacity allocation for airlines with multi-channel distribution. *Journal of Air Transport Management*, 69:173–181, 2018. ISSN 0969-6997. doi: <https://doi.org/10.1016/j.jairtraman.2018.02.006>. URL <https://www.sciencedirect.com/science/article/pii/S0969699717303204>.
- Chieh-Hua Wen and Po-Hung Chen. Passenger booking timing for low-cost airlines: A continu-

- ous logit approach. *Journal of Air Transport Management*, 64:91–99, 2017. ISSN 0969-6997. doi: <https://doi.org/10.1016/j.jairtraman.2017.06.030>. URL <https://www.sciencedirect.com/science/article/pii/S0969699717302995>. Selected papers from the 19th ATRS World Conference, Singapore, 2015.
- Elizabeth Louise. Williamson. Airline network seat inventory control : methodologies and revenue impacts. 1992. URL <https://api.semanticscholar.org/CorpusID:109755890>.
- Guangming Xu, Hai Yang, Wei Liu, and Feng Shi. Itinerary choice and advance ticket booking for high-speed-railway network services. *Transportation Research Part C: Emerging Technologies*, 95:82–104, 2018. ISSN 0968-090X. doi: <https://doi.org/10.1016/j.trc.2018.07.010>. URL <https://www.sciencedirect.com/science/article/pii/S0968090X18300251>.
- Dan Zhang and Daniel Adelman. An approximate dynamic programming approach to network revenue management with customer choice. *Transportation Science*, 43(3):381–394, 2009. doi: 10.1287/trsc.1090.0262. URL <https://doi.org/10.1287/trsc.1090.0262>.
- Dan Zhang and William L. Cooper. Pricing substitutable flights in airline revenue management. *European Journal of Operational Research*, 197(3):848–861, 2009. ISSN 0377-2217. doi: <https://doi.org/10.1016/j.ejor.2006.10.067>. URL <https://www.sciencedirect.com/science/article/pii/S0377221708002038>.
- Xiang Zhao and Peng Zhao. A seat assignment model for high-speed railway ticket booking system with customer preference consideration. *Transportmetrica A Transport Science*, 15(2):776–806, 2019. doi: <https://doi.org/10.1080/23249935.2018.1532467>.
- Nan Zheng and Nikolas Geroliminis. Modeling and optimization of multimodal urban networks with limited parking and dynamic pricing. *Transportation Research Part B: Methodological*, 83:36–58, 2016. ISSN 0191-2615. doi: <https://doi.org/10.1016/j.trb.2015.10.008>. URL <https://www.sciencedirect.com/science/article/pii/S0191261515002234>.
- X. Zhou and Others. Nonlinear integer programming model for integrated ticket pricing and stop planning in railway systems. *Mathematics*, 10(10):1679, 2022. doi: 10.3390/math10101679.

X. Zhou and Others. Integrated pricing and passenger flow assignment model based on prospect theory and logit model. *Mathematics*, 11(6):1412, 2023. doi: 10.3390/math11061412.